·人工智能与模式识别· 文章编号: 1000-3428(2020)06-0040-10 文献标志码: A 中图分类号: TP183

基于改进LSTM的儿童语音情感识别模型

余莉萍[1],梁镇麟[2],梁瑞宇[3]

(1.复旦大学 计算机科学技术学院,上海 201203; 2.东南大学 信息科学工程学院,南京 210096;
3.南京工程学院 信息与通信工程学院,南京 211167)

摘 要: 为实现不同儿童情感需求状态下帧级语音特征的有效获取,建立一种基于改进长短时记忆(LSTM)网络的儿童语音情感识别模型。采用帧级语音特征代替传统统计特征以保留原始语音中的时序关系,通过引入注意力机制将传统遗忘门和输入门转换为注意力门,并根据自定义的深度策略计算得到深度注意力门,从而提高语音情感识别性能。实验结果表明,在Fau Aibo儿童情感数据语料库及婴儿哭声情感需求数据库上,该模型在召回率和F1分数上相比基于传统LSTM的识别模型分别提高了3.14%、5.50%和1.84%、5.49%,在CASIA中文情感数据库上,其相比基于传统LSTM和GRU的识别模型训练时间更短、儿童语音情感识别率更高。

关键词: 儿童情感; 时序关系; 帧级语音特征; 深度注意力门; 长短时记忆网络

开放科学(资源服务)标志码(OSID):

中文引用格式: 余莉萍,梁镇麟,梁瑞宇. 基于改进LSTM的儿童语音情感识别模型[J]. 计算机工程,2020,46(6):40-49.

英文引用格式: YU Liping,LIANG Zhenlin,LIANG Ruiyu. Emotion recognition model for children speech based on improved LSTM[J]. Computer Engineering,2020,46(6):40-49.

Emotion Recognition Model for Children Speech Based on Improved LSTM

YU Liping[1],LIANG Zhenlin[2],LIANG Ruiyu[3]

(1.School of Computer Science and Technology,Fudan University,Shanghai 201203,China;
2.School of Information Science and Engineering,Southeast University,Nanjing 210096,China;
3.School of Information and Communications Engineering,Nanjing Institute of Technology,Nanjing 211167,China)

【Abstract】 To achieve the effective acquisition of frame-level speech features under different emotional needs of children,an emotion recognition model for children speech based on improved Long Short-Time Memory(LSTM) network is established. Frame-level speech features are used to replace the traditional statistical features,so as to retain the time sequence relationship of the original speech. Introducing attention mechanism to convert the traditional forget gate and input gate into attention gate,and the deep attention gate is calculated according to the customized depth strategy,so as to improve the performance of speech emotion recognition. Experimental results show that compared with the traditional LSTM based recognition model,the recall rate and F1 score of the model are increased by 3.14%,5.50% and 1.84%,5.49% respectively on Fau Aibo children's emotional data corpus and infant crying emotional demand database. Compared with the traditional LSTM and GRU based recognition model,the training time of the model is shorter and the recognition rate of children speech emotion is higher on CASIA Chinese emotion database.

【Key words】 children's emotional; time sequence relationship; frame-level speech feature; deep attention gate; Long Short-Term Memory(LSTM)

DOI: 10.19678/j.issn.1000-3428.0056559

0 概述

儿童情感识别是情感计算的重要部分[1]。儿童在情感发泄和应对不同情感时作出合理举措的能力远不如成年人,如果儿童情绪无法进行合理宣泄并及时得到疏导会导致其产生情绪障碍,进而引发焦虑症等心理健康问题。因此,运用适当的算法或模型对儿童情绪进行智能判断和合理疏导具有重要意义。

基金项目: 国家自然科学基金(61673108)。

作者简介: 余莉萍(1994—) 女,硕士研究生,主研方向为人工智能、认知科学; 梁镇麟,硕士研究生; 梁瑞宇,副教授、博士。

收稿日期: 2019-11-11 **修回日期:** 2019-12-31 **E-mail:** 1070776909@qq.com

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

研究人员从声学特征、机器学习和深度学习等方面对儿童情感识别进行深入研究。文献[2]提出利用支持向量机和卷积神经网络来构建检测儿童二级情绪状态的系统。文献[3]利用基于多智能体的交互系统对儿童的情感状况进行实时定义。文献[4]创建儿童双模态情感数据库并采用双模态情感识别方法衡量儿童情感的贡献比例，指出婴儿(或幼儿)的情感比大龄儿童的更难判断，婴儿通常用哭泣向父母或者监护人表达自身需求。文献[5]提取婴儿哭声的梅尔频率倒谱系数(Mel-Frequency Cepstral Coefficients，MFCC)并基于隐马尔科夫模型(Hidden Markov Model，HMM)对婴儿哭声进行分类，以识别婴儿是否处于健康状态。文献[6]将语谱图作为特征向量，选取卷积神经网络(Convolutional Neural Network，CNN)作为分类模型，对婴儿在疼痛、饥饿和困倦时的哭声进行分类和有效识别。文献[7]将支持向量机(Support Vector Machine，SVM)作为分类器对婴儿在饥饿、疼痛及困倦时的哭声进行分类，取得较好的识别效果。

虽然上述算法被成功应用于儿童情感识别，但是传统机器学习算法以及深度学习中的自编码器和卷积神经网络都只能接受具有固定维度的数据作为输入，这与实际中有效语音长度不断变化存在一定矛盾。针对该问题，文献[8-10]从短时语音帧中提取情感相关特征(以下称为帧级特征)，将静态统计函数(如均值、方差、最大值、线性回归系数等)作用于帧级特征上，最终串联形成具有固定维度的特征向量来表示该帧语音的特性。虽然该方法解决了模型输入的问题，但是通过统计分析处理后的语音特征丢失了原始语音的时序信息。

本文提出一种基于改进长短时记忆(Long Short-Term Memory，LSTM)的儿童语音情感识别模型，在 LSTM 网络结构的基础上，将帧级语音特征取代传统统计特征，用注意力门替换传统的遗忘门和输入门，并在多个时刻的细胞状态上加权注意力构建深度注意力门，以取得更好的识别性能。

1　相关工作

1.1　LSTM 网络

LSTM 网络是循环神经网络(Recurrent Neural Network，RNN)的一种变体，主要用于处理时间差较长的序列信息[11-13]。LSTM 网络通过加入遗忘门单元可以解决反向传播时 RNN 存在的梯度消失造成长期信息难以存放的问题。LSTM 网络已成功应用于自然语言处理[14-16]问题。为强化 LSTM 网络在特定任务中处理数据的能力，研究人员进一步对 LSTM 网络内部构造进行优化。文献[17]通过门控循环单元(Gated Recurrent Unit，GRU)将 LSTM 网络的输入门和遗忘门进行融合降低了模型参数，但是在大规模的数据集上，LSTM 网络在所有机器翻译任务上的指标均优于 GRU[18]。文献[19]通过 ConvLSTM 网络结构将 LSTM 的门结构计算方式由矩阵相乘改进为卷积，该方法在图像领域取得成效，但是对语音效果的改善十分有限。文献[20]通过前馈型序列记忆网络(Feedforward Sequential Memory Network，FSMN)将 RNN 的无限脉冲响应滤波器(Infinite Impulse Response Filter，IIR)记忆块改进为有限脉冲响应滤波器(Finite Impulse Response Filter，FIR)记忆块，并在语音识别和合成方面取得显著成效，但是 FSMN 通常需要堆叠很深的层数，因而 FSMN 较单向的 LSTM 网络存在延时[21]。文献[22]提出高级长短期记忆(Advanced LSTM)网络，利用注意力机制对多个细胞状态进行加权，能有效用于情感识别。但是文献[23]指出该方法并没有改变 LSTM 网络内部的门结构，且所需训练时间较多。此外，研究人员在如何堆叠 LSTM 结构以实现更可靠的情感识别方面不断探索。文献[24]通过卷积神经网络(Convolutional Neural Network，CNN)从 6 s 长的语音波形中提取多通道语音特征作为 LSTM 网络的输入，实现了端到端的情感识别。文献[25]通过 CNN 从 6 s 长的语音波形中提取 1 280 种抽象特征，与表情特征融合后作为 LSTM 网络的输入，实现了多模态情感识别。

传统的 LSTM 网络使用的计算公式如下：

$$f_t=\sigma(W_f\cdot[h_{t-1},x_t]+b_f) \tag{1}$$

$$i_t=\sigma(W_i\cdot[h_{t-1},x_t]+b_i) \tag{2}$$

$$\tilde{C}_t=\tanh(W_C\cdot[h_{t-1},x_t]+b_C) \tag{3}$$

$$C_t=f_t*C_{t-1}+i_t*\tilde{C}_t \tag{4}$$

$$o_t=\sigma(W_o\cdot[h_{t-1},x_t]+b_o) \tag{5}$$

$$h_t=o_t*\tanh(C_t) \tag{6}$$

其中，σ 为 sigmoid 激活函数，h_{t-1} 为 $t-1$ 时刻的隐层输出，x_t 为 t 时刻的输入，C_{t-1} 为 $t-1$ 时刻的细胞状态，$\tilde{C}_t$ 为 t 时刻的细胞状态候选值，f_t、i_t、o_t 分别为遗忘门、输入门和输出门。

1.2　注意力机制

注意力机制是在人类视觉注意力机制基础上形成的。注意力使得人类对视觉捕获到信息的重要部分给予更大关注，尽可能获取所关注目标的细节信息，同时减少对目标周围无关信息的关注，即对无关信息产生抑制。为有效利用 LSTM 网络历史时刻输出的信息，文献[26]将软注意力机制引入到 LSTM 网络模型(以下称为 LSTM 模型)中，并将其成功应用于机器翻译领域，通过对 LSTM 模型在不同时刻的输出进行注意力加权，可表达当前待翻译单词与其他单词的关联程度。文献[27]提出基于注意力机制的 encoder-decoder 结构，其应用于语音识别的效果优于 HMM 解码系统。文献[28]在 encoder-decoder 结构

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

的基础上提出局部注意力模型，首先预估一个对齐位置，然后在对齐位置处尺寸为 L 的窗口范围取类似于软注意力模型的概率分布。文献[29]将单头注意力机制改进为多头注意力机制，通过 Transformer 模型显著地提升了机器翻译的质量。

近年来，自注意力机制成为学者们研究的热点。文献[30]计算 LSTM 模型输出的自注意力，针对不同的时间步数计算出多个分数，进而提出新的 LSTM 模型，计算公式为：

$$\boldsymbol{A}=\text{softmax}(W_{s_2}\tanh(W_{s_1}\boldsymbol{H}^{\mathrm{T}})) \tag{7}$$

其中，$\boldsymbol{A}$ 为注意力分数矩阵，h_i 为 i 时刻隐层单元的输出，$\boldsymbol{H}$ 为 LSTM 模型每个时刻输出 h_i 堆叠在一起的结果：

$$\boldsymbol{H}=(h_1,h_2,\cdots,h_n) \tag{8}$$

加权后输出表示为：

$$\boldsymbol{M}=\boldsymbol{A}\boldsymbol{H} \tag{9}$$

注意力机制的引入减小了处理高维输入数据的计算负担，使得任务处理系统更专注于找到输入数据中与当前输出显著相关的信息，从而提高输出质量[28]。近年来，研究人员将注意力机制应用于语音情感效果的提升。文献[31]利用注意力机制在多层 LSTM 网络之间进行特征筛选和跨越链接，取得良好的情感识别效果。文献[32]在 RNN 的输出端提出本地注意力(Local Attention)机制，有效地提升了多个数据集的情感识别效果。

2 改进的深度注意力门

2.1 注意力门

本文将注意力机制引入 LSTM 模型的内部门结构，提出了基于注意力门的 LSTM 模型，从而大量减少了 LSTM 的参数数量；将深度的概念引入注意力门使得 LSTM 模型能更好地学习输入特征而避免信息冗余。本文提出的基于注意力门的 LSTM 结构使得每个时间步计算时，上一刻的细胞状态自行决定需要注意的特征，并在这一刻输入中利用注意力门修改传统遗忘门和输入门后对需要注意的特征进行加权。

由于传统的输入门和遗忘门仅由一个全连接层实现，因此需要训练足够多次后模型才能注意到需要留下的细胞状态信息和需要加入的新输入信息，从而导致其收敛减速。文献[33]在此基础上增加了窥视连接，将细胞状态也作为输入，在 3 个门中加入细胞状态信息，而参数的增加造成了训练时间和空间复杂度相应增加。本文对每一刻的细胞状态做自注意力，并对细胞状态不需要注意的部分加入输入的候选信息，自注意力算法用注意力门替换了遗忘门、输入门以及窥视连接所需的 3 个矩阵。

注意力门 a_t 的定义如下：

$$a_t=\text{activation}(V\cdot\tanh(W\cdot C_{t-1})) \tag{10}$$

其中，activation 为激活函数(可根据需要自选对应激活函数，但其值域应满足绝对值小于 1)，更新细胞状态的计算公式为：

$$C_t=a_t*C_{t-1}+(1-a_t)*\tilde{C}_t \tag{11}$$

注意力门能在提高模型识别率的同时减少参数数量和训练时间。在已有的报道中，通常会采用模型蒸馏[34]、8-bit 量化[35]、共享参数[36-37]等方法。本文提出基于注意力机制的注意力门，显著地减少了 LSTM 模型内部的参数。此外，由于在 LSTM 模型内部进行修改，对于较长的输入序列，基于注意力门的模型能减少更多的训练时间。例如，对于输入维度为 512、输出维度为 256 的一层 LSTM 模型来说，如果忽略偏置，其通常需要的参数为：1) 3 个门结构和候选值所需的维度为 $[512+256,256\times4]$ 的权重；2) 如果在计算门结构时考虑到上一刻的细胞状态，还需增加 $3\times[1,256]$ 的向量作为窥视门[38]。本文因为直接对细胞状态计算自注意力作为注意力门，所以不需再引入窥视门结构。同时，由于融合了遗忘门和输入门为注意力门，所需参数数量降为 $[512+256,256\times2]$ 和计算注意力的 $2\times[256,256]$ 的权重。对于本层而言，参数数量从最初的 787 200 降到 524 288，减少了 33.4% 的参数。对于层数更深、模型更复杂、数据量也更大的 LSTM 模型而言，有效地减少了参数数量。

2.2 深度注意力门

LSTM 模型通常用来处理时序信息，但是该信息会随着时间的累积而增加，因而 LSTM 模型在某一刻的计算(即更新细胞状态 c 和隐层输出 h)都只基于外部输入和上一刻的细胞状态与隐层输出。在注意力机制提出前，如果每一时刻都考虑之前多个时刻，会导致信息过多而遗失重要信息，以及增加计算量并导致梯度爆炸。但是，t 时刻细胞状态的信息不仅与 $t-1$ 时刻的信息有关，还与 $t-2$ 时刻的信息紧密相关，而 $t-2$ 时刻的信息在 $t-1$ 时刻被选择性遗忘(遗忘门)。为此，本文提出了深度遗忘门的概念，并设计对应的输入门。

深度遗忘门不仅关注上一时刻细胞状态的信息(深度 length = 1)，还关注 $t-2,t-3,\cdots,t-n$ 时刻(深度 length = n)细胞状态的信息，即构建 Deep-Attention-LstmCell 结构，如图 1 所示。

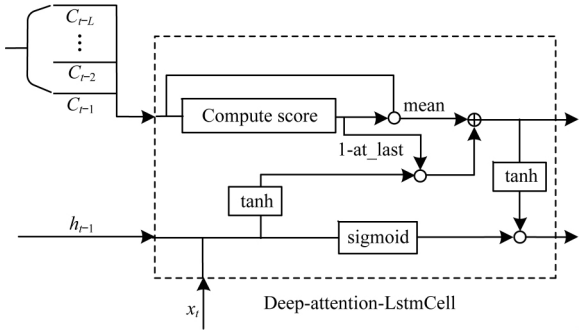


图 1 Deep-Attention-LstmCell 内部结构示意图

Fig. 1 Internal structure diagram of Deep-Attention-LstmCell

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

深度遗忘门具体实现如下：

$$C_{t-1}^{\text{stack}} = [C_{t-\text{length}}, C_{t-\text{length}+1}, \cdots, C_{t-1}] \tag{12}$$

$$a_t^{\text{stack}} = \text{activation}(V \cdot \tanh(W \cdot C_{t-1}^{\text{stack}})) \tag{13}$$

其中，$a_t^{\text{stack}} = [a_t^{t-\text{length}}, a_t^{t-\text{length}+1}, \cdots, a_t^{t-1}]$。此时，更新细胞状态的计算公式为：

$$C_t = \frac{\sum_i^{\text{length}} a_t^{t-i} * C_{t-i}}{\text{length}} + (1 - a_t^{t-1}) * \tilde{C}_t \tag{14}$$

值得注意的是，“深度”的引入会造成训练时间的增加。这是因为除了前向增加了在循环中对多个细胞状态计算各自的注意力门，反向传播中也增加了更多的链式求导。从模型的参数来看，虽然深度会造成训练时间的增加，但是因为各层深度的注意力门权重 V、W 共享，所以不会造成模型参数的增加。

本文提出深度的目的是提升语音情感的识别性能，为研究对该性能的提升效果，进行以下实验：

实验 1　研究深度性能对儿童情感识别率的影响。使用深度为 1、2 和 3 的基于注意力门的 LSTM 模型（以下称为注意力门 LSTM 模型）进行对比。

实验 2　研究参数数量和训练时间的降低对语音情感识别性能的影响。使用深度为 1 的注意力门 LSTM 模型和传统的 GRU 模型、LSTM 模型进行实验对比。

2.3　训练整体框架

深度注意力门 LSTM 模型的训练框架如图 2 所示。其中，LSTM0 表示第 1 层深度注意力门 LSTM 模型，LSTM1 表示第 2 层深度注意力门 LSTM 模型。x_t 为分帧加窗后第 t 帧语音所提取的 INTERSPEECH 语音特征[8-10]，h_t 和 C_t 为其对应的 LSTM 模型输出的隐层输出和细胞状态。由图 2 可以看出，传统 LSTM 模型在 t 时刻的输入状态是 (h_{t-1}, C_{t-1})，而在本文的训练中，每一时刻的状态扩充为 $(h_{t-1}, \{C_{t-1}, C_{t-2}, \cdots, C_{t-L}\})$，其中 L 为注意力门的深度。包含前序所有时序信息的最后一层 LSTM 的最后一个状态被输入到后续分类网络中，以进行对儿童情感的识别。

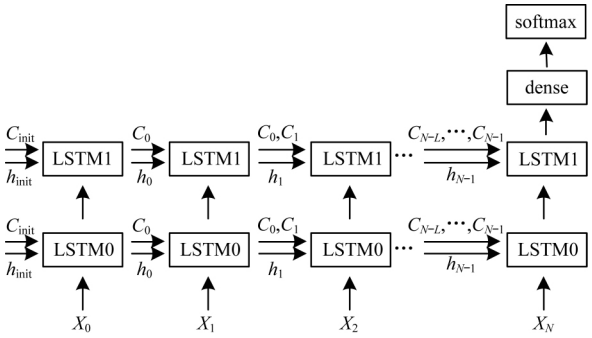


图 2　深度注意力门 LSTM 模型训练框架

Fig. 2　Training frame of deep attention gate LSTM model

3　实验设置与分析

3.1　实验设置

实验使用 2 个情感表征形式差异较大的数据库来验证本文算法对于儿童语音情感的有效性。为研究本文算法处理其他类型情感识别问题的性能，以及参数数量降低是否能优化时间或降低性能，实验采用 Fau Aibo 儿童情感语料库、婴儿哭声情感需求语料库和 CASIA 汉语情感语料库[39]进行验证。

1) Fau Aibo 儿童情感语料库：Fau Aibo 用高性能的无线耳麦收集并录制了 10 岁左右的 51 名儿童和电子宠物 Aibo 在游戏过程中的发声，保留其中情感较突出的数据，其中自然语言包含 48 401 个单词。为了保证标注的准确性，该语料库的每个样本均由 5 个语言专业的学生试听后通过投票标注情感。本文从该语料库中挑选了 INTERSPEECH 2009 情感挑战赛中定义的 5 类标签：即 A（Angry、Touchy、Reprimanding）、E（Emphatic）、N（Neutral）、P（Motherese、Joyful）和 R（Rest）。

2) 婴儿哭声情感需求语料库：由于国际上没有统一的婴儿哭声情感需求语料库，笔者与国内某医院合作录制了婴儿在生气（Angry）、饥饿（Hungry）、疼痛（Pain）、伤心（Sad）和困倦（Tired）5 种状态下的哭声语音文件，并对该文件进行了标注。为提高该语料库的质量，笔者通过人工的方法对婴儿哭声情感语料进行筛选，除去婴儿哭泣时夹杂父母安慰孩子的语音相关帧，以及 2 个和 2 个以上婴儿同时哭泣的语音相关帧。该语料库经过筛选后包含 10 名婴儿（男孩和女孩各 5 名），每位婴儿在每种状态下有 20 条语料，共计 $5 \times 10 \times 20 = 1\,000$ 条语料。

3) CASIA 汉语情感语料库由中国科学院自动化所录制，由 4 个相关专业的人员按照生气（angry）、高兴（happy）、害怕（fear）、悲伤（sad）、惊讶（surprise）和中性（neutral）等 6 种情绪进行发音。该语料库共有 9 600 条语料。

3.2　帧级特征的选择

实验在 INTERSPEECH 语音情感特征[8-10]的基础上选用了部分帧级特征。文献[8]提取了 16 种低级描述符（LLD、过零率、均方根帧能量、基音频率和梅尔频率倒谱系数 1～12）及其差分系数，针对其中每个描述符，又计算了 12 个统计函数，因此总特征向量共有 $16 \times 2 \times 12 = 384$ 个特征。INTERSPEECH 2010（IS2010）语音情感特征[9]在此基础上，将 LLD 增加到 38 种，因而总特征维度扩展到 1 582 维。INTERSPEECH ComPARE[10]特征集的特征维度则增加到 6 373 维。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

实验所用帧级语音情感特征集如表 1 所示。与 INTERSPEECH 语音情感特征相比，该特征集未计算统计函数，这是因为:

1) 计算统计函数后的固定长度特征损失了原始语音中的大量信息，如时序信息和序列间的关系等。

2) 文献 [40] 认为深度学习具有自动学习特征变化的能力，能够从底层语音特征中学习到与任务相关的深层特征，由此可知帧级特征更适合作为深度学习网络的输入。

3) 包含大量统计信息的特征会大量增加训练模型的参数数量、训练时间和复杂度，对训练设备有一定要求。

表 1 帧级语音情感特征集

Table 1 Frame-level speech feature set

特征名称	描述
voiceProb	语音活跃度
HNR	对数谐波噪声比(HNR)
F0	基频
F0raw	在无声片段中没有阈值的原始基频候选者
F0env	基频包络
jitterLocal	连续周期间的平均绝对差值除以帧中所有周期的平均周期长度
jitterDDP	连续周期间的连续差异间的平均绝对差值除以帧中所有周期的平均周期长度
shimmerLocal	连续周期内插峰值幅度间的平均绝对差值除以帧中所有周期的平均峰值幅度
harmonicERMS	谐波分量 RMS 能量(能量平均周期波形)
noiseERMS	噪声分量 RMS 能量(重复平均周期波形与实际信号间的差信号能量)
pcm_loudness_sma	响度
pcm_loudness_sma_de	响度的一阶回归
mfcc_sma [0] ~ [14]	梅尔频率倒谱系数
mfcc_sma_de [0] ~ [14]	mfcc 的一阶回归
pcm_Mag [0] ~ [25]	梅尔谱
logMelFreqBand [0] ~ [7]	对数梅尔频率段
lpcCoeff [0] ~ [7]	线性预测编码系数
lspFreq [0] ~ [7]	线谱对频率
pcm_zcr	计算过零率

3.3 实验参数设置

原始数据分为训练集与测试集两部分，这两部分数据相互隔离，且训练集与测试集的比例为 4∶1。实验均采用单向两层 LSTM 堆叠结构，并使用了一个全连接层和一个 softmax 层作为训练模型。在训练过程中，使用小批量梯度下降法并采用 tanh 作为激活函数，具体参数如表 2 所示。为保证实验对比的有效性，相同的语料库和模型实验参数均完全相同。

表 2 实验参数

Table 2 Experimental parameters

参数名称	婴儿哭声情感需求语料库参数值	Fau Aibo 儿童情感语料库参数值	CASIA 汉语情感数据库参数值
学习率 (Eta)	1e-3 beta2 = 0.7	1e-4 beta2 = 0.9	1e-4 beta2 = 0.9
批大小 (Batch size)	64	128	128
迭代次数 (Epochs)	1 500	1 200	1 200
隐层单元数 (Lstn cells)	[512,256] 单向	[512,256] 单向	[512,256] 单向
全连接层 (Dense layers)	[256,128]	[256,128]	[256,128]
分类层 (Softmax layers)	[128,5]	[128,5]	[128,6]
正则化系数 (L2)	1e-4	1e-4	1e-4

4 算法性能分析

4.1 深度的性能分析

传统 LSTM 模型通过遗忘门除去多余信息，通过输入门获取新信息。本文利用自注意力和 LSTM 的基本结构，对细胞状态做自注意力，从而对 LSTM 的遗忘门和输入门进行对比。同时，考虑到时序信息的关联性，提出基于深度的自注意力门，并在深度为 1、2 和 3 的条件下分别进行比较。实验对比了 4 类模型: 即传统 LSTM 模型、LSTM + deepf_1 模型、LSTM + deepf_2 模型、和 LSTM + deepf_3 模型，上述模型对应的深度分布为 0、1、2 和 3，如图 3 所示。由图 3(a)、图 3(b)、图 4(a) 和图 4(b) 可以看出，采用婴儿哭声情感需求语料库和 Fau Aibo 儿童情感语料库，利用提出的注意力门替换掉传统 LSTM 模型的遗忘门和输出门后，注意力门 LSTM 模型在训练集和测试集上的收敛速度比传统 LSTM 模型的大幅提高; 采用婴儿哭声情感需求语料库时，传统 LSTM 模型约在第 5 000 步开始稳定收敛，而注意力门 LSTM 模型约在 2 500 步开始稳定收敛; 采用 Fau Aibo 儿童情感语料库时，传统 LSTM 模型约在第 30 000 步开始稳定收敛，而注意力门 LSTM 模型在约 17 000 步开始稳定收敛; 当模型收敛后，注意力门 LSTM 模型对儿童情感的平均识别率明显优于传统 LSTM 模型。由图 3(c) 和图 4(c) 可以看出，当模型收敛时，注意力门 LSTM 模型在测试集上的平均识别率、最低识别率和最高识别率均比传统 LSTM 模型高约 5%; 当注意力门的深度加大后，注意力门 LSTM 模型的上述性能得到进一步提升。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

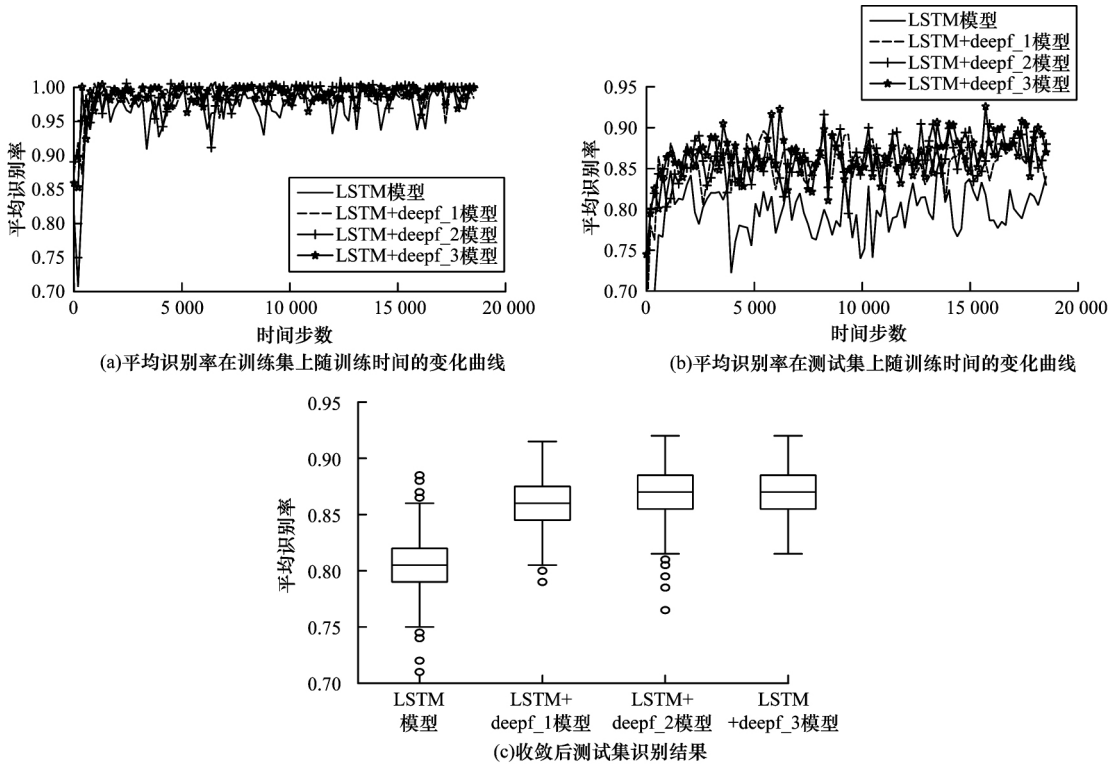


图 3　不同 LSTM 模型采用婴儿哭声情感需求语料库的性能情况

Fig. 3　Performance of different LSTM models using emotional needs corpus of infant crying database

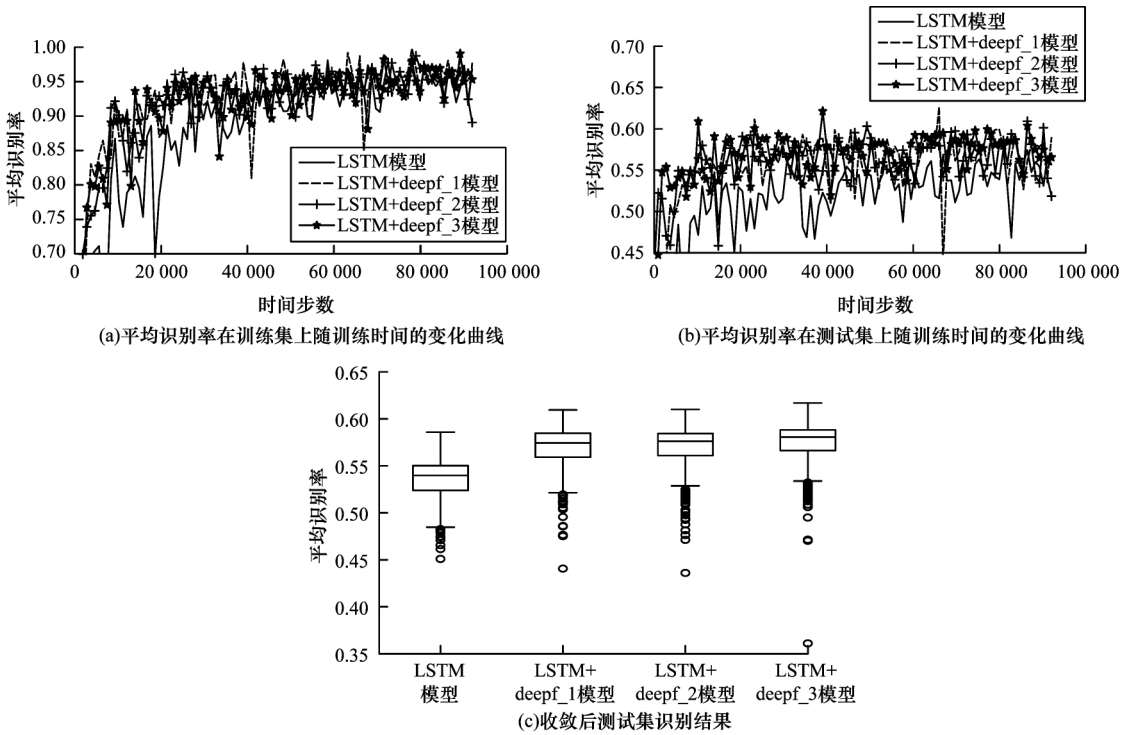


图 4　不同 LSTM 模型在采用 Fau Aibo 儿童情感语料库的性能情况

Fig. 4　Performance of different LSTM models using Fau Aibo children's emotion corpus database

通过上述分析可知，注意力门 LSTM 模型的性能得到改善是因为其修改了传统 LSTM 模型的遗忘门和输入门，使得 LSTM 模型能针对上一刻的细胞状态通过自注意力来留下重要信息，并将不重要的信息作为新加入的输入在对应位置进行补充，从而提升 LSTM 模型性能; 注意力门 LSTM 模型引入深度概念后，使得每次遗忘操作由多个细胞状态决定而不是由其中某一个细胞状态决定。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

为定量分析不同模型在测试集中对每类情感的识别性能,取各模型在测试集上从训练开始到结束识别率最高一次的模型性能指标进行对比,采用婴儿哭声情感需求语料库和 Fau Aibo 儿童情感语料库得到的性能指标如表 3 和表 4 所示。可见对于测试集而言,注意力门 LSTM 模型的性能指标均优于传统 LSTM 模型。

表 3 不同 LSTM 模型采用婴儿哭声情感需求语料库的性能指标

Table 3 Performance indicators of different LSTM models using emotional needs corpus of infant crying database

模型	衡量标准	生气	饥饿	疼痛	伤心	困倦	AVG
样本数	—	40	45	34	35	46	200
LSTM	召回率	0.875	0.911	0.824	0.829	0.957	0.885
	F1 分数	0.875	0.901	0.848	0.906	0.889	0.885
LSTM + deepf_1	召回率	0.875	0.889	0.882	1.000	0.935	0.915
	F1 分数	0.909	0.941	0.822	0.946	0.945	0.916
LSTM + deepf_2	召回率	0.925	0.978	0.882	0.943	0.957	0.940
	F1 分数	0.949	0.957	0.923	0.930	0.936	0.940
LSTM + deepf_3	召回率	0.925	0.978	0.824	0.943	0.957	0.930
	F1 分数	0.949	0.926	0.875	0.943	0.946	0.930

表 4 不同模型采用 Fau Aibo 儿童情感语料库的性能指标

Table 4 Performance indicators of different LSTM models using Fau Aibo children's emotion corpus database

模型	衡量标准	A	E	N	P	R	AVG
样本数	—	611	1 508	5 376	215	546	8 256
LSTM	召回率	0.352	0.373	0.755	0.088	0.081	0.594
	F1 分数	0.339	0.373	0.743	0.110	0.093	0.586
LSTM + deepf_1	召回率	0.326	0.300	0.814	0.153	0.119	0.621
	F1 分数	0.358	0.338	0.770	0.173	0.133	0.603
LSTM + deepf_2	召回率	0.339	0.289	0.826	0.158	0.081	0.625
	F1 分数	0.342	0.340	0.772	0.173	0.104	0.601
LSTM + deepf_3	召回率	0.360	0.327	0.800	0.191	0.095	0.619
	F1 分数	0.371	0.363	0.765	0.192	0.112	0.604

由表 3 可以看出,采用婴儿哭声情感语料库时,注意力门 LSTM 模型召回率除了“困倦”项和传统 LSTM 模型较接近外,其他 4 项均优于传统 LSTM 模型;而注意力门 LSTM 模型的 F1 分数在 5 类情感上均优于传统 LSTM 模型。在深度方面,深度 3 和深度 2 的注意力门 LSTM 模型的性能接近,除了“伤心”外,上述模型其他 4 项的召回率和 F1 分数均优于深度 1 的注意力门 LSTM 模型。

由表 4 可以看出,采用 Fau Aibo 儿童情感语料库时,注意力门 LSTM 模型的召回率和 F1 分数除了 E 类比传统 LSTM 模型要低,其他 4 项均优于传统 LSTM 模型。在深度方面,深度 3 和深度 2 的注意力门 LSTM 模型性能接近,除了 R 类外,上述模型其他 4 项的召回率和 F1 分数均优于深度 1 的注意力门 LSTM 模型。

值得注意的是,Fau Aibo 儿童情感语料库各类别的样本数量不均衡,其中 *N* 类最多有 5 376 个样本,而 *P* 类最少只有 215 个样本。由上述分析可知,随着深度的加大,可以增强模型对少量样本的学习。和传统 LSTM 模型相比,采用婴儿哭声情感语料库时,LSTM + deepf_2 模型的召回率提高 5.50%,F1 分数提高 5.49%;采用 Fau Aibo 儿童情感语料库时,LSTM + deepf_2 模型的召回率提高 3.14%,LSTM + deepf_3 模型的 F1 分数提高 1.84%。

4.2 注意力门的时间和性能分析

和传统 LSTM 模型相比,注意力门 LSTM 模型将注意力机制改进为注意力门机制,并用注意力门替换了 LSTM 模型的遗忘门和输入门,从而大量减少了 LSTM 模型的参数。以下实验中将两层 LSTM 模型和注意力门 LSTM 模型进行对比。为了和其他低参数 RNN 进行对比,将 LSTM 模型、LSTM + deepf_1 模型和 GRU 模型在时间和识别性能方面进行对比。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

前文对参数量的减少已进行具体分析(见 2.1 节)。在以下实验中，两层注意力门 LSTM 模型将参数数量从“(93 +512) ×512 ×4 +3 ×512 +(512 +256) ×256 ×4 +3 ×256 =2 027 776”降低为“(93 +512) ×512 ×2 +2 ×512 ×512 +(512 +256) ×256 ×2 +2 ×256 ×256 =1 668 096”。此外，还引入深度的概念使得 LSTM 模型更好地学习输入特征以避免信息冗余。注意力门 LSTM 结构使得每个时间步计算时，上一刻的细胞状态自行决定需要注意的特征，并在这一刻的输入中利用注意力门修改传统的遗忘门和输入门，从而对需要注意的特征进行加权，以加快网络的收敛速度。

由图 5 可以看出，采用 CASIA 汉语情感语料库时，在相同的输入数据、网络参数、批大小和硬件设施下训练 1 200 次后，LSTM + deepf_1 模型所需时间少于传统 LSTM 模型，同时多于 GRU 模型。这是因为注意力门减少了模型的参数数量并降低了运算复杂度。此外，当运行时间相同时，因为注意力门 LSTM 结构使得每个时间步在计算时，上一刻的细胞状态自行决定需要注意的特征，对需要注意的特征进行加权，并在权重较小的地方利用候补值进行补充，所以 LSTM + deepf_1 模型的收敛速度要明显优于传统 LSTM 模型和 GRU 模型。

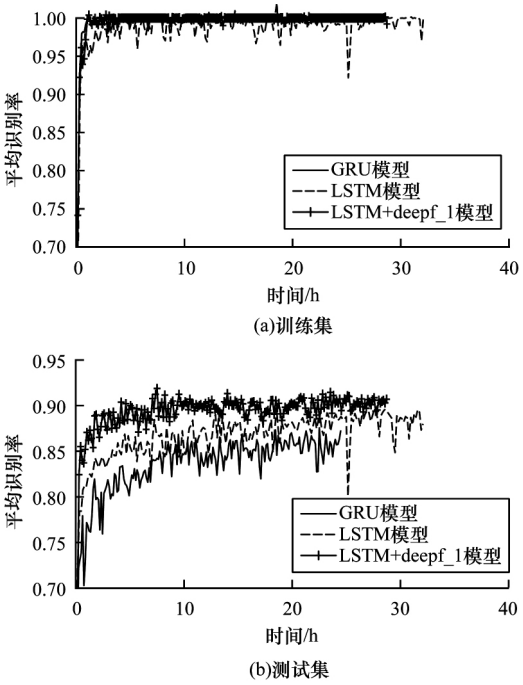


图 5　不同模型采用 CASIA 汉语情感语料库训练 1 200 次的所用时间曲线

Fig. 5　Time curve of 1 200 epochs trained by CASIA Chinese emotion corpus of different models

由图 6 可以看出，LSTM + deepf_1 模型的平均识别率最大，传统 LSTM 模型次之，GRU 模型最小。这是因为虽然 GRU 模型参数数量减少的更多且训练时间更短，但是随着数据集的不断迭代，其模型结构复杂度比传统 LSTM 模型更低，平均识别率比传统 LSTM 模型更小；LSTM + deepf_1 模型通过注意力算法在每个时间步对细胞状态进行主动筛选，减少了模型的参数数量和训练时间，显著地提升了识别性能。

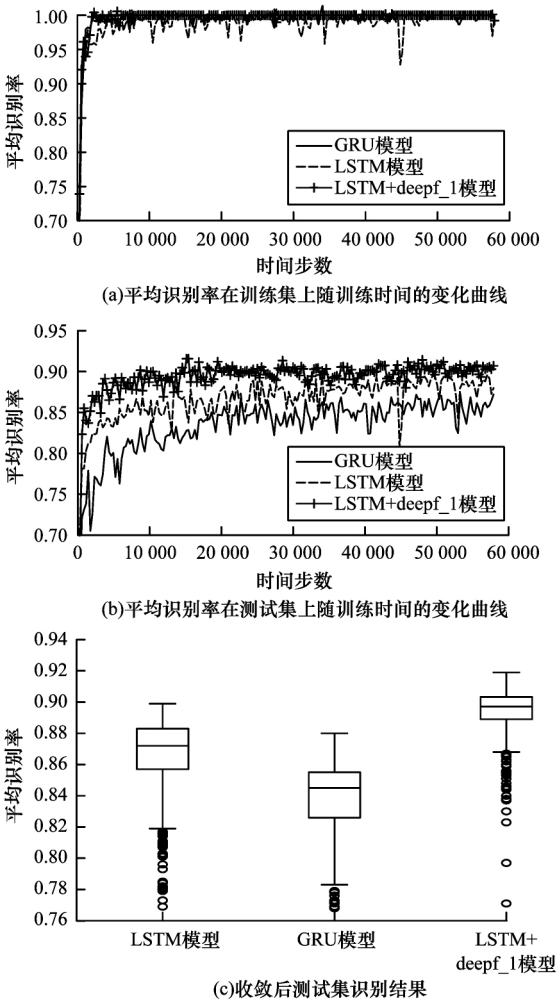


图 6　不同模型采用 CASIA 汉语情感语料库的性能情况

Fig. 6　Performance of different models using CASIA Chinese emotion corpus database

5　结束语

本文提出一种基于改进 LSTM 网络的儿童语音情感识别模型，用帧级语音特征代替传统语音特征，将注意力机制引入 LSTM 网络模型内部结构的遗忘门和输入门并形成注意力门，按照自定义的深度建立基于深度注意力门的 LSTM 模型。实验结果表明，在婴儿哭声和儿童情感数据库上，本文模型的

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

识别率显著高于传统 LSTM 模型，且深度模型的识别率比浅层模型的更高。在包含其他情感的 CASIA 数据库上，本文模型训练时间短于 LSTM 模型，且识别率高于 LSTM 模型和 GRU 模型。下一步将把本文模型引入语音识别、机器翻译以及测谎等领域，对连续情感的语料库进行测试和研究并改进计算注意力分数的模型，进一步提升儿童语音情感识别率。

参考文献

[1] LU Fang, CHEN Guopeng. An overview on the development of children's emotion regulation [J]. Psychological Science, 2003, 26(5): 928-929. (in Chinese)
陆芳，陈国鹏. 儿童情绪调节的发展研究 [J]. 心理科学，2003，26(5)：928-929.

[2] GONG Y, POELLABAUER C. Continuous assessment of children's emotional states using acoustic analysis [C]//Proceedings of 2017 IEEE International Conference on Healthcare Informatics. Park City, USA: IEEE Press, 2017: 171-178.

[3] DE SILVA P R, MADURAPPERUMA A P, MARASINGHE A, et al. A multi-agent based interactive system towards Child& #146; s emotion performances quantified through affective body gestures [C]//Proceedings of the 18th International Conference on Pattern Recognition. Hong Kong, China: IEEE Press, 2006: 1236-1239.

[4] DAI Weijia. Research on expression and speech bimodal emotion recognition of children [D]. Nanjing: Southeast University, 2016. (in Chinese)
戴惟嘉. 基于表情和语音双模态的儿童情感识别研究 [D]. 南京：东南大学，2016.

[5] LEDERMAN D, COHEN A, ZMORA E, et al. On the use of hidden Markov models in infants' cry classification [C]//Proceedings of the 22nd Convention on Electrical and Electronics Engineers in Israel. Tel-Aviv, Israel: IEEE Rress, 2002: 350-352.

[6] CHANG Chuanyu, LI Jiajing. Application of deep learning for recognizing infant cries [C]//Proceedings of 2016 IEEE International Conference on Consumer Electronics-Taiwan. Nantou County, China: IEEE Press, 2016: 1-2.

[7] CHANG C Y, CHANG C W, KATHIRAVAN S, et al. DAG-SVM based infant cry classification system using sequential forward floating feature selection [J]. Multidimensional Systems and Signal Processing, 2017, 28(3): 961-976.

[8] SCHULLER B, STEIDL S, BATLINER A. Theinterspeech 2009 emotion challenge [C]//Proceedings of the 10th Annual Conference of the International Speech Communication Association 2009. Brighton, UK: IEEE Press, 2009: 1-7.

[9] SCHULLER B, STEIDL S, BATLINER A, et al. The INTERSPEECH 2010 paralinguistic challenge [C]//Proceedings of the 11th Annual Conference of the International Speech Communication Association 2010. Makuhari, Japan: IEEE Press, 2010: 25-32.

[10] SCHULLER B, STEIDL S, BATLINER A, et al. The INTERSPEECH 2016 computational paralinguistics challenge: deception, sincerity and native language [C]//Proceedings of Interspeech 2016. San Francisco, USA: ISCA, 2016: 2001-2005.

[11] HOCHREITER S, SCHMIDHUBER J. Long short-term memory [J]. Neural Computation, 1997, 9(8): 1735-1780.

[12] HAN Wenjing, LI Haifeng. A brief review on emotional speech databases [J]. Intelligent Computer and Applications, 2013, 3(1): 5-7. (in Chinese)
韩文静，李海峰. 情感语音数据库综述 [J]. 智能计算机与应用，2013，3(1)：5-7.

[13] ATHIWARATKUN B, STOKES J W. Malware classification with LSTM and GRU language models and a character-level CNN [C]//Proceedings of 2017 IEEE International Conference on Acoustics, Speech and Signal Processing. New Orleans, USA: IEEE Press, 2017: 2482-2486.

[14] MERITY S, KESKAR N S, SOCHER R. Regularizing and optimizing LSTM language models [EB/OL]. (2017-08-07) [2019-10-20]. https://arxiv.org/abs/1708.02182.

[15] LI Wei, MAK B. Derivation of document vectors from adaptation of LSTM language model [C]//Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics. Stroudsburg, USA: Association for Computational Linguistics, 2017: 456-461.

[16] LIU Yue, ZHAI Donghai, REN Qingning. News text classification based on CNLSTM model with attention mechanism [J]. Computer Engineering, 2019, 45(7): 303-308. (in Chinese)
刘月，翟东海，任庆宁. 基于注意力 CNLSTM 模型的新闻文本分类 [J]. 计算机工程，2019，45(7)：303-308.

[17] CHO K, VAN M B, GULCEHRE C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation [EB/OL]. (2014-06-03) [2019-10-20]. https://arxiv.org/abs/1406.1078.

[18] BRITZ D, GOLDIE A, LUONG M T, et al. Massive exploration of neural machine translation architectures [EB/OL]. (2017-03-11) [2019-10-20]. https://arxiv.org/abs/1703.03906.

[19] SHI Xingjian, CHEN Zhourong, WANG Hao, et al. Convolutional LSTM network: a machine learning approach for precipitation nowcasting [EB/OL]. (2015-06-13) [2019-10-20]. https://arxiv.org/abs/1506.04214v1.

[20] ZHANG Shiliang, JIANG Hui, WEI Si, et al. Feedforward sequential memory neural networks without recurrent feedback [EB/OL]. (2015-10-09) [2019-10-20]. https://arxiv.org/abs/1510.02693.

[21] ZHANG Shiliang, LEI Ming, YAN Zhijie, et al. Deep-FSMN for large vocabulary continuous speech recognition [C]//Proceedings of 2018 IEEE International Conference on Acoustics, Speech and Signal Processing. Calgary, Canada: IEEE Press, 2018: 5869-5873.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[22] TAO Fei,LIU Gang. Advanced LSTM: a study about better time dependency modeling in emotion recognition [C] // Proceedings of 2018 IEEE International Conference on Acoustics,Speech and Signal Processing. Calgary,Canada: IEEE Press,2018: 2906-2910.

[23] XIE Yue,LIANG Ruiyu,LIANG Zhenlin,et al. Speech emotion classification using attention-based LSTM [J]. ACM Transactions on Audio, Speech, and Language Processing,2019,27(11): 1675-1685.

[24] TRIGEORGIS G, RINGEVAL F, BRUECKNER R, et al. Adieu features end-to-end speech emotion recognition using a deep convolutional recurrent network [C] // Proceedings of 2016 IEEE International Conference on Acoustics, Speech and Signal Processing. Shanghai, China: IEEE Press,2016: 5200-5204.

[25] TZIRAKIS P, TRIGEORGIS G, NICOLAOU M A, et al. End-to-end multimodal emotion recognition using deep neural networks [J]. IEEE Journal of Selected Topics in Signal Processing,2017,11(8): 1301-1309.

[26] BAHDANAU D, HYUN CHO K, BENGIO Y. Neural machine translation by jointly learning to align and translate [EB/OL]. (2014-09-01) [2019-10-20]. https://arxiv.org/abs/1409.0473.

[27] CHOROWSKI J ,BAHDANAU D ,CHO K ,et al. End-to-end continuous speech recognition using attention-based recurrent NN: first results [EB/OL]. (2014-12-04) [2019-10-20]. https://arxiv.org/abs/1412.1602.

[28] LUONG M T, PHAM H, MANNING C D. Effective approaches to attention-based neural machine translation [EB/OL]. (2015-08-17) [2019-10-20]. https://arxiv.org/abs/1508.04025.

[29] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [C] //Proceedings of Advances in neural information processing systems 2017. Long Beach,USA: IEEE Press,2017: 5998-6008.

[30] LIN Z H,FENG M W,SANTOS C N,et al. A structured self-attentive sentence embedding [EB/OL]. (2017-03-09) [2019-10-20]. https://arxiv.org/abs/1703.03130.

[31] XIE Yue, LIANG Ruiyu, LIANG Zhenlin, et al. Attention-based dense LSTM for speech emotion recognition [J]. ICE Transactions on Information and Systems,2019,102(7): 1426-1429.

[32] MIRSAMADI S,BARSOUM E,ZHANG C. Automatic speech emotion recognition using recurrent neural networks with local attention [C] //Proceedings of 2017 IEEE International Conference on Acoustics,Speech and Signal Processing. New Orleans,USA: IEEE Press,2017: 2227-2231.

[33] GERS F A,SCHMIDHUBER J. Recurrent nets that time and count [C] //Proceedings of Proceedings of the IEEE-INNS-ENNS International Joint Conference on Neural Networks. Como,Italy: IEEE Press,2000: 189-194.

[34] HINTON G, VINYALS O, DEAN J. Distilling the knowledge in a neural network [EB/OL]. (2015-03-09) [2019-10-20]. https://arxiv.org/abs/1503.02531.

[35] JACOB B,KLIGYS S,CHEN B,et al. Quantization and training of neural networks for efficient integer-arithmetic-only inference [C] //Proceedings of IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City,USA: IEEE Press,2018: 1-5.

[36] HAN S,MAO H Z,DALLY W J. Deep compression: compressing deep neural networks with pruning,trained quantization and huffman coding [EB/OL]. (2015-10-01) [2019-10-20]. https://arxiv.org/abs/1510.00149.

[37] DAI Dawei,YU Liping,WEI Hui. Parameters sharing in residual neural networks [J]. Neural Processing Letters, 2020,51(2): 1393-1410.

[38] HOCHREITER S, SCHMIDHUBER J. Long short-term memory [J]. Neural Computation,1997,9(8): 1735-1780.

[39] PAN Shifeng, TAO Jianhua, LI Ya. The CASIA audio emotion recognition method for audio/visual emotion challenge 2011 [C] //Proceedings of Affective Computing and Intelligent Interaction. Berlin,Germany: Springer Berlin Heidelberg,2011: 388-395.

[40] JAITLY N,HINTON G. Learning a better representation of speech soundwaves using restricted boltzmann machines [C] //Proceedings of 2011 IEEE International Conference on Acoustics,Speech and Signal Processing. Prague,Czech Republic: IEEE Press,2011: 5884-5887.

编辑　宋　圆

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net