分 类 号：TP391　　密　　级：公开
单位代码：10149　　学　　号：2018146

沈阳化工大学

硕士研究生学位论文

题　　目：基于深度学习的婴儿啼哭情感分析研究

专　　业：计算机软件与理论

研 究 生：王晰墨

指导老师：王亮　　副教授

日　　期：　　2021 年 6 月 13 日

中国知网　https://www.cnki.net

Dissertation Submitted to

Shenyang University of Chemical Technology

for

The Master Degree of

Computer Software and Theory

Analysis of Infant Crying Sentiment Based on Deep Learning

By

WANG Ximo

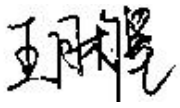
Supervisor：Wang Liang

June 2021

中国知网 https://www.cnki.net

沈阳化工大学硕士学位论文独创性声明

本人郑重声明：此处所提交的硕士学位论文《基于深度学习的婴儿啼哭情感分析研究》，是本人在导师指导下，在沈阳化工大学攻读硕士学位期间独立进行研究工作所取得的成果。据本人所知，论文中除已注明部分外不包含他人已发表或撰写过的研究成果。对本文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。本声明的法律结果将完全由本人承担。

作者签字：  　　日期：2021 年 6 月 13　日

中国知网　https://www.cnki.net

中国知网 https://www.cnki.net

摘要

情感分析是人工智能领域中自然语言处理的重要研究方向之一，近年来备受国内外研究机构和相关人员的关注。情感分析包括面向文本、面向图片、面向视频、面向语音等各个方面。由于语音是人类最原始最直接的交流方式，包含着人类丰富的情感，所以语音的情感分析尤为重要。本文将婴儿哭声的情感分析作为研究背景，目的是找到可以对婴儿哭声的情感进行自动识别的智能模型。通过智能模型实现对婴儿身体健康状况、心理发展及精神状态做出准确的判断，从而能有效的帮助婴儿健康成长，本课题的研究具有重要的理论意义和实际应用价值。本文在前人研究的基础上，针对婴儿啼哭情感分析需要解决的有关问题，主要做了以下几方面工作：

（1）针对现如今未制定出一个规范的，标准化的婴儿哭声数据库所导致的研究人员在划分婴儿哭声类别时出现差异的问题，本文查阅了大量文献，并在此基础上进行了分析与研究。根据丹斯婴儿语言理论设计并建立了包含五种情感的婴儿哭声数据库，为后续的模型训练以及本领域其他研究人员提供了可靠的数据集。

（2）针对婴儿哭声数据的预处理问题，本文对婴儿哭声发声特点进行研究，总结了婴儿啼哭与成人语音的差异及特点，并根据婴儿哭声数据的特征提出采用预加重、分帧、加窗、端点检测的方法进行哭声数据预处理，为后续生成语谱图提供了优质的音频数据。

（3）针对现有婴儿哭声情感分类模型的情感识别率和模型训练时间效率有待提高的问题，对卷积神经网络和 Transformer 模型等基于深度学习的语音情感分析技术的优势及长短期记忆神经网络的不足进行了深入研究。随后本文提出采用基于 CNN-Transformer 模型对婴儿哭声情感进行分类，该模型利用 CNN 提取语谱图的特征图，并将提取后的特征图压缩成为向量，然后将向量输入到 Transformer 模型的 Encoder 部分对婴儿连续哭声进行时序建模。最后通过采用修改位置编码、多头感知、残差链接与归一化、全连接前馈网络等技术对 CNN-Transformer 模型进行了改进。

（4）为了对提出的模型进行准确地评估，本文在自建立的数据库上对提出的 CNN-Transformer 婴儿哭声情感分类模型进行训练，为了证明实验的公平性，采用公开的 ESC-50 数据集和 Freesound 数据集作为测试集进行验证。实验结果表明提出的模型在分类正确率、单分类正确率、训练耗时几个主要性能指标上有明显的提升。

综上所述，本文对婴儿哭声的特点进行了充分的分析与研究，设计了包含五种情感的婴儿哭声数据库，提出了一种基于 CNN-Transformer 的婴儿哭声情感分析模型，并对该模型进行了实验验证及分析。本文所做的工作为其他领域的语音情感分析提供了一种新的研究思路和方法。

关键词：语音识别；情感分析；婴儿哭声；深度学习；CNN-Transformer 模型

中国知网 https://www.cnki.net

Abstract

Sentiment analysis is one of the main research directions of natural language processing in artificial intelligence, which has attracted much attention from domestic and foreign research institutions and related personnel in recent years. Sentiment analysis includes text oriented, picture oriented, video oriented, speech-oriented and other fields. As speech is the most primitive and direct way of human communication, which contains rich emotions of human beings, emotion analysis of speech is particularly important. The purpose of this paper is to find an intelligent model which can automatically recognize the emotion of baby cry. To achieve the baby's physical health, psychological development and mental state to make an accurate judgment, so as to effectively help the healthy growth of the baby. That was the reason why he was so much more important for the search that he made for the application. On the basis of previous research, this paper mainly does the following work in order to solve the problems that need to be solved in the analysis of infant crying sentiment：

（1）In view of the fact that there is no standard, standardized infant crying database that has caused the researchers to classify infant crying categories, this article has consulted a large number of documents, and conducted analysis and research on this basis. According to Dunstan baby language theory, a baby crying database containing five emotions was designed and established, which provides a reliable data set for subsequent model training and other researchers in the field.

（2）Aiming at the pre-processing of baby crying data, this paper studies the characteristics of baby crying voice, summarizes the differences and characteristics of baby crying and adult voice, and proposes the use of pre-emphasis, framing, and windowing based on the characteristics of baby crying data. , The endpoint detection method performs crying data preprocessing to provide high-quality audio data for subsequent generation of spectrograms.

（3）In order to improve the efficiency of sentiment recognition rate and model training time of existing infant cry emotion classification model, a Convolutional Neural network (CNN) was proposed.and Transformer model and other deep learn-based speech sentiment analysis technology advantages and shortcomings of Long-Short Term Memory (LSTM). Then this paper proposes to classify infant crying sentiment based on CNN-Transformer model. The model extracts the feature image of the language spectrum by using CNN, compressing the extracted feature image into vectors, then inputs the

中国知网 https://www.cnki.net

vector into the encoder part of transformer model to model the continuous crying of infants. Finally, CNN-Transformer model is improved by adopting modified position coding, multi-head sensing, residual linking and normalization, and fully connected feedforward network.

（4）In order to accurately evaluate the proposed model, this paper trains the proposed CNN-Transformer infant crying emotion analysis model on the established database. In order to prove the fairness of the experiment, the public ESC-50 data set and Freesound data are used. The experimental results show that the model is improved obviously in the classification accuracy rate, single classification accuracy rate, and training time consumption.

To sum up, this paper fully analyzes and studies the characteristics of baby cry, designs a baby cry database containing five emotions, and proposes a cry emotion analysis model based on CNN-Transformer, which is verified and analyzed by experiments. The work done in this paper provides a new research idea and method for other fields of speech sentiment analysis.

Key words: Speech recognition**;** Sentiment analysis; Infant cry; Deep learning; CNN - Transformer model

中国知网 https://www.cnki.net

目录

摘要.....I
Abstract.....II
目录.....IV
第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.1.1 研究背景.....1
1.1.2 研究意义.....1
1.2 国内外语音情感分析研究现状.....2
1.2.1 国外研究现状.....2
1.2.2 国内研究现状.....4
1.3 本文研究内容.....6
1.4 论文组织结构.....7
1.5 本章小结.....7
第 2 章 基于深度学习的语音情感分析相关技术.....8
2.1 CNN 卷积神经网络.....8
2.2 LSTM 神经网络.....10
2.3 Transformer 模型.....11
2.3.1 位置编码.....13
2.3.2 缩放点积感知.....13
2.3.3 多头感知.....14

中国知网 https://www.cnki.net

2.3.4 残差链接与归一化..... 15
2.3.5 位置全连接前馈网络..... 16
2.4 本章小结.....16
第 3 章 婴儿哭声数据库设计及数据预处理.....17
3.1 数据获取及数据库建立..... 17
3.2 数据预处理.....21
3.2.1 婴儿哭声数据预处理流程.....21
3.2.2 预加重.....21
3.2.3 分帧.....22
3.2.4 加窗.....23
3.2.5 端点检测..... 24
3.3 语谱图.....25
3.3.1 语谱图的特征..... 25
3.3.2 语谱图的生成..... 25
3.4 本章小结.....28
第 4 章 基于 CNN-Transformer 模型的婴儿啼哭情感分析方法.....29
4.1 CNN-Transformer 模型.....29
4.1.1 CNN-Transformer 模型架构..... 29
4.1.2 CNN-Transformer 模型细节..... 30
4.2 CNN-Transformer 模型的改进..... 31
4.2.1 修改位置编码..... 32
4.2.2 修改多头感知..... 32

中国知网 https://www.cnki.net

4.2.3 修改残差链接与归一化.....35
4.2.4 修改位置全连接前馈网络.....35
4.3 实验验证.....35
4.3.1 实验环境.....35
4.3.2 实验数据集.....36
4.3.3 实验对比模型.....37
4.3.4 评价标准.....37
4.3.5 实验参数设置.....38
4.4 实验结果与分析.....38
4.4.1 ESC-50 数据集实验结果.....39
4.4.2 Freesound 数据集实验结果.....43
4.5 Encoder 堆叠模型.....47
4.6 本章小结.....49
第 5 章 总结与展望.....50
5.1 总结.....50
5.2 展望.....50
致谢.....52
攻读学位期间发表的期刊文章.....53
参考文献.....54

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 研究背景及意义

1.1.1 研究背景

如今科学技术持续进步，社会高速发展，更多的人开始追求智能化品质生活。智能化的生活方式不仅意味着便捷与舒适，更能在实际生活中为人们减轻压力，因此人工智能越来越受到人们的关注，智能化情感分析也成为了研究人员关注的热点话题。而语音的情感识别便是其中重要的一个部分，并且在很多领域有所发展，如心理健康检测、情感翻译、互动电影等。当今国内外许多研究人员在语音情感分析领域开展了大量研究工作，本文所研究的婴儿哭声情感分析便是其中的一类。在城市化发展不断加快的时代，人们的生活习惯和生活节奏受到了很大的影响，在这种忙碌的生活方式中，由于年轻父母对新生儿的照顾经验不足和工作压力所导致的残留时间和精力的匮乏，照顾新生儿的工作成为这一部分人口的重大难题。这种情况下，这些问题不仅影响了和孩子相处的愉悦感，还对工作效率造成了影响。因为刚出生的婴儿并不知道如何表达自己，所以他们与父母沟通的唯一方法就是哭，所以照顾新生儿最直接、最有效的方法就是了解哭声所包含的意义。

丹斯婴儿语言理论[1]提出，可以根据婴儿哭声对其进行情感分类，当他们有不同种类的需求时，婴儿会发出不同种类相对应的音调，并且即使是来自不同的国家但其同种原因的哭声都非常相似。新生儿哭喊的声音还可以看作是生物学警报系统，在新生儿哭泣的时候，往往包含着有饥饿、不快、困倦、疼痛等感受[2-4]。基于此种现象，有些组织在 CD-ROM 平台上播放这些音频资料，并出售给有需要的父母，但是这个方式有很多不便[5]，首先大多数父母在面对刚出生的婴儿时，生活会变得更加忙碌，让他们为了学习这个知识而花费大量时间是不现实的。其次，识别新生儿哭声的原因，并不是一个短期内可以完成的工作，并且有关研究结果表明，听婴儿的哭声并不是一个快乐的经历[6]。基于以上原因，本文提出了对婴儿哭声进行情感识别的模型来快速且智能的对婴儿哭声做出准确的分辨。

1.1.2 研究意义

对婴儿哭声进行情感识别分类可以检测到婴儿的健康状态，了解哭声的原因并及时做出反应。此项研究大大缓解了家庭焦虑，高识别率的婴儿哭声情感分析不仅可以应用到医疗领域来检测婴儿的健康，还可以应用到商业领域。

中国知网 https://www.cnki.net

根据哭声的波浪所传递的信息，可以判断婴儿的身体状况，也可以检测出疾病。因此，可以使用基于声音信号处理技术的分析方法，进一步研究婴儿的哭声，将其作为可靠的科学辅助手段来识别儿童疾病。这对婴儿疾病的早期诊断、治疗效果评估、疾病愈后预测等方面提供了一个科学的判断依据。在如今科技快速发展的时代，许多国内外的高端养老中心和月子会所也都引入了声音监测系统，此方法大大降低了人力成本。所以此课题的研究有着非常重要的理论意义与实际应用意义。

1.2 国内外语音情感分析研究现状

1.2.1 国外研究现状

（1）基于神经网络的婴儿啼哭情感分析

国外在很早时期便对语音情感分析有了探讨与研究，自动识别幼儿哭声属于自动语音识别的范畴。随着深度学习技术的持续发展，许多学者开始对语音情感识别进行更深入的学习与研究。目前国外主流学者的主要研究焦点是将幼儿哭声应用于临床诊断[7]。

1960 年代斯坦迪纳维亚的 Wasz Hockert 小组[8]最先提出幼儿哭声研究，到 1980 年代中期，人工神经网络（Artificial Neural Network，ANN）成为研究人员热点研究对象，各种神经网络模型成为了婴儿哭声情感识别的主要方法。Zabidi A[9]等利用深度学习卷积网络从哭声中提取频率倒谱系数（Mel Frequency Cepstral Coefficients，MFCC）对幼儿正常哭泣声音与窒息哭声进行识别判断。同样 Basodi S[10]等人也采用深度学习算法对窒息婴儿的哭声进行了研究，但是不同的是，在实验中 Basodi S 等人加入了声学特征与加权韵律特征。

Zabidi A [11]指出窒息婴儿啼哭信号具有独特的模式，可用人工神经网络等模式分类器进行识别，并且研究探讨了二进制粒子群的优化对婴儿啼哭特征的影响与多层感知分类器来区分健康哭声和窒息婴儿啼哭信号，采用 MFCC 分析方法进行特征提取，用不同的系数组合检验了多层神经网络（Multi-Layer Perception ,MLP）的性能，实验结果表明，粒子群优化算法在减少计算量的同时，有助于提高 MLP 分类器的分类精度，分类准确率最高的为 95.07%。Garcia J O[12]等人用神经网络对正常的婴儿哭声与低音婴儿哭声进行分类。随后 Yaacob S[13]等人运用时频信息和广义神经网络对正常婴儿哭声与低音哭声进行了分类，此项对窒息婴儿哭声的研究，大大减少了婴儿的死亡率，为后续的医学疾病研究提供了新思路。

M. Malowany[14]使用了三种不同的监测神经网络技术，简单的前馈神经网络、循环神经网络、时间延迟神经网络为哭声设计了分类系统。在文章中将哭声情感分为“痛”、“恐怖”和“饥饿”三类。实验结果表明，循环神经网络实现了最高的分类准确率，并且实验中提出婴儿的哭声可以看作是疼痛的标志。在随后的时间里

中国知网 https://www.cnki.net

Mohammed Y A[15]又采用新的方式对三种哭声进行识别，实验中提出两种不同的自动分类技术，该方法分为人工神经网络（ANN）和连续隐马尔可夫模型（Continuous Hidden Markov Model，CHMM）。从哭声样本中提取了两组不同的声学特征，分别为 MFCC 和 LPCC（线性预测倒谱系数），每组产生的特征向量最终输入到分类模块中进行训练和测试，实验结果表明，基于 CHMM 的系统性能优于基于 ANN 的系统，CHMM 的最佳识别率为 96.1% ，远高于人工神经网络的 79% 。大量研究者[16-17]在神经网络的基础上开始采用模糊神经网络对婴儿的哭声进行分析研究，其结果都有着不错的表现。

随着应用驱动性能的提升，Y. Lavner[18-19]等人将语音识别技术应用到家庭环境的监测中，同时国外各大呼叫中心也开始采用语音识别技术进行智能化的服务。Guyer C[20]提出采用 24 小时的语音监测技术依据婴儿的哭声对早产婴儿进行智能化看护，以防止发生护士或者家长注意不到的紧急情况。

Zabidi A , Yassin I M 等人 [21]指出深度学习神经网络（Deep Learning Neural Network，DLNN）具有复杂特征的表示能力，虽然它主要适用于图像特征，但是假如任何一种特征都可以转化为图像，那么其他类型的数据也可以适用于 DLNN，文章亦证明了将婴儿哭声音频信号产生的频率倒谱系数（MFCC）特征可以作为输入特征用于卷积神经网络。随后 Franti. E [22]等人运用 CNN 卷积网络对婴儿语言进行自动识别。本文受此种思想启发，深度学习对于图像特征有着强大的学习能力，那么就可以将语音识别问题转换成图像的识别问题，由此本文将哭声的语音信号变成图像－语谱图，再对婴儿进行五种哭声情感分类。

(2)基于统计机器学习及其他技术的婴儿哭声情感分析

计算机性能持续高速发展下，研究者发现可采用机器学习与模式识别等多种研究方法对婴儿哭声进行情感分析。矢量化（VQ）、隐马尔可夫模型（HMM）、动态时间跳跃（DTW）、与线性预测编码（LPC）等技术理论的日趋成熟，大量基于统计和机器学习的模型开始被应用到语音情感分析研究中。Mohamad Adnan 等人[23]使用隐藏的马尔可夫模型进行哭泣类型的分类，隐藏的 Markov 模型是基于双重随机过程的，该技术广泛用于医学信号处理和语音识别等声音信号分析领域。

随着时间的推移，许多人开始使用模糊支持向量机（Fuzzy Support Vector Machine ，FSVM）建立模型，首先提取梅尔频率分布系数特征，然后使用主成分分析（ Principal Component Analysis，PCA）方法对哭声进行疼痛与非疼痛的分类。Chen S T , Srinivasan K[24]等人鉴别出三种不同类型的新生儿啼哭：疼痛、嗜睡、饥饿。此方法首先从每帧图像中提取出 15 个特征，然后运用序列浮动前向选择算法（SFFS）选择最优的识别特征，最后采用有向无环图支持向量机算法对新生儿哭声进行分类，实验结果表明，该系统具有很好的分类效果，分类准确率为 92.17%。

中国知网 https://www.cnki.net

采用科学的技术手段可以减少婴儿因窒息而导致死亡的概率。在基于前人研究支持向量机的方法上，Sahak R [25]提出的主成分分析－支持向量机（PCA-SVM）算法对窒息婴儿哭声识别进行了优化。采用累积方差百分比、特征值统一准则和筛选试验三种主成分选择方法，对正常声音和窒息哭声中提取的梅尔频率倒谱系数进行特征分类，利用线性径向基函数神经网络和支持向量机对窒息婴儿的啼哭与正常啼哭进行了识别。比较了主成分分析－支持向量机与无主成分分析的支持向量机在窒息婴儿哭声识别中的性能，通过计算分类精度和支持向量数来检验这两种技术的性能。结果表明，PCA－SVM 分类器分类准确率最高，准确率为 95.323%，是当时识别窒息婴儿哭声的最佳方法。

Michelsson K [26]用声谱学方法分析了 110 例细菌性脑膜炎患儿由疼痛引起的哭声，这些婴儿年龄在 4 天到 6 个月之间并且确诊时间在 1 天至 14 天，并对 75 例足月健康婴儿哭声进行分析。与正常婴儿的哭声进行比较，结果显示脑膜炎患儿的哭声与正常对照组有显著性差异，患病儿童发声持续时间较短，基频音高较高，发出的信号中无声部分较多，双音化、滑动和双谐波断裂发生率较高。其他研究人员提出了一种改进的 K－最近邻近算法对幼儿哭声进行分类，实验结果验证了该方法的有效性，最大精度为 80.39%。大量研究者[27-28]对其心脏类疾病导致的哭声进行了专门的研究，其中有人利用小波变换以及自组织映射的方法对心脏疾病类的心音进行了研究。也有人基于哭声的基本频率以及共振峰频率对心室中隔缺损（VSD）、心房中隔缺损（ASD）、动脉管通畅（PDA）以及其他疾病的四种病症婴儿哭声进行了分类。随着时代的进步，对婴儿哭声的研究方法多种多样，其采用的技术也越来越丰富。Yoo S K 等[29]使用基于熵能量检测的方法进行婴儿哭声的分类。S. P. Dewi[30]等人使用 MFCC 及 LFCC 进行不同哭声的分类研究。随着技术的进步，研究人员对婴儿哭声的情感分析所采用的技术也多种多样，本文查阅分析了大量文献，发现基于深度学习模型的分类准确率略高于基于机器学习的分类准确率，所以本文将婴儿哭泣的音频信号转化成图像的形式，采用基于深度学习模型对婴儿哭声进行情感分析。

1.2.2 国内研究现状

国内对于语音情感的识别技术起始于 20 世纪 80 年代，而对于婴儿啼哭情感分析的研究相较于国外来起步较晚，许多国内学者将智能化监测哭声作为重点研究内容。

王群[31]指出婴儿哭泣不仅是为了向外界传递信息，哭泣是人类早期语言的胚胎形态。新生儿大部分时间都是处在睡觉的过程中。在幼儿睡眠中实施哭喊状态监测，减轻了监护人的心理压力和负担，可以减少很多不必要的注意力高度集中时间。目

中国知网 https://www.cnki.net

前，一些监控系统将照相机和传感器相结合应用在家庭看护中，它可以在婴儿醒来时给予早期的警告。为了降低用户的阈值和成本，文章中提出基于移动设备的音频监控系统，在该系统中融入最新识别模式与学习方法，同时具有终端识别能力的动态更新和扩展能力。为了促进更多的家庭使用智能婴儿护理系统，文章主要的研究包括以下部分，为了建立婴儿哭声数据库，使用手机或其他设备在室内环境中收集来自个人用户的数据、用户定义的标签和分类信息，并对四个数据类别进行排序。为了解决由于不同的哭泣时间引起的特征向量对准的问题，GMM-Fisher 向量基本特征提取方法被投入使用，可以根据功能平均值对长度不等的音频进行切割，但是这种做法导致了信息的损失。GMM-Fisher 向量可从完整音频中提取相等长度的音频数据，此方法对功能细节进行了保留，从而提高模型的稳定性和可靠性。与常规语音识别模型（VQ、DTW、GMM、HMM、RFC、SVC）相比，基于深度学习的幼儿语音识别模型可以更好地学习音频数据的一些潜在特征，并且对于数据扩展和特征复杂性具有更强大的理解能力，这对建立手机终端婴儿哭声识别系统有极大的帮助。

崔战士[32]实现了婴儿哭声的自动检测，在文中提出基于 CNN 和改进的 K-means 两种幼儿哭检测模型，并进行了性能测试和分析。通过改进预处理声音信号的信噪比来达到改进声音检测的目地，有效地区分声音段和噪声段，减轻了数据处理的负担，并降低了噪声对背景噪声的耐受性。同时又设计了两种基于改进的 K-means 算法和卷积神经网络的检测算法，使用 MEL 频率分布系数作为信号的特征，将婴儿的哭声与其他声音进行分辨。由于健康哭声样本数据具有长度不确定的哭声检测模板问题，文章中提出使用动态时间工作算法来测试信号特征与模板之间的匹配度来进行 K-means 算法的改进。文章中还提出采用基于 CNN 模型的五层神经网络来进行识别，卷积层提取声音参数的特征，用池化层减少数据维度，全连接层将所学特征映射到标本标签空间，实现健康哭声样本分类。

魏丽娜[33] 幼儿专家的研究结果表明，婴幼儿的哭声不仅是与外界进行沟通，更是反映婴儿生理、心理需求、身心健康状态以及智力发育水平的重要信息源。吴鸿凯[34] 在不同的感情信息下建立幼儿哭泣的语料库。语料库是语音感情认识的研究基础，目前国内外还没有统一的婴幼儿情感需求信息。基于这种情况，构建了幼儿哭声感情信息的语料库。研究了幼儿哭泣时，不同感情需求信息在传统语音情感识别模型中声学特性的鲁棒性。文章将韵律特征和相关光谱特征结合形成原始特征，实验中提出三种研究方法，Softmax 回归算法，人工神经网络和支持向量机算法。实验结果表明，三个识别模型是都稳健的，但是识别的准确率不高。为了提高幼儿哭声中不同情感需求信息识别的鲁棒性，提出了改进的卷积神经网络模型。针对传统的卷积神经网络的不足，此文提出了一种基于多尺度卷积内核和多池化层方法的卷积神经网络，以提高幼儿哭时不同情感信息识别的鲁棒性。实验表明，改进的卷积神经网络提高了幼儿哭声中不同情感请求信息识别的鲁棒性。

中国知网 https://www.cnki.net

王诗佳[35]指出，语音情感分析是语音识别的代表性应用。近年来，深度学习将更深层次的神经网络用作其主要框架。各种类型的网络模型被卷积，产生了不同的模型结构，如神经网络、循环神经网络。这些网络具有各种功能，在各个领域都取得了较好的分辨率。为了提高声音事件识别系统精准识别程度，文章提出通过运用不同结构的神经网络来提取声音事件样本信息进行深度学习。首先，研究者对基于循环神经网络的声音事件识别方法进行研究，循环神经网络具有梯度消失和梯度爆炸的缺陷，由此提出了改进的循环神经网络来解决这些问题。基于声音事件识别特征，对帧内的声音事件音频样本进行处理，并将其中的 MFCC 提取出来当作特征，结合 GRU 作为分类模型，建立了基于循环神经网络的语音事件识别系统。实验结果表明，基于 GRU 的声学事件识别模型有效地利用了效果声音的自然时间属性，通过环路层网络解决了长时间依赖性问题，提高了识别精度。作者又提出了一种改进的多尺度卷积神经网络模型，并将其应用于健康事件识别。作者发现目前具有传统堆栈结构的卷积型神经网络存在缺乏低水平特征表示的问题，作者提出将网络中的所有卷积层的特征图连接一起，通过使用 CCCP 层来减小底部特征图的通道尺寸，并且用卷积网络提取来自各层的特征图，此时特征信息可以最大限度地保持，由此构建了多尺度卷积神经网络。此外，用多通道 MEL 频谱系数和沿时间轴和频率轴的一阶和二阶频谱导数，结合 MEL 频谱系数的多通道多尺度卷积神经网络可以有效地提取和融合所有级别的特征，在 ESC 和 TUT 数据集的实验结果表明该方法有效地提高了准确度。最后，文章提出了一种基于深度卷积产生对策网络的声音事件数据强化方法，从数据集中提取所有的尺度不变（Scale Invariant Feature Transform,，SIFT）的特征，建立 DCGAN 网络学习这些 SIFT 特征，并批量生成类似的伪样本，使用面对面训练的想法，增加质量差的伪样本的模糊性，实验结果表明该方法增强了模型的稳定性和鲁棒性。

1.3 本文研究内容

针对现有基于深度学习的婴儿啼哭情感分类识别率有待提高的问题，本文从以下三方面内容进行研究：

1. 分析婴儿哭声的原因及特点，建立数据库。根据丹斯婴儿语言提出的理论对婴儿哭声进行分类，将婴儿的哭声分为 5 个类别：因饥饿而哭泣、因困倦而哭泣、因不舒服而哭泣、因疼痛而哭泣以及因打嗝而哭泣。由于无任何一个公共数据库集具有这五种不同的幼儿哭泣类型，所以本文从 YouTube 网站上收集了有着丰富育儿经验的父母所上传的婴儿哭声数据，并对数据进行预处理，将处理后的哭声放到对应的标签文件夹下，建立婴儿哭声数据库。

2. 对 CNN、LSTM、Transformer 深度学习模型进行研究，分析了各模型的优势以及不足，提出采用基于 CNN-Transformer 模型进行婴儿哭声情感分类研究，并详

中国知网 https://www.cnki.net

细地给出了模型框架及具体过程。该模型使用 CNN 提取特征图，然后将特征图压缩为向量，最后将向量输入到 Transformer 的 encoder 部分进行哭声情感分类，并对所提出的婴儿哭声情感分析模型进行改进。

3. 对提出的 CNN-Transformer 婴儿哭声情感分析模型在三个主要的性能指标上进行评测。用本文所建立的婴儿哭声数据库进行训练，为了更加客观的对模型进行评测，本文用公开数据集 ESC-50 和 Freesound 数据集进行验证，并与 CNN-LSTM 模型和 Inception-v3 算法进行对比分析。

1.4 论文组织结构

第一章 在本章节，主要介绍了本课题选题的原因，研究背景及意义，对国内外的研究现状与进展进行总结，最后对本文的主要研究内容以及文章组织结构进行介绍。

第二章 对语音情感分析相关模型进行研究。总结了目前使用最广泛的 LSTM 模型特点及不足，给出了本文会用到的 CNN 模型及 Transformer 技术的相关理论知识。

第三章 首先分析了婴儿哭声的独有特点，设计建立了五种哭声类型的数据库。其次根据哭声特点采用合理的数据预处理方法对数据进行处理。最后根据语谱图具有的优势特点对哭声进行语谱图处理。

第四章 提出了一种基于 CNN-Transformer 的婴儿哭声分类模型，详细地描述了模型结构及内部算法流程，并对该模型进行了优化改进。最后设置了对比实验，将本文提出的 CNN-Transformer 婴儿哭声情感分析模型与 CNN-LSTM 模型和 Inception-v3 算法进行对比分析。

第五章 对本文所做工作内容进行总结，对接下来的工作方向进行展望。

1.5 本章小结

本章首先阐述了婴儿哭声情感分析的研究背景与意义，然后总结了目前国内外关于婴儿哭声情感分析的研究现状，最后对本文的主要工作及文章组织结构进行了详细描述。

中国知网 https://www.cnki.net

第 2 章 基于深度学习的语音情感分析相关技术

近年来，随着对深度学习技术的不断深入研究及应用领域的不断扩展，深度学习成为语音情感分析的主流模型。其中卷积神经网络、长短期人工神经网络在各类的情感分析中有着优秀的表现，近两年提出的 Transformer 模型也逐渐受到研究人员的关注。本章对基于深度学习的语音情感分析相关技术进行深入研究，为能够高效率的识别婴儿哭声情感分析模型提供了理论基础。

2.1 CNN 卷积神经网络

卷积神经网络最初是为计算机视觉而设计，后在自然语言处理中也发挥了巨大作用[36]。卷积神经网络在空间与时间上有平移不变形的卷积优势，将其用在语音信号上可以解决语音信号本身的多样性[37]问题。本文借鉴前人的工作，将语音信号转换成语谱图，把语音信息当做图像进行处理，发挥了卷积神经网络（Convolutional Neural Networks，CNN）对图像强大的特征提取功能。CNN 由五层结构组成：输入层、卷积层、池化层、全连接层及输出层，其标准结构如图 2.1 所示：

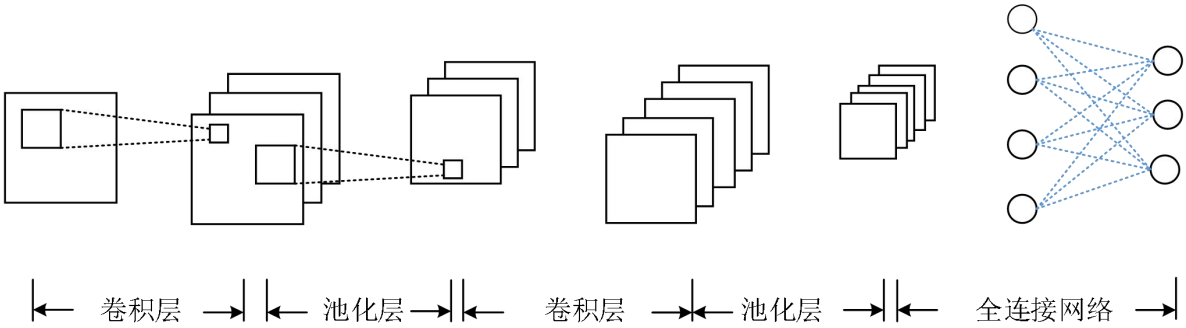


图 2.1 卷积神经网络标准结构

Fig.2.1 Convolutional neural network standard structure

由于卷积神经网络学习了特征提取层的参数特征，这样就可以合理解决提取数据时存在的误差问题，对比原始神经网络，卷积神经网络的特征提取优势更加显著。在卷积神经网络模型中，池化层与卷积层是其核心部分，每层输出对最后的训练输出都能产生巨大影响，应用时可利用一个或者多个卷积核提升其处理效率，图 2.2 为卷积核运算示意图。图中，绿色部分为卷积层，蓝色部分为卷积核进行卷积的范围，然后将卷积结果映射到绿色矩阵中，这样就将信息量压缩，也称为特征提取[38]。卷积神经网络是对真实生活中的神经结构进行模拟，上部与底部神经网络间的完整连接会导致其处理参数过大，而卷积神经网络采用了局部连接特征，将上部与底部的神经网络链接全部去除，大大减少了参数个数，将扩展性显著提升。

中国知网 https://www.cnki.net

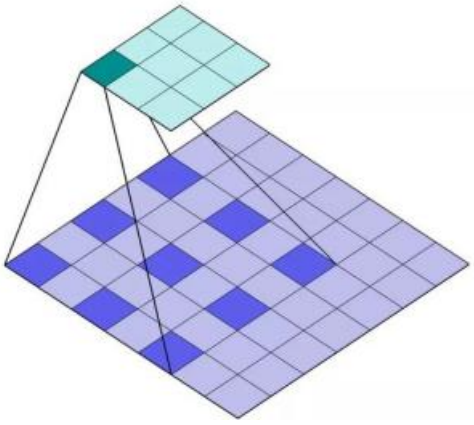


图 2.2 卷积核运算示意图

Fig.2.2 Schematic diagram of convolution kernel operation

卷积型神经网络的本地权重共享机制再次减少网络层的数量，通过大幅减少各层的样本数，将参数的个数用下采样处理来进一步减少，有效地改善了模型鲁棒性问题，其处理方式在后续处理中显示出良好的特性。卷积神经网络的具体模型结构如下图 2.3 所示;

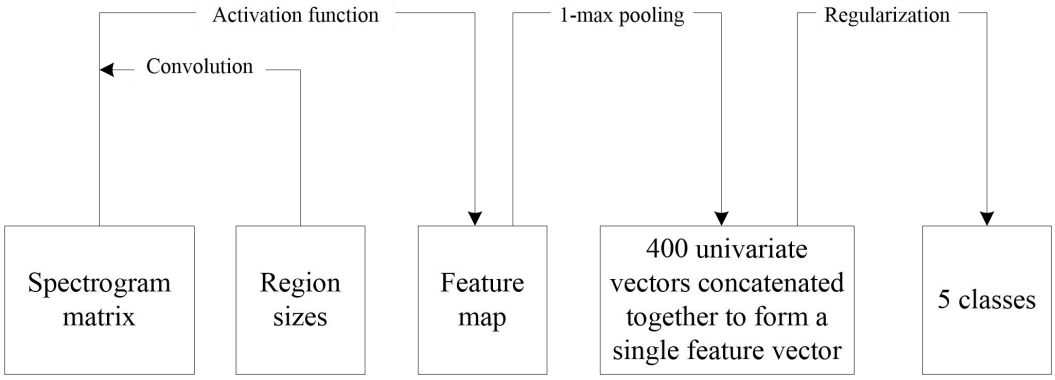


图 2.3 卷积神经网络模型结构

Fig.2.3 Convolutional neural network model structure

卷积前的参数直接影响 Feature map 尺寸，卷积操作前后参数之间的关系如公式（2-1）和公式（2-2）所示：

$$W_2 = \frac{(W_1 - F_w + 2P)}{S} + 1 \tag{2-1}$$

$$H_2 = \frac{(H_1 - F_h + 2P)}{S} + 1 \tag{2-2}$$

中国知网 https://www.cnki.net

上式，W_2 表示卷积操作后 Feature map 的宽度值，H_2 为高度；W_1 表示未进行卷积操作前的矩阵列，H_1 为行，F_W 表示 filter 的宽，F_h 表示其高，P 表示 Padding 具体数量，S 为卷积期间的步幅。

池化层也可简称为池层[39]，它的主要功能是通过降低采样和删除功能图的重要部分来减少参数的数量。这也是一种方便有效的减少数据维度的方法，对计算过程的复杂性进行了简化。MAX 环中选取最大值当作样本值，再将样本平均值当作最后样本值。本模型上的池化层用最大化一维最大带环进行处理，也就是特征图仅选择一个最大值，将它认为是在该滤波器的卷积后提取到的最关键的特征，然后经过下拉操作利用 Softmax 分类器完成分类操作。Softmax 回归是根据逻辑回归演变而形成，目的是处理更多的分类问题。本文将 Softmax 与深度学习方法进行结合以达到对婴儿哭声进行情感分析的目的。

2.2 LSTM 神经网络

LSTM（Long-Short Term Memory，LSTM）模型是语音情感分析中常用的模型，LSTM 神经网络模型是对串行数据建模的重要方法，是一种具有时间连接功能的前馈型神经网络，以时间来连接不同通道[40]，因此它被广泛用于处理串行化输入，它是一个在深度学习框架中非常受欢迎的模型，它的计算能力是非常强大的。大量论文中使用 LSTM 模型进行训练，其模型训练流程如图 2.4 所示：

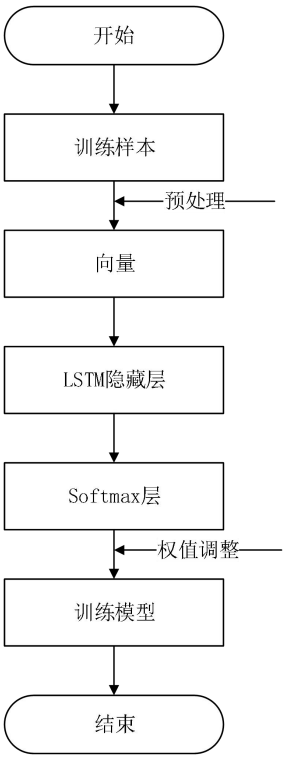


图 2.4 LSTM 模型的训练流程

Fig.2.4 Training process of LSTM model

中国知网 https://www.cnki.net

LSTM 模型[41]解决了由于不同的激活函数而具有严重的梯度消失或梯度爆炸问题，LSTM 模型的诞生避免了信息随时间快速消失的问题，对原始的神经网络的远程依赖性的问题做出了良好的解决。同时 LSTM 不仅被广泛用于图像处理等多个领域，在自然语言处理的领域中也有着广泛的应用。LSTM 模型对序列注释、语言模型、含义表示、系统解析、机器翻译等也都有所贡献[42-43]。LSTM 模型能够有效处理循环神经网络导致的梯度爆炸、梯度消失等问题，利用隐藏层增加单元状态 c 来代替原始循环神经网络的隐藏层只有一个状态 h 的情况，LSTM 模型隐藏层[44]如图 2.5 所示：

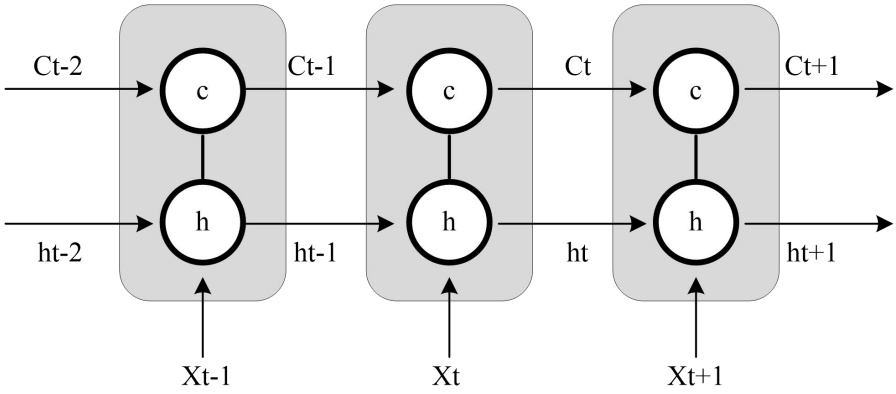


图 2.5 按照时间维度展开的长短期记忆网络隐藏层

Fig.2.5 The hidden layer of the long and short-term memory network expanded according to the time dimension

在 t 时刻，存在三个长短期记忆网络输入内容：本时刻输入 X_t、上个时刻输出值 h_{t-1}、上个时刻单元状态 C_{t-1}。LSTM 上有两个输出，即 C_t 单元状态与 h_t 输出时刻。长期时间状态 c 的控制是 LSTM 的核心，基本理念并非使用生物学机制实现，而是根据设计的电路图得到的启发，本模型采用“门”结构进行处理，由公式（2-3）来表示“门”：

$$g(x)=\sigma(Wx+b) \tag{2-3}$$

上式 W 表示“门”权重向量，x 表示输入向量，b 表示偏置项，g（x）=0 则为关闭“门”，使信息难以从其中经过；g（x）=1 是开启“门”，其含义是可通过信息。

2.3 Transformer 模型

在针对 LSTM 模型面临长距离信息损失问题、运行速度慢与效率低问题时，Google 机器翻译团队提出了变压器模型也就是 Transformer 模型。其主要是实现一种

中国知网 https://www.cnki.net

新的自我注意力机制，以建立一个优于 LSTM 的传统编码器解码器结构，Transformer 模型相对 LSTM 模型来说减少了计算量，提高了并行效率。Transformer 模型的具体结构如图 2.6 所示：

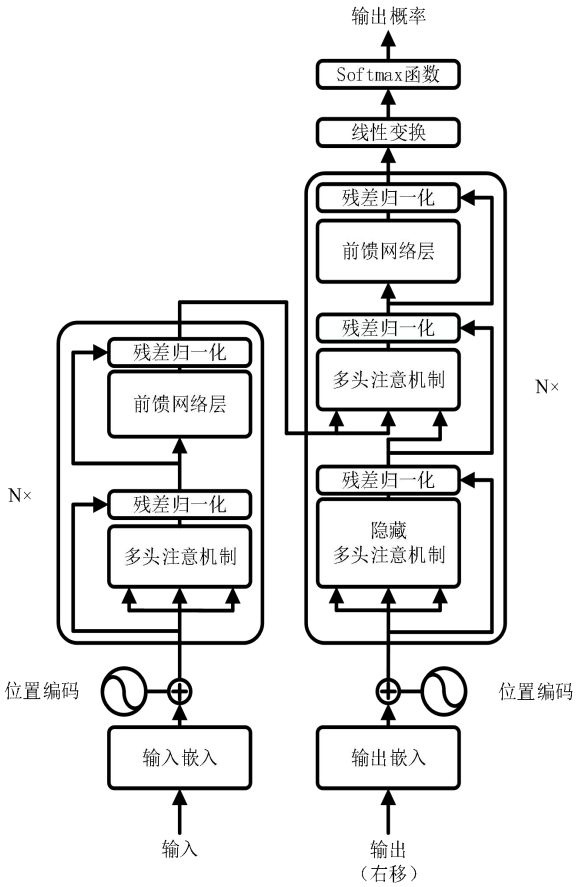


图 2.6 Transformer 模型的具体结构

Fig.2.6 The specific structure of the Transformer model

Transformer 模型包括两个部分：编码器和解码器，左侧部分为编码器 Encoder 模块，右侧部分为解码器 Decoder 模块。编码器的功能是序列功能检测器，用于检测提取序列特征上不同输入序列元素间的数据关系。解码器模块其主要功能是进行特征提取，此外还能构建基于自我注意力机制的语言模型与序列生成模型。编码器和解码器通常由若干子块构成，可以对子块的数量进行叠加，子块的数量越多[45]，网络模型的参数越大，学习能力越强，但是训练起来就越难。

Transformer 模型的训练过程为：首先，对输入向量进行一次位置编码，编码后的输入向量通过多头感知层随后进行残差链接与归一化，接下来将向量输入到位置全连接层，再执行一次残差链接和归一化，最后结果被输入到解码器中。解码器为了方便地处理输入，并且不参考将来的信息，添加了掩码操作。在多次多头感知、

中国知网 https://www.cnki.net

残差链接和归一化之后，将其输入到全连接前馈网络中，最终通过线性层获得输出进行 Softmax 函数激活后得到分类结果。

Transformer 模型本质是一种神经网络模型，不同网络层构成了模型的基本单位，模型的主要技术是位置编码、缩放点积感知、多头感知、残差链接及归一化、位置全连接网络。

2.3.1 位置编码

Transformer 模型弃用了 LSTM 模型的序列结构，然而序列结构可以更容易的获取信息的位置，所以 Transformer 模型与 LSTM 模型相比其位置信息获取要更难一些，不能直接获得输入序列的位置关系。为了补充不足的位置信息，需要在输入数据之前对数据进行预处理，以增加数据的位置信息。Transformer 模型在位置信息中对两种位置信息进行位置编码，一个是各要素的绝对位置信息，另一个是要素间的相对位置信息。

Transformer 将一个序列的向量拼接为一个（m, N）的矩阵作为输入，表示有 m 个向量，每个向量有 N 维。对于矩阵中的每一个元素，若其位于第 pos 行第 i 列，则将 pos 与 i 代入式（2-4）中：

$$f\left(pos,i\right)=pos/10000^{\frac{i}{N}} \tag{2-4}$$

将得到的计算结果设置为 (m, N) 维度的矩阵，用来表示输入矩阵上所有的元素位置信息，再使用 sin 函数激活矩阵偶数列和第 0 列，对矩阵的奇数列用 cos 函数激活，如式（2-5）所示：

$$\begin{cases} PE_{2i}\left(pos\right)=\sin\left(pos/10000^{\frac{2i}{N}}\right) \\ PE_{2i+1}\left(pos\right)=\cos\left(pos/10000^{\frac{2i+1}{N}}\right) \end{cases} \tag{2-5}$$

矩阵被 cos 与 sin 两个函数激活处理后即可得到编码完成后的最终形式，矩阵自身为一个绝对位置信息，然而依据公式（2-6）得出，位于位置 $p+k$ 的向量可以表示为位于位置 p 与 k 的向量的线性变换，这就提供了某种相对位置信息。

$$\begin{aligned} \sin\left(\alpha+\beta\right)&=\sin\alpha\cos\beta+\cos\alpha\sin\beta \\ \cos\left(\alpha+\beta\right)&=\cos\alpha\cos\beta-\sin\alpha\sin\beta \end{aligned} \tag{2-6}$$

2.3.2 缩放点积感知

中国知网 https://www.cnki.net

基于前向神经网络的 AA（Additive Attention）与基于点乘的 DA（Dot-product Attention）是两种应用较多的注意力计算方法。理论上该方法的复杂程度基本相同，但实际应用时运行速度较快的方法为 DA，此方法可节约大量内存。在向量维度很小的状态下时使用这两种方式基本相同，向量维度非常大的情况下，AA 方法得到的效果与 DA 相比更理想，这是因为向量维度高时 K 与 Q 点乘结果间的差别较大，由 Softmax 处理后得到的权值不是 0 就是 1，造成权值出现严重的偏斜问题。缩放点积感知流程如图 2.7 所示：

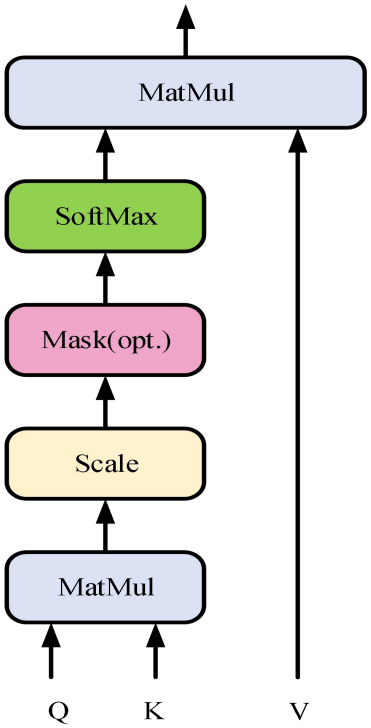


图 2.7 缩放点积感知流程

Fig.2.7 Scaling dot product perception process

缩放点积感知理念相对简单，点积结果与一个 K 维度的 D_k 的平方根相除后即可进行调整，这样来控制点积，使其结果不会过大。

缩放点积感知的计算公式如（2-7）所示：

$$Attention\left(Q,K,V\right)=soft\max\left(\frac{QK^{T}}{\sqrt{d_{K}}}\right)V \tag{2-7}$$

2.3.3 多头感知

中国知网 https://www.cnki.net

多头感知与注意力机制有一定差别，不是学习输入与输出序列间的关系，而是学习输入序列上不同元素间的关系，因而被称作自注意力机制。多头感知令 Query=Key=Value，并非 Key=Value，在 K 于 Q 两个关系矩阵计算过程中，其本质是将序列的两个元素之间的关系输入，然后再对输入序列内部各元素间建立的序列关系进行挖掘。在自注意力机制上，序列上两个元素间具有相等的距离，并且元素位置不会对计算各元素间的关系系数进行干扰，此过程就能比基于 LSTM 的传统注意机制获得更长距离依赖性，图 2.8[46]为多头感知流程：

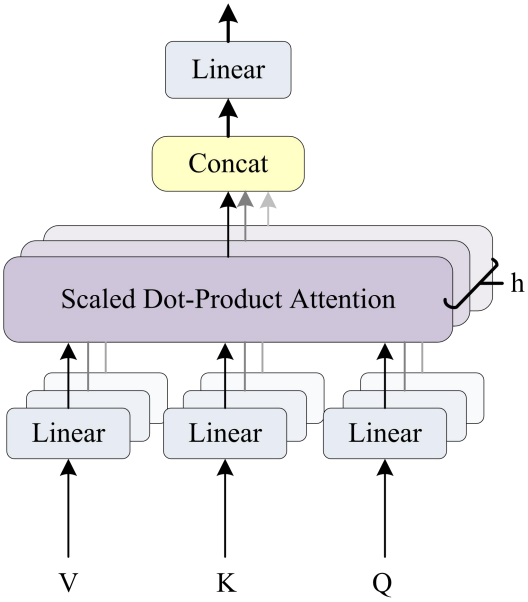


图 2.8 多头感知流程

Fig.2.8 Multi-head perception process

2.3.4 残差链接与归一化

残差链接机制来源于 ResNet[47]，该机制的最终输出是通过线性叠加输入矩阵与输出矩阵而形成的，也就是将未线性变换的 Q 矩阵与 A 矩阵进行叠加，以此来限制网络加深而造成的网络训练难度问题。

归一化的方式有很多，批归一化和层归一化。批归一化是计算一批数据上的平均值和方差，再用减去平均值后的数据除以方差，这样做的目的是使数据与平方差为 1、均值为 0 的正态分布相同。由于数据通过网络层后会有特定的偏差，所以此时需要归一化，如果不进行归一化，则数据的偏差随着层深度的增加而增大，此时数值的偏差会影响反向传播的效率，降低学习能力，从而导致梯度消失和梯度爆炸的问题，最终以极慢的训练速度结束。采取层归一化的原因在于无法在循环网络结构

中国知网 https://www.cnki.net

上应用批量归一化方式，Transformer 的解码器部分就是循环的网络结构，所以要采取层归一化进行处理。

2.3.5 位置全连接前馈网络

位置全连接前馈网络是将多头感知的结果进行空间变换，位置全连接主要包含包括一个 Relu 激活函数和两个线性变换。具体过程为：对第一个全连接层的输出进行 Relu 激活，但不对第二个全连接层的输出进行激活，如式 （2-8）所示：

$$FFN = \max\left(O, xW_1 + b_1\right)W_2 + b_2 \tag{2-8}$$

本部分可将模型抽取特征能力加强，考虑到速率因素，所以只选择使用一个非线性变换与两个线性变换，现实中通常采用两层 1×1 卷积层将全连接层取代，经过该操作后可处理速度会加快。

2.4 本章小结

本章详细讨论了语音情感分析常用的几种基于深度学习的模型，CNN 卷积神经网络模型，LSTM 神经网络模型和 Transformer 模型。由于本文将语音数据转换成语谱图的形式进行情感分析，所以在此总结了卷积神经网络模型对于图像特征提取的相对优点及卷积和定量关系，功能和方法。接下来以示例的方式对对 LSTM 模型的工作原理进行描述，分析与传统神经网络模型相比，LSTM 模型的主要特征以及相对比于 Transformer 模型来不足的地方。最后给出了 Transformer 模型的各种网络层的具体操作流程，为本文所提出的模型奠定了理论基础。

中国知网 https://www.cnki.net

第 3 章 婴儿哭声数据库设计及数据预处理

在对婴儿的哭声进行情感分析的过程中，数据的获取与处理至关重要。本文查阅分析大量文献发现，国内外现在并没有统一的婴儿哭声数据库，本章首先对婴儿的哭声特点进行分析与研究，接下来设计并建立了包含 5 种声音的婴儿哭声数据库并对哭声数据进行预加重、分帧、加窗、端点检测等预处理。

3.1 数据获取及数据库建立

婴儿的哭声主要是通过喉腔中部的声带进行定期开关而发出的。根据现有数据的分析和前人研究的结论[48]进行研究，得出幼儿哭泣有以下特征：

（1）婴儿哭声不是连续的，前后段哭声相关性较低。

（2）婴儿哭声持续时间不定，有时候哭的时间长，有时候哭的时间短，且各个原因的哭声时长也不确定。

（3）基音频率高，倍音丰富。普通婴儿哭声的基音频率通常为 200Hz 到 600Hz，而短期疼痛可能达到 730Hz，严重疾病或休克的情况下也有可能达到 1kHz。成年人的俯仰频率分布在 60Hz≈450Hz，远低于幼儿。

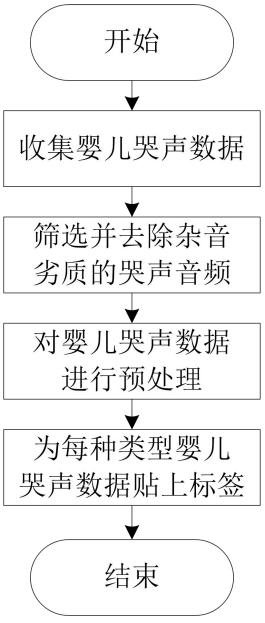


图 3.1 婴儿哭声数据库创建流程

Fig.3.1 Infant cry database creation process

中国知网 https://www.cnki.net

本文收集的婴儿哭声数据来源主要是基于国外视频网站 YouTube，该网页链接为 https://www.youtube.com/data/home/kaichen/crying。在该网站上有关于婴儿哭声 5 种声音分类的相关知识，根据用户上传的一些标签，作者收集整理了与标签所对应的 5 个类别的婴儿哭声。由于用户上传的哭声音频数据的录制地点主要集中在用户家里，导致有些音频中含有父母的声音以及嘈杂的背景音，所以必须手动过滤这些劣质婴儿哭声数据，然后将收集到的婴儿哭声的数据用预处理阶段的对应代码进行处理，最终将相应类别的婴儿哭声数据标出来。

数据库的建立对其哭声情感分析有着至关重要的影响，数据的质量决定着模型参数的质量，对其模型实验结果有着决定性的作用。由于国内外现在并没有一个统一的标准的哭声数据库，所以作者决定根据丹斯语言理论设计创建一个包含五种哭声的数据库，其五种哭声为：因打嗝而哭、因困倦而哭、因饥饿而哭、因疼痛而哭、因不舒服而哭。创建婴儿哭声数据库由以下几个步骤完成，首先要将收集到的婴儿啼哭的所有数据放在一个文件夹中，然后将杂音大、质量差的婴儿啼哭数据全部删除，接下来对已收集整理的婴儿哭声数据进行预处理，最后给不同类型的婴儿哭声贴上标签放入到数据库中，图 3.1 为具体创建过程。

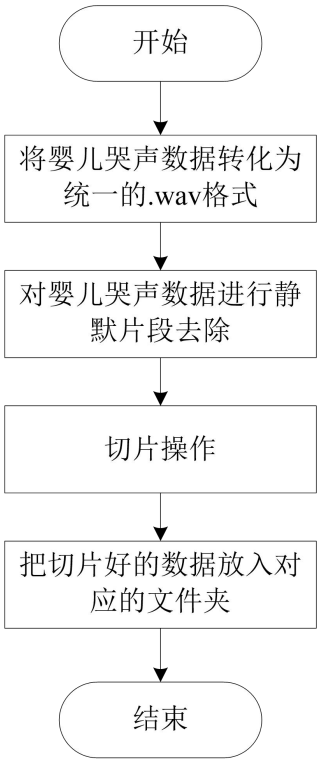


图 3.2 婴儿哭声数据处理流程图

Fig.3.2 Flow chart of infant cry data processing

中国知网 https://www.cnki.net

处理婴儿哭声由是以上四个过程完成，详细操作过程如图 3.2 所示。因为网站上的音频数据有 MP3 格式和 AAC 等各种格式，因为 WAV 格式具有很好的音质并且在较低采样的频率下也能产生较好的音质，所以首先要将收集的婴儿啼哭声数据转换为相同的 WAV 格式数据，然后去除婴儿哭声数据上的静默片段部分，再完成切片操作，最后一步是在相应的文件夹上保存已切片的数据信息。

在现实生活中，宝宝的叫声总是无法连续的，哭声数据中包含很多无声的片段，所以我们必须要做一个对安静片段的剪辑处理操作，将这些片段进行删除。这里采用的主要想法是计算音频帧的根平均平方值（RMS），因为它不需要 STFT 计算，所以从音频样本中计算 RMS 更快。同时由于可以窗口化帧，所以固定时间内的能量可以由语图谱更准确地体现。在获得各帧的根平均平方值后，再求出阈值，阈值是根平方值的 1/5。最后，将幼儿哭泣类型的对应文件夹放在幼儿对应的分类中。

通过以上过程，本文收集了 7500 个婴儿哭声的数据，其中有 1500 个打嗝型数据，1500 个困倦型数据，1500 个饥饿型数据，1500 个疼痛型数据，1500 个不愉快类型数据，本文将建立的哭声数据放在文件夹中，其中部分婴儿哭声文件截图如图 3.3 所示：



图 3.3 部分婴儿哭声文件

Fig.3.3 Part of baby crying files

数据库中包含着用户数据以和婴儿哭声语音数据。用户数据包含姓名，身份证号等个人信息；婴儿哭声数据库包含分类类型，婴儿年龄等信息；数据库的描述如表 3.1、3.2、3.3 所示：

中国知网 https://www.cnki.net

表 3.1 用户信息数据表

Table 3.1User information data sheet

字段名	字段类型	取值范围	含义	备注
UIDcard	CHAR	10	身份证号	主键
Uname	CHAR	15	姓名	
Password	ChAR	6	密码	
Phonenumber	INT	12	电话	

婴儿哭声数据库信息表如表 3.2 所示：

表 3.2 婴儿哭声数据表

Table 3.2 Infant crying data sheet

字段名	字段类型	取值范围	含义	备注
VoiceID	INT	7500	音频 ID	主键
VoiceFID	INT	5	音频类型 ID	外键
UIDcard	CHAR	10	身份证号	外键
Voicename	CHAR	15	音频文件名	
VoicePath	CHAR	300	音频路径	
VoiceTime	DATETIME	20（字节）	上传时间	
VoiceBabyAge	FLOAT	0-12(月)	婴儿年龄	

音频特征表如表 3.3 所示：

表 3.3 音频类型表

Table 3.3 Audio feature table

字段名	字段类型	取值范围	含义	备注
VoiceFID	INT	5	音频类型 ID	主键
VoiceType	CHAR	20	音频类型名称	

中国知网 https://www.cnki.net

3.2 数据预处理

3.2.1 婴儿哭声数据预处理流程

婴儿的哭声信号是一种时变信号，在对哭声进行情感分析之前要进行预加重、分帧、加窗等预处理操作。这些操作会消除婴儿哭泣时或者语音收集时带来的声音混叠，或者失真等问题，尽可能的为后续的研究提供更高质量的声音信号。婴儿哭声数据的预处理过程如图 3.5 所示：

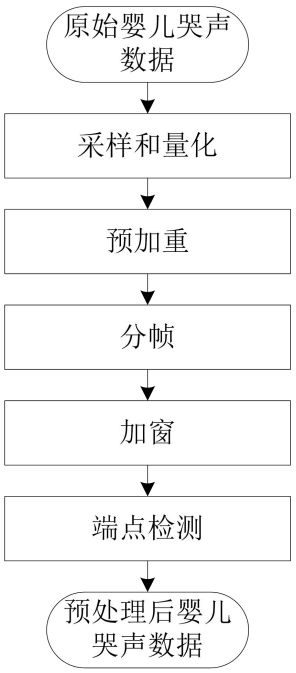


图 3.4 婴儿哭声数据的预处理流程

Fig.3.4 The preprocessing process of baby crying data

3.2.2 预加重

根据成人声音系统特征，成人的发声容易受到人体口鼻辐射干扰，语音信号在低频段具有较大的能量，但是高频声音信号的能量非常容易衰减，在此过程中声音信号的高频部分的弱化会使信号的低频部分成为声音信号的主要成分，因此需要使用预加重技术，此方法不仅可以改进高频部分的频谱，还可以平滑整个频带，有助于分析声音参数。利用 FIR 数字滤波器处理婴儿啼哭声信号，该滤波器也被称预加重滤波器，由公式（3-1）所示：

$$H(z)=1-az^{-1} \tag{3-1}$$

中国知网 https://www.cnki.net

上式 a 是预加重系数，取值在 0.9 至 1 区间内，假如 $X(n)$为婴儿哭声未预加重之前的信号，$Y(n)$是经过预加重滤波器后得到的婴儿哭声信号，则可以由公式（3-2）表示：

$$Y(n)=X(n)-aX(n-1) \tag{3-2}$$

3.2.3 分帧

在预加重技术之后，下一步是进行分帧操作[49]。与语音信号分析的过程一样，“短期分析技术”是对婴儿哭声的整个过程进行分析的最合适的方式。从整体数据特征来看，宝宝发出的信号分为无声有声两种，不论何种情况其保持时间非常短，并且是交替进行的，所以哭声是具有时变特性的。但是另一方面来看，哭声信号是随口腔肌肉变化的，婴儿口腔内的肌肉发育比较缓慢，这种肌肉运动的频率对于婴儿哭声的频率比较慢，所以这个特性基本上没有变化，也就是说此特征比较稳定。基于这个考虑，婴儿哭信号的分析和处理必须基于“短期分析”。将哭喊的信号分割成称为“帧”的段，由于婴儿哭声信号在前 10ms～30ms 时间内处于稳定状态，因此通常帧长度一般为 10ms～30ms。

常用的方法有两种，分别是连续分割与重复分割[50]，应该根据不同的情况采用不同的方法。经过分析作者认为第二种方法是更好的，因为重叠的分割方法可以更好地保持信息的连续性。前一帧和下一帧的重叠部分被称为帧移位，帧移位的比例通常是帧长度的 1/2。显示帧之间的分段重叠方法。如图 3.5 所示。

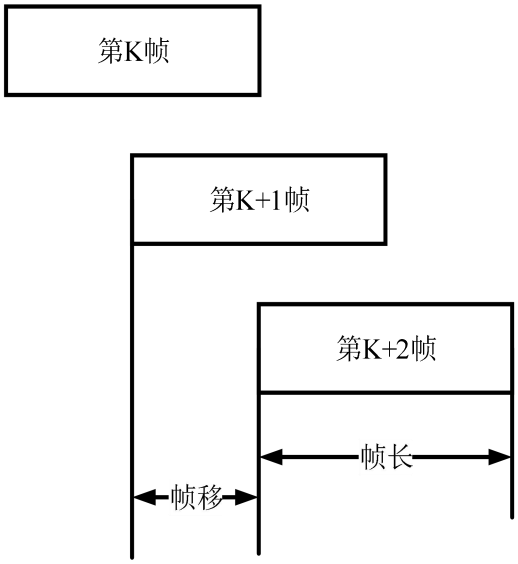


图 3.5 帧长和帧移示意图

Fig.3.5 Schematic diagram of frame length and frame shift

中国知网 https://www.cnki.net

3.2.4 加窗

分帧是处理婴儿哭声信号的理论基础，具体实现过程是通过窗口化婴儿哭声信号而获得的。如果只进行简单的分帧操作会使音频信号的周期性截断，非周期截断的音频会造成频谱泄露，所以为了尽可能的减少频谱泄露，要进行加窗操作。通过让婴儿的哭声信号顺畅地滑过窗户，婴儿哭声信号可以根据窗口分割成段，在后续的研究中就可以分析和处理每个短段的婴儿哭声信号。加窗过程用公式(3-3)表示为：

$$Q_n = \sum_{m=-\infty}^{+\infty} T\left[x(m)\right] w(n-m) \tag{3-3}$$

上式 $w(n-m)$表示加入的窗函数，$x(m)$表示原始婴儿啼哭声信号的采样序列，$T[\ ]$表示各种变换，$T[\ ]$所包含的变换类型较多，通常为线性与非线性两种，在实际选择时依据加窗对象的现状进行判断，当 $T[\ ]$取不同的变化时，对应的输出 $Q(n)$也有随着改变。

在分析婴儿啼哭声时，所选的各种窗函数会对分析婴儿啼哭声音信号的最后结果产生直接影响，因而在选择窗函数时，要从下列两点进行研究，首先是窗函数形状，其次是窗函数长度大小。

窗函数有多种不同形状，而应用较多的几种为汉明窗、汉宁窗、矩形窗等，由下列公式(3-4)定义矩形窗：

$$w(n) = \begin{cases} 1, 0 \le n \le N-1 \\ 0, else \end{cases} \tag{3-4}$$

汉明窗的定义如公式（3-5）所示：

$$w(n) = \begin{cases} 0.54 - 0.46\cos\left[\dfrac{2\pi n}{(n-1)}\right], 0 \le n \le N-1 \\ 0, else \end{cases} \tag{3-5}$$

汉宁窗的定义如公式（3-6）所示：

$$w(n) = \begin{cases} 0.5\left[1 - \cos\left[\dfrac{2\pi n}{(n-1)}\right]\right], 0 \le n \le N-1 \\ 0, else \end{cases} \tag{3-6}$$

以上(3-4)、(3-5)、(3-6)三个表达式中的 N 均为窗口长度。

尽管三个窗函数的频率响应都具有低通特性，然而在对婴儿哭声进行分帧后，窗函数形状不同也会对短时特征产生一定影响。由此可见窗口函数的形状对于婴儿哭信号的时域分析非常重要，矩形窗口优势在于频谱平滑性，所以它被更广泛地使用然而它也有弊端，是易于丢失高频信息，由于婴儿的哭声包含着丰富的频率特征，所以本文选择汉明窗进行加窗操作。

中国知网 https://www.cnki.net

窗口函数的长度对婴儿哭声信号幅度变化有重要影响。这是因为窗口 N 值越大、长度越长，窗口功能越宽，宝宝哭声信号的短期信息就越慢。窗口函数的宽度变窄，此时婴儿哭信号的短期信息波动非常快，会导致映波形上细小的改变，然而 N 值较小导致短期信息受阻，无法顺畅流通，一个语音帧内应包含 1-7 个基音周期，但是婴儿的基音周期变化较大，变化频率的跨度也非常大，因此短期分析婴儿哭信号期间要选取一个最佳的窗函数长度，在本文研究中 N 取 150 点较为合适。

3.2.5 端点检测

幼儿哭声识别系统中端点检测技术是核心部分[51]。对于哭泣的片段，要准确地找到它的开始和结束位置，然后在哭泣片段前后有效地去除多余的噪音，最后即可准确的得到哭泣片段数据，它为功能参数提取阶段和之后的哭声训练识别阶段提供了完全可靠的高潮部分[52]。

利用端点检测技术，实验过程中可大大降低幼儿哭声系统的计算量和数据存储量，然而应当注意，工作负载量越小终点检测方法越有效。在端点检测过程中，如果去除了过多的哭泣片段，在去除杂音片段的同时，也去除了一些有用的哭泣片段，如果在该部分的高潮部分中包含的数据信息非常重要，则它影响下一个呼叫识别的正确性。当然，如果没有正确移除噪声片段，则剩余的噪声片段也干扰下一个呼叫识别。因此，在应用环境中，如何有效对婴儿啼哭开始时间与结束时间判断，采取的端点检测方式非常关键。

目前有多种不同类型的终点检测方式，然而每种方式的检测效果与结果都有一定差别，面对各对象要采取不同方法检测，在确保计算量与处理时间较短的基础上，保证取得的效果最佳，最终得出婴儿哭声识别系统具有较高的识别率。

终点检测过程由三个部分构成：

（1）根据分段重叠方法，哭泣的信号由分割的段分割成帧。

（2）使用适当的检测方法，将幼儿的哭声段分割成具有哭声信息的帧和没有哭声信息的帧。

（3）去除没有哭声的信息的框架，剩下的是婴儿哭段的整个区域。

这里给出常用的终点检测方法：短时能量和短时平均振幅。短时能量能够有效且准确地判断有声和无声的部分。

哭泣信号的能量随着时间而变化，由于有声部能量远远大于无声部能量，因此与之相应的无声与有声部婴儿高潮信号峰值振幅就有一定的差别，采用有效方式对无声段与有声端区分，可对婴儿哭声信号的特性进行说明。婴儿哭声信号能量在时间推移下产生变化，通常浊音部分能量远超清音部分能量，因而轻音段、浊音端相

中国知网 https://www.cnki.net

应的婴儿啼哭声信号峰值幅度具有较大差别，由此可通过清晰地辨认浊音段与轻音段来说明婴儿啼哭声信号特征。

短时能量的定义如(3-7)式所示：

$$E_n = x^2(n) * h(n) \tag{3-7}$$

$\{x(n)\}$为婴儿原始啼哭声信号，E_n指的是婴儿啼哭声信号在第 n 个点上将函数短时能量加入，分析公式(3-7)可知，需要将婴儿啼哭声信号的平方从滤波器上经过后得到短时能量。$h(n)$是本滤波器单位冲激响应，由此可知平方运算婴儿啼哭声信号后即可得到短时能量，理解起来也非常简单，然而该做法会导致婴儿啼哭高低信号间具有差异，产生的影响更严重。由此可见此处要用其他方法对婴儿啼哭声能量改变情况表示，即短时平均振幅，由公式(3-8)表示其定义：

$$M_n = \sum_{-\infty}^{+\infty} |x(m)| w(n-m) \tag{3-8}$$

3.3 语谱图

3.3.1 语谱图的特征

语谱图也被称作频谱分析视图[53]。在发音过程中，因为声道通常是活动的，所以这个斗篷也是时变的。然而，这种时变过程比振动过程慢得多，所以我们通常可以假设在短期内是稳定的，我们可以分析在那一段时间内每一个瞬间的声音信号频谱，通过这样的连续分析，获得二维光谱，即语音频谱[54]，这种反映声音动力学的谱图也被视为视觉语言。频谱图的横轴表示时间，纵轴表示频率，各像素的灰度值在对应的时间反映对应的频率的信号能量密度，语谱图的横向黑色带纹表示共振峰，竖向黑带纹表示基音，条纹越密集表示基因频率越高。

3.3.2 语谱图的生成

将语音信号变成图形模式，可以选用时域波形图或频域波形图[55]，但是这两种方式中的信息内容较少，存在限制，仅能对语音信号跟随时间发生的变化进行表示，或者是随频率而发生的变化。此时语谱图的出现就可以解决这个问题，它同时包含时域信息和频域信息。语谱图实质是二维的图谱，它的颜色信息表示频率能量大小，语谱图由于使用的语音信号具有波长短、稳定性好等特征，因而可以更好地整合语音频域信息与时域信息。不管在何时，周围的短波信号均可获得比较稳定的频率特征，再利用该方式持续分析频谱即可有效整合两者[56]。

中国知网 https://www.cnki.net

语谱图通常分成两类，宽带语谱图和窄带语谱图，用带通滤波器实现对宽度的分析，这就是宽带语谱图和窄带语谱图划分的原理。宽带语谱图和窄带语谱图一般从两个方面进行区分，一种是时间分辨率，另一种是频率分辨率。

针对时间分辨率上的研究数据为 300-400Hz 左右，其取值范围在 2-5ms 左右；针对频率层面的分辨率研究数据为 50-100Hz，其取值范围在 5-10ms。以下列出五种不同类型的婴儿哭声语谱图，这些语谱图是由于饥饿、疲倦、腹部疼痛、打嗝等各种原因而哭泣的声音来绘制成的，每种因素不同哭声形成的语谱图也不同。

本文将婴儿哭声数据用绘制语谱图代码进行处理，得到以下五种类别的婴儿哭声语谱图，如下所示：

婴儿因打嗝而哭语谱图如图 3.6、3.7 所示：

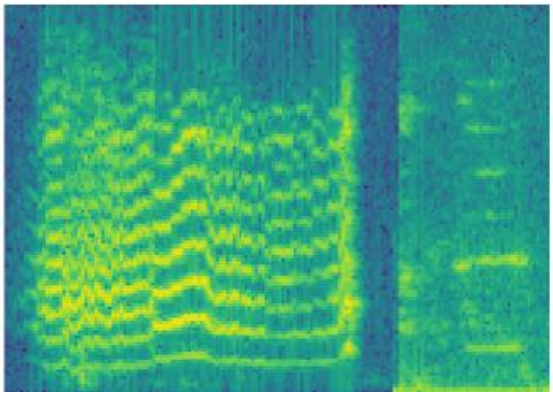


图 3.6 婴儿打嗝语谱图（1）

Fig.3.6 Synopsis of baby hiccups（1）

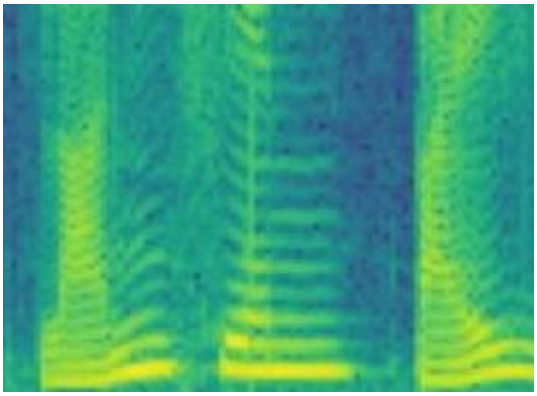


图 3.7 婴儿打嗝语谱图（2）

Fig.3.7 Synopsis of baby hiccups（2）

婴儿因困倦而哭语谱图如图 3.8、3.9 所示：

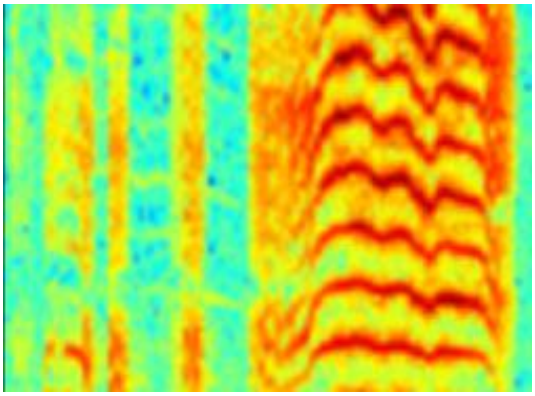


图 3.8 婴儿困倦语谱图（1）

Fig.3.8 Synopsis of crying fromsleepiness（1）

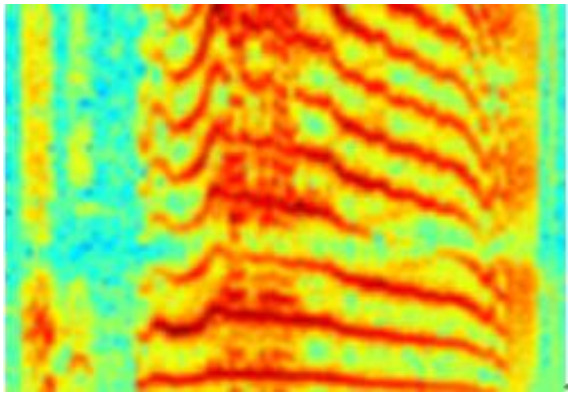


图 3.9 婴儿困倦语谱图（2）

Fig.3.9 Synopsis of crying from sleepiness （2）

中国知网 https://www.cnki.net

婴儿因饥饿而哭语谱图如 3.10、3.11 所示：

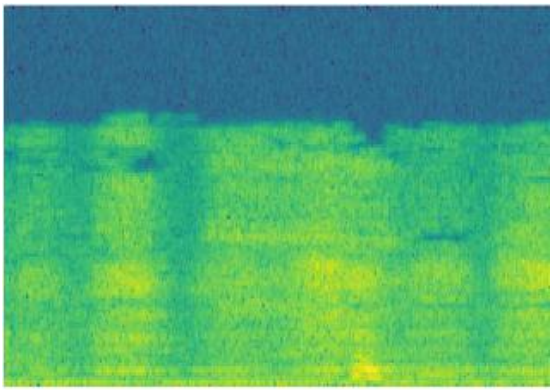


图 3.10 婴儿饥饿语谱图（1）

Fig.3.10 Synopsis of crying from hunger（1）

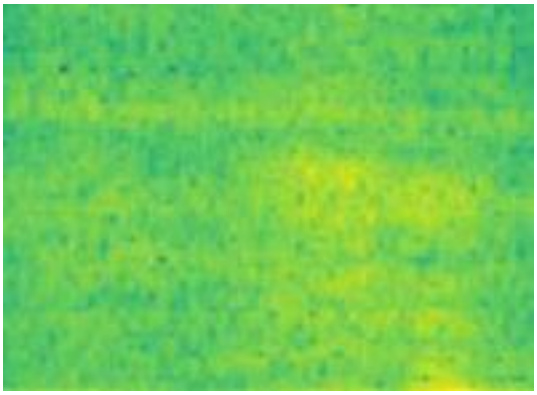


图 3.11 婴儿饥饿语谱图（2）

Fig.3.11 Synopsis of crying from hunger（2）

因为疼痛而哭的语谱图如下图 3.12、3.13 所示：

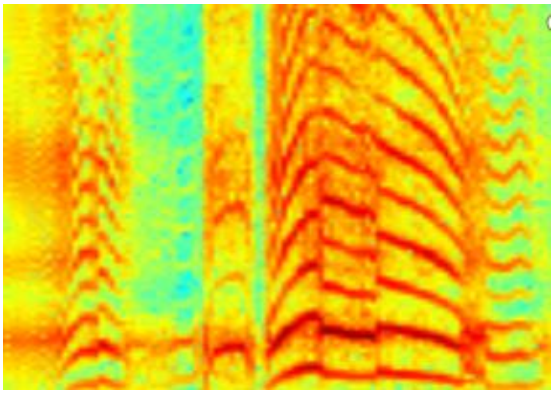
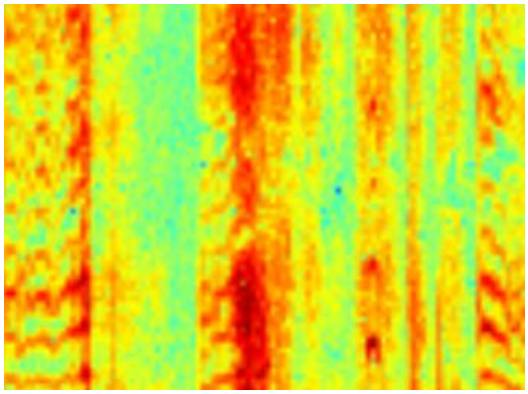


图 3.12 婴儿疼痛语谱图（1）

Fig.3.12 Synopsis of crying from pain



3.13 婴儿疼痛语谱图（2）

Fig.3.13 Synopsis of crying from pain

因为不舒服而哭的语谱图如下图 3.14、3.15 所示：

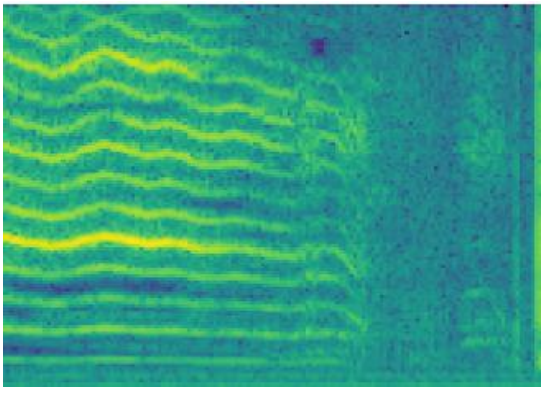
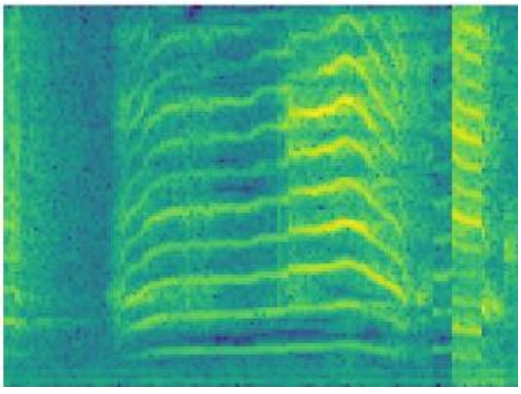


图 3.14 婴儿不舒服语谱图（1）

Fig.3.14 Synopsis of uncomfortable（1）



3.15 婴儿不舒服语谱图（2）

Fig.3.15 Synopsis of uncomfortable（2）

中国知网 https://www.cnki.net

3.4 本章小结

有效的婴儿哭声数据库是研究婴儿情感识别课题的重要数据依据，对哭声情感识别领域的特征参数提取非常关键。本章首先总结了婴儿哭声的特点，设计并建立了婴儿哭声情感数据库；其次对婴儿哭上数据进行预处理，采用分帧、加窗、端点检测等操作；最后将预处理操作后的婴儿哭声转化成语谱图，为接下来建立基于 CNN-Transformer 的婴儿哭声情感分析模型做好准备。

中国知网 https://www.cnki.net

第 4 章 基于 CNN-Transformer 模型的婴儿啼哭情感分析方法

第二章对于基于深度学习的语音情感分析相关技术的研究和第三章中对婴儿哭声数据库的建立以及哭声数据预处理为本章提出的 CNN-Transformer 婴儿哭声情感分析模型奠定了基础。在本章中详细给出了模型的具体架构以及模型细节，并对模型进行了改进，用本文所构建的数据库对模型进行训练，并且将 CNN-Transformer 婴儿哭声情感分析模型与 CNN-LSTM 模型和 Inception-v3 算法按照分类正确率、单分类正确率、以及训练耗时三个指标进行评测并对结果进行对比分析。

4.1 CNN-Transformer 模型

本文提出采用 CNN-Transformer 模型进行婴儿哭声情感分析，CNN 模型对图片的强大处理功能联合 Transformer 模型的有效时序数据处理功能，能够快速且准确的对婴儿哭声进行情感分析。该模型主要运用 Transformer 完成整体模型的主要创建，Transformer 模型针对连续语谱图也就是视频帧节展开分析，利用注意力作为依据，在时间上对于不同视频之间的帧节在同等的频率下进行研究，这样就可以保证帧节的首部和尾部在数据上的等值，在信息的保存和距离的控制上起到很好的作用。注意力机制在时序的捕捉上与传统的捕捉机制有着本质的差别，通过对连续帧节的科学分析，从而实现对视频序列的科学分析和研究，Transformer 模型对于时序的处理效率较高，借助矩阵实现对各项信息的采集，借助 GPU 的矩阵计算可以极大的改善系统的算法效率，实现科学分析的目的。

4.1.1 CNN-Transformer 模型架构

图 4.1 为 CNN-Transformer 模型对婴儿哭声情感分类的处理流程：

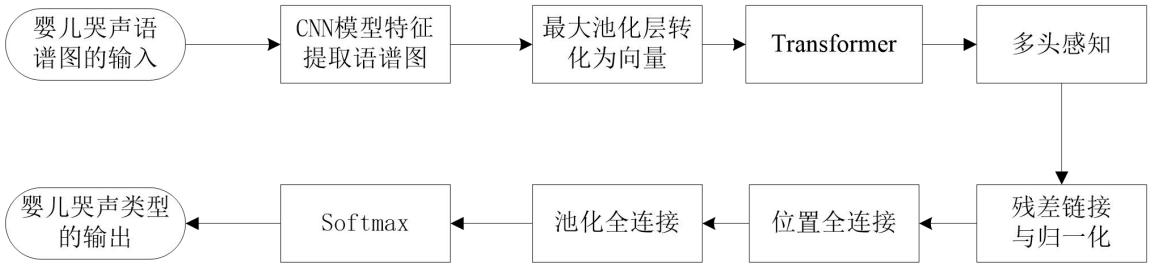


图 4.1 基于 CNN-Transformer 模型对婴儿哭声情感分类的处理流程

Fig.4.1 The processing flow of infant crying emotion classification based on the CNN-Transformer model

中国知网 https://www.cnki.net

CNN-Transformer 模型运算的机理就是借助模型实现对连续语谱图进行分析，将多余的信息清除，然后利用 CNN 实现对连续图片信息的完整采集和科学分析，获取图像化的各项特征，借助最大池化层将图像化特征转化为向量，作为模型创建的基础，再将特征向量输入到 Transformer 结构的 Encoder 部分，因为 Decoder 部分主要使用在序列的生成上，而 Encoder 在这里的作用是编码，在时序模型的创建上发挥着一定的作用。Encoder 信息的输出可以加上一个全局的平均池化，实现矩阵的一维分析，然后通过连接层完成对数据的研究，最后通过 Softmax，实现对类的激活和转化，最后得到分类。

4.1.2 CNN-Transformer 模型细节

表 4.1 CNN-Transformer 算法中 Resnet50 特征提取器网络结构

Table 4.1 Resnet50 feature extractor network structure in CNN-Transformer algorithm

网络层	参数	输出维度
Conv1	7×7, 64, stride2 3×3, MaxPool, stride2	*n*/2×*n*/2
Conv2×3	1×1, 64 3×3, 64 1×1, 256	*n*/4×*n*/4
Conv3×3	1×1, 128 3×3, 128 1×1, 512	*n*/8×*n*/8
Conv4×3	1×1, 256 3×3, 256 1×1, 1024	*n*/16×*n*/16
Conv5×3	1×1, 512 3×3, 512 1×1, 2048	*n*/32×*n*/32
MaxPooling		1×1

中国知网 https://www.cnki.net

CNN-Transformer 模型采用 Resnet50 进行特征提取，Resnet50[57-58]利用残差链接有效控制卷积层网络，模型的创建对参数精度要求较高，这也是模型创建的重要指标。在本模型设计中使用的网络是 Resnet50，属于训练好的网络样本，这里的全连接层和 Pool5 层在设计过程中需要全部清除，并且在 Resnet50 中添加全局最大池化层以确保一维向量的有效生成，这样得到的 Resnet50 中输出的维度向量表示为 1×1×2048，由此向量 2048 就是将前两个维度清除之后的产物。研究中假设输入的图片为 n×n，表 4.1 为 Resnet50 网络结构。

CNN-Transformer 模型利用 Transformer 创建时序模型，Encoder 部分其主要的作用是实现对特征的提取，根据非线性和残差链接，使 Encoder 输入输出数据的维度具有相同的属性，在后续的类的划分上则主要是建立在全连接的基础上。维度的输出决定着信息的精度，这里使用 flatten 层加全连接层可能会造成数据的参数较大，所以需要使用平均全局化池层消除其中的计算量，假设 Encoder 输入的矩阵为 $m\times n$，m 表示序列长度，n 代表其中的特征向量长度，这里的目标研究分为 k 类，则 Encoder 部分的结构如表 4.2 所示：

表 4.2 CNN-Transformer 模型对应 Encoder 部分结构

Table 4.2 Partial structure of Encoder corresponding to CNN-Transformer model

网络层	参数	输出维度
Multi-head attention	$n\times n\times 3$	$m\times n$
Position-wise Feed-Forward network	$n\times n$ $n\times n$ (no activate)	$m\times n$
AveragePooling		n
FullConnect	$n\times k$	k
Softmax		k

对于 CNN-Transformer 模型来说，Encoder 上的参数研究主要集中在多头感知部分，其中数据参数和输入维度之间保持着密切的联系，想要保证网络的迅速建立就要确保具有足够多的参数数据，所以在图片特征向量的提取时要设置一个较大的向量。

4.2 CNN-Transformer 模型的改进

传统的 CNN-Transformer 模型会在 CNN 提取特征后将特征图压缩为一维向量，压缩过程中会导致信息的丢失，本章对模型进行改进，使模型能够直接将特征图序

中国知网 https://www.cnki.net

列作为输入，但是为保证其具有很好的拓展性，这里需要对研究的向量和维度进行明确，为实现对数据的完整收集将 resnet50 网络全连接层与 pool5 层清除，改进后的模型仍采用表 4.1 中显示的 resnet50 网络基本结构。相对于传统的 CNN-Transformer 模型，本文所提出的 CNN-Transformer 模型使用 3D 卷积来替换传统的 Transformer 中的线性层与全连接层，把原来 DA 的感知方式更换为 AA 的感知方式，让更高维的特征数据可以在网络中流动。

提取图像上的特征图后，结合不同特征图拼接图像成为一个整体，将其做为 Encoder 上的输入，此处 m 为稀疏采样的视频帧，即时序长度，CNN-Transformer 模型是针对元素能顾并行计算的分析，针对上述的特征拼接成(m,h,w,c)的四维张量成为 Encoder 的输出部分，h 与 w 分别表示特征图高度、宽度，c 就是特征图的深度。

4.2.1 修改位置编码

输入维度的变化使得向量的表达形式也发生一定的变化，一维向量会转变为二维向量，特征图就表示为(h,w,c)的张量，但是需要注意到元素位置的影响，一般同一个特征图不同通道属于同一位置的元素，其位置信息应相同，因而无法向通道数 c 设定对应的位置信息，分析输入张量元素时由(pos,i,j,c)来表示所处位置，那么得到的位置编码信息为式（4-1）所示：

$$F\left(p,i\right)=p/10000^{\frac{ij}{hw}} \tag{4-1}$$

针对相同维度(m,h,w,c)的张量运算时，首先需要对位置信息进行明确，然后将所有位置为 pos 的张量进行运算：计算(i,j,c)元素位置信息期间，假如$(i+j)\bmod 2=0$，则与元素相应的 sin 函数处于激活状态，如果$(i+j)\bmod 2=1$，需要用 cos 函数激活，将式（4-1）代入后得到式（4-2）如下：

$$\begin{cases} P\left(p\right)=\sin\left(p/10000^{\frac{ij}{hw}}\right),\left(\left(i+j\right)\bmod 2=0\right) \\ P\left(p\right)=\cos\left(p/10000^{\frac{ij}{hw}}\right),\left(\left(i+j\right)\bmod 2=1\right) \end{cases} \tag{4-2}$$

经过 sin 函数与 cos 函数激活后得到的张量作为位置编码的输出，再将位置编码的输入输出进行线性叠加，就得到了多头感知部分的输入。

4.2.2 修改多头感知

常见的 Transformer 模型中的多头感知主要是由 Q、K、V 通过线性转换和缩放点积感知得出，其中线性转换采用单层全连接层，缩放点积感是一种 DA 感知模式，数据维度上与传统 CNN-Transformer 模型具有一定差别，使得这两点的特征会出现

中国知网 https://www.cnki.net

一定的变化，也可以理解为不同 Q、K、V 维度发生了变化，这里主要是借助 3D 卷积实现对各项数据的研究分析，而图像的输入特征则会在数据向量的压缩下实现缩放点积感知，向量维度的变化也会造成数据的变化，因此在研究思路上使用 AA 方式提升自注意力感知。

线性变换 Q、K、V 期间，传统 Transformer 模型设置的参数的头数为 *Num_Head*，再与 Q、K、V 需要划分的片段相结合，得出对应的 *Num_Head* 段，这就是建立卷积运算基础上的数据分析和研究。而本模型是使用 3D 卷积来实现 Q、K、V 之间的相互变换，在 *Num_Head* 的卷积函数的变化中，需要对头数进行计算，以实现各项数据维度的一致性，将头数转换为卷积核数 *Num_Kernel*，*Num_Kernel* 需与特征图通道数一致，通过 *Num_Kernel* 个 1*1*1 的卷积核从而能够对 Q、K、V 进行操作，其操作后的维度为(*h,w, Num_ Head*)。

缩放点积感知中需要对 Q 与 K 的关系进行明确，分析其维度上的向量关系，找出 Q 与 K 的元素在描述中的各项特征，接着对其进行转换，使 Q 与 K 在维度上完成数据的拼接和特征的科学提取。Q 可以表示为 m 个(*h,w, Num_ Head*)张量构成的序列，使用 iQ 表示第 i 个向量的研究 ，那么这里的 m 个张量就可以按照（4-2）的方式实现对数据分析和拼接的科学构造得出(1,*mh,mw, Num_ Head*)的输出阵列，如图 4.3 所示：

$$\begin{pmatrix} Q_1 & Q_1 & \cdots & Q_1 \\ Q_2 & Q_2 & \cdots & Q_2 \\ \cdots & \cdots & \cdots & \cdots \\ Q_m & Q_m & \cdots & Q_m \end{pmatrix}$$

图 4.3 Q 输出阵列

Fig.4.3 Q output array

结合上述的研究得出 K *也*可以表示为 m 个(*h,w, Num_ Head*)张量构成的序列，使用 *iK* 表示第 i 个向量的研究 ，对数据分析和拼接的科学构造得出构造一致的输出阵列，如图 4.4 所示：

$$\begin{pmatrix} K_1 & K_1 & \cdots & K_1 \\ K_2 & K_2 & \cdots & K_2 \\ \cdots & \cdots & \cdots & \cdots \\ K_m & K_m & \cdots & K_m \end{pmatrix}$$

图 4.4 K 输出阵列

Fig.4.4 K output array

中国知网 https://www.cnki.net

Q 在序列的横向排布上的元素完全一致，第 *i* 个元素由第 *i* 行表示，纵向排列上 *K* 阵列排布元素一致，第 *i* 个元素由第 *i* 列表示，拼接 *K* 阵列与 *Q* 阵列为一个维度，就可以得出对应的一个维度为(2,*mh,mw, Num_ Head*)的张量，如图 4.5 所示：

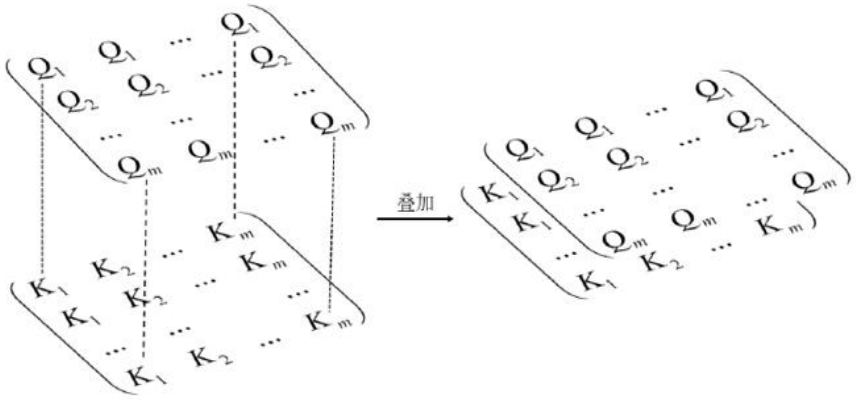


图 4.5 Q 与 K 拼接

Fig.4.5 Q and K stitching

拼接后可以看出，*Q* 序列的 *m* 个元素与 *K* 序列的 *m* 个元素在各个位置上进行了一一对应。然后采用一个池化大小为(2,*h*,*w*)、池化步长为(1,*h*,*w*)的三维平均池化层计算 *Q* 与 *K* 矩阵的，这里的(1,*m,m, Num_ Head*)表示输出张量，然后在经过 3D 卷积层进行操作，其卷积核为 1×1×1，在此种方法进行降维处理，得出对应的(1,*m*,*m*,1)的张量，然后留下中间维度的张量，这里的维度矩阵表示为(*m,m*)，如图 4.6 所示。各项研究主要是围绕平均池化展开，所以对于数值的大小有很好的控制效果，可以直接将数据代入得到对应的 Softmax 激活得到最终关系矩阵，这也是以科学的方式研究矩阵内两两元素之间的关系。

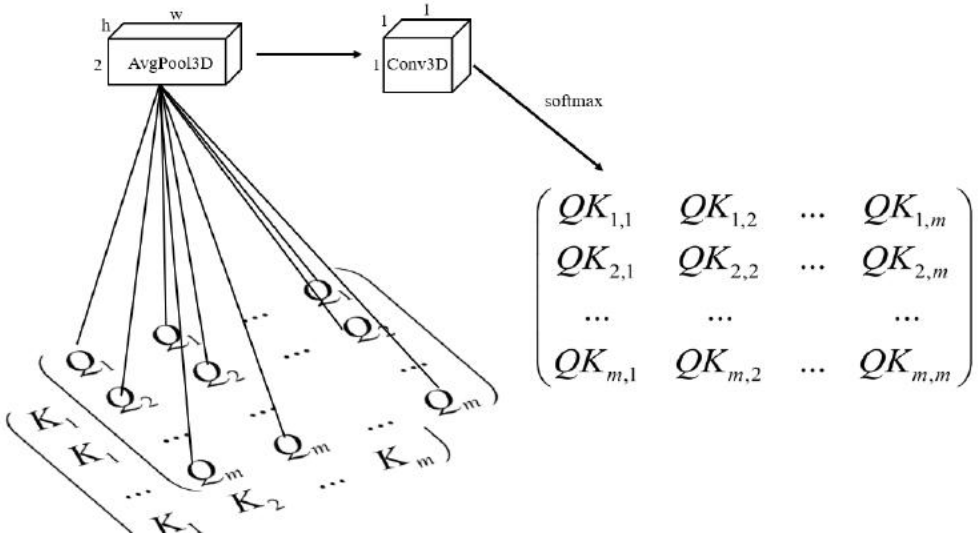


图 4.6 求关系矩阵过程

Fig.4.6 The process of finding the relation matrix

中国知网 https://www.cnki.net

为快速获取矩阵和 V 的积，首先需要对 V 进行维度转换，将原来的维度($m, h, w, Num_ Head$)进行转换，得出（$m, hwNum_ Head$）然后将得到的维度结果和 V 相乘，就可以得出对应的矩阵，将其作为下一层的研究基础。

4.2.3 修改残差链接与归一化

这里研究的内容操作步骤较为简单，就是将多头感知部分进行叠加，然后经过批归一化处理实现对数据的整合然后输送到位置全连接前馈网络。

批归一化的作用主要体现在 CNN-Transformer 模型在运算中的序列长度都是保持一致的，并且不需要接借助 Decoder 部分就可以实现对数据的分析，模型具有良好的运算效果，不受序列长度的影响，在时序的分析上发挥着很好的效果，批归一化计算方式简单，有很好的科学性。在 mini batch 较大的情况下，尤其是对大量数据的分析和研究时，批归一化在卷积神经网络的研究上具有很好的效果。

4.2.4 修改位置全连接前馈网络

传统的 Transformer 往往会使用两个 1×1 卷积对全连接前馈网络展开分析，以此确保参数量不会过大，此时卷积也可以使用两个 1×1×1 的方式完成对数据的分析。实际的研究中主要是依据增加第一个 1×1×1 卷积的核数的方式来加强对网络的管理，但是需要保持各项数据的一致性，所以第二个 1×1×1 卷积核数需要设置为 c ，相关的运算过程如（4-3）所示：

$$FFN = Tran_{1\times1\times1}\left(\max\left(0, Tran_{1\times1\times1}\left(x\right)\right)\right) \tag{4-3}$$

位置全连接前馈网络中的数据在经过残差链接归一化处理之后得到维度(m,h,w,c)的张量，然后经过两个池化量为(2,2,2)、步长为(2,2,2)的三维平均池化层，再经过全连接层和激活的 Softmax 完成最后的数据输出。

4.3 实验验证

4.3.1 实验环境

本文提出的对婴儿啼哭情感分析模型属于深度学习模型，该模型可以通过一个或者若干个 Encoder 块叠加实现哭声情感分析的各项功能，Encoder 的数量决定着网络的学习深度，因为在研究中 Transformer 模型不需要对数据做循环迭代计算，所以本文研究的本质就是对向量维度的研究。在系统的硬件配置上，对于显卡的要求较高，配置 GXT1080Ti 显卡与英特尔 i7-7700k 处理器。如表 4.3 所示实现详细的系统配置参数。语言的编辑软件使用的是 Python，因为这里的数据分析需要对婴儿哭声音频的特征进行提取以及大量数据的整合和压缩，所以在版本上主要以 C++版本

中国知网 https://www.cnki.net

的 OpenCV 为主，实现对图像信息的快速处理和数据的有效采集。为快速的完成模型的创建，这里主要是依据 Keras 做为深度学习框架，数据的处理主要依据 Numpy、Hdf5、Matplotlib、Python 等实现，表 4.3，4.4 是与硬件部分软件部分的信息参数：

表 4.3 硬件环境配置

Table 4.3 Hardware environment configuration

硬件名称	硬件参数
CPU	Intel i7-7700k
GPU	GTX1080 Ti 11GB
内存	16GB
主板	Z270-AR
硬盘	512GB SSD + 2T HDD

表 4.4 软件环境配置

Table 4.4 Software environment configuration

软件名称	配置名称
系统	Ubuntu16.04　64bit
深度学习框架	Keras、Tensorflow
编程语言	Python
依赖库	Numpy、Hdf5、Matplotlib 等

4.3.2 实验数据集

为了使模型的测试更具有公平性，本文选取公开数据集作为测试数据集。由于 ESC-50 数据库和 Freesound 数据库中部分数据集含有杂声，所以本文在这两个公开数据库中筛选适合的音频数据进行实验。

（1）ESC-50

ESC-50 数据集的组成部分包含大约两千个音频数据，数据由 5s 的定长录音片段构成，类型有 50 种，每种样本共计 40 个，同时可划分该类型为五个不同大类。

中国知网 https://www.cnki.net

Freesound 项目是 ESC-50 数据集原始数据的主要来源，通过引用 ESC-50 上部分数据选取一个满足个人要求的数据集，也可以查找 Freesound 上数据资源创建数据集。

（2）Freesound

Freesound 是一个开放化的音频数据库，其中存储了大量音频数据，基于 Creative Commons 发布许可证，用户可在该数据库上完成语音数据的上传与下载操作，可自由下载其他用户上传的音频数据，并且按照授权协议授权可以结合作者授权模式对发布的音频二次创造。网站上的音频数据通常具有下列信息：

1. 说明：主要是对音频文件上的信息说明。

2. 文件类型：Aif、Wav、Mp3 及 Aiff 等。

3. 授权方式：常见的有三种，分别为 Attribution、Creative Commons0 及 Attribution Noncom-Mercial。

4. 采样率、比特率、位深信息。

4.3.3 实验对比模型

为了充分验证本文所提出的 CNN-Transformer 模型的有效性，将所提出的模型与可解释性较强又有具有完备理论基础的深度学习模型进行对比，实验从多个维度综合的验证本文所提出的基于 CNN-Transformer 模型婴儿啼哭情感分析方法，下面为对比模型：

（1）CNN-LSTM 是 CNN（卷积层）与 LSTM 的集成。利用模型的 CNN 部分处理数据，将一维结果输入 LSTM 模型[59]进行分类。

（2）InceptionV3 模型是谷歌 Inception 系列里面的第三代模型，Inception 网络将神经网络层与层之间的卷积运算进行了拓展。Inception 网络采用不同大小的卷积核，使得存在不同大小的感受野，最后进行拼接达到不同尺度特征的融合[60]。

4.3.4 评价标准

（1）分类正确率

分类正确率是对整体性能的科学评价，是对整体样本的均等分配的研究，实现对正确率的均等分析，如公式（4-4）所示：

$$Q_a = \frac{N_c}{N_t} \tag{4-4}$$

式中，Q_a 代表正确率，N_c 代表正确的个数，N_t 代表总的个数。

（2）单类分类正确率

$$q_a = \frac{N_{cd}}{N_{td}} \tag{4-5}$$

中国知网 https://www.cnki.net

单分类正确率如公式（4-5）所示，q_a表示单类正确率，N_{cd}表示单类正确率个数，N_{td}表示单类总个数。单类分类正确率能够进一步对模型特征性能展开分析，尤其是当前类的研究在数据分布上不均的时候，使得分类器的操作在数据研究上的误差增加，但是在其他类别的研究上具有很好的效果，这也是出现误差不易被察觉的原因。单类分类正确率和总体正确率在计算方式上的差异不大，是对单独类进行研究分析。

（3）训练耗时

训练耗时是针对训练运行速率的分析，时间越短说明模型实时的效果越好，这里指所有次数训练消耗的均值，如公式（4-6）所示：

$$Q_T = \frac{\sum_{i}^{N} T_i}{N_{time}} \tag{4-6}$$

4.3.5 实验参数设置

在连续语谱图的稀疏采样过程中，对于帧数选取其平均值，将连续语谱图划分成 10 段，然后明确每段的第一帧，直至将 10 帧找出，作为采样帧数的结果。原图是 320×240 分辨率，按照特征提取器的分辨率进行变化，使用双线插值法使其分辨率变为 112×112，这样就可以快速提取相关的特征。

为保证特征提取的有效进行以及各项数据的完整，这里需要对提取的特征进行存储，训练模型就是直接对样本特征的提取。这里的提取方式就是依据 Imagenet 实现对网络的预处理得到 Resnet50 网络，再将最后的全连接层清除，当输入 112×112 的语谱图时，这里在数据处理之后得到的维度就是(4,4,2048)的特征图。也可以理解为 CNN-Transformer 算法在维度上的输入为(10,4,4,2048)。由于 CNN-LSTM 与 Inception-v3 模型都需要输入相关的维度，所以针对 Resnet50 网络的运算中需要添加的池化层为 4×4，步长为 1×1 的最大池化层，这样在之后就得到的维度为(1,1,2048)的特征图，然后再将冗余的数值清除，得到一维特征图，其数值为 2048，也可以理解为 CNN-LSTM 与 Inception-v3 的输入维度为(10,2048)。

在训练样本之前需要对数据和标签顺序进行打乱，接着依据训练样本的数据完成模型的创建和维度的分析。为体现实验的公平性，选取公开的 ESC-50 数据集和 Freesound 数据集中适合的哭声数据进行实验测试，ESC-50 数据集有可用哭声 200 个，Freesound 数据集可用哭声 1800 个，选取各数据库的 20%作为测试集，将各数据集的 80%数据和本文所建的数据集作为训练集。这里的总体训练数为 200 代，CNN-LSTM 模型、Inception-v3 算法、CNN-transformer 模型的 batch_size 数值设置为 32。

中国知网 https://www.cnki.net

4.4 实验结果与分析

4.4.1 ESC-50 数据集实验结果

在经过 200 次训练之后，不同的模型都基本上趋向收敛。CNN-LSTM 在第 177 次的时候正确率最高，数值为 92.4%。Inception-v3 算法在第 200 次达到的正确率最高，数值为 87.7%，在第 150 次之后其准确率增加并不明显。CNN-Transformer 模型在第 200 次训练后的正确率最高，数值为 97.8%，在第 150 次时其准确率就已经明显高于其他两个模型。CNN-LSTM 每次训练的时间为 9.2 秒，CNN-Transformer 每次训练的时间为 8.7 秒，Inception-v3 算法每次训练的时间为 7.2 秒。如表 4.5 所示：

表 4.5 不同算法的正确率与训练耗时

Table 4.5 The accuracy and training time of different algorithms

算法	正确率（%）	耗时（s）
CNN-LSTM	92.4	9.2
Inception-V3	87.7	7.2
CNN-Transformer	97.8	8.7

随着训练进行不断的更新数据，三种模型的正确率折线变化如图 4.7 与图 4.8 所示，在分析中可以得知，Inception-V3 与 CNN-Transformer 模型对于数据的分析效果显著，尤其是训练之后的正确率得到显著的提升，收敛效果显著。

CNN-LSTM 在经过 70 次训练后的收敛效果显著，而 CNN-Transformer 只需要进行 20 次训练就可以得到很好的收敛效果，Inception-V3 需要 16 次训练就可以有很好的收敛效果，然而其收敛效果远不如 CNN-Transformer。在对上述模型的研究分析中得出 CNN-LSTM 模型在数据集上有较好的正确率，但是其耗时比较长，而 Inception-V3 耗时较短，但是其正确率并不高。由此可见，CNN-Transformer 模型的学习效果更好，在数据处理上的正确率更高，这也是基于其的 3D 卷积数据处理之后的结果，为模型的创建和数据的分析提供便利。

中国知网 https://www.cnki.net

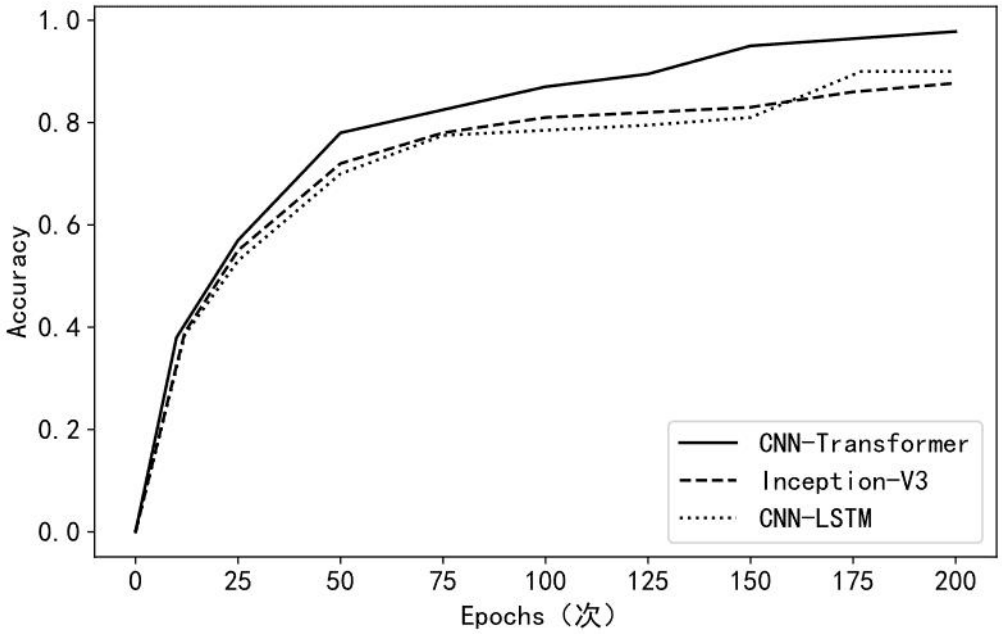


图 4.7 不同模型正确率

Fig.4.7 Correct rate of different models

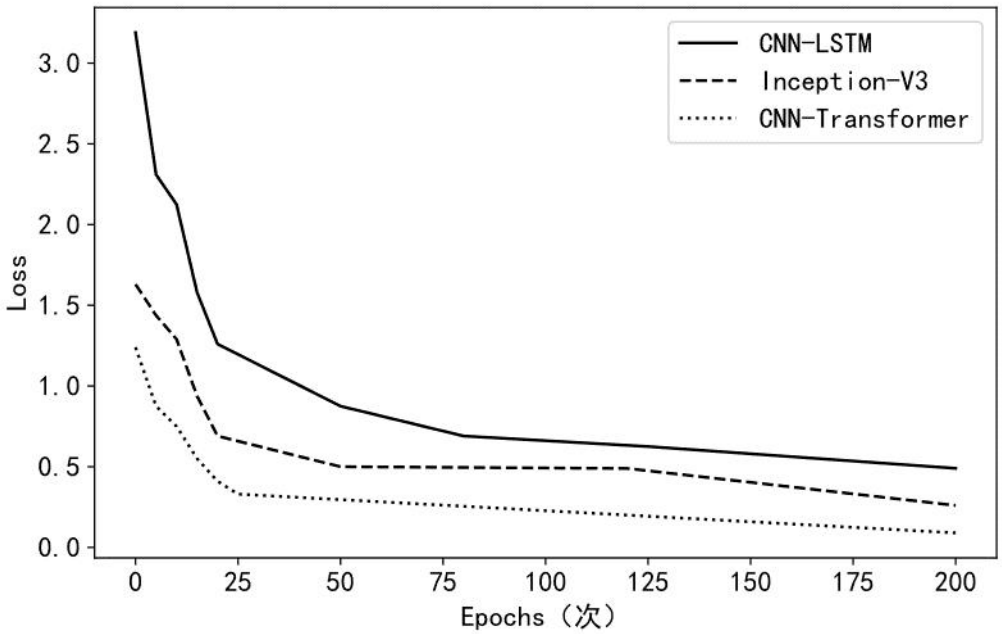


图 4.8 不同模型 loss 变化

Fig.4.8 Changes in loss of different models

中国知网 https://www.cnki.net

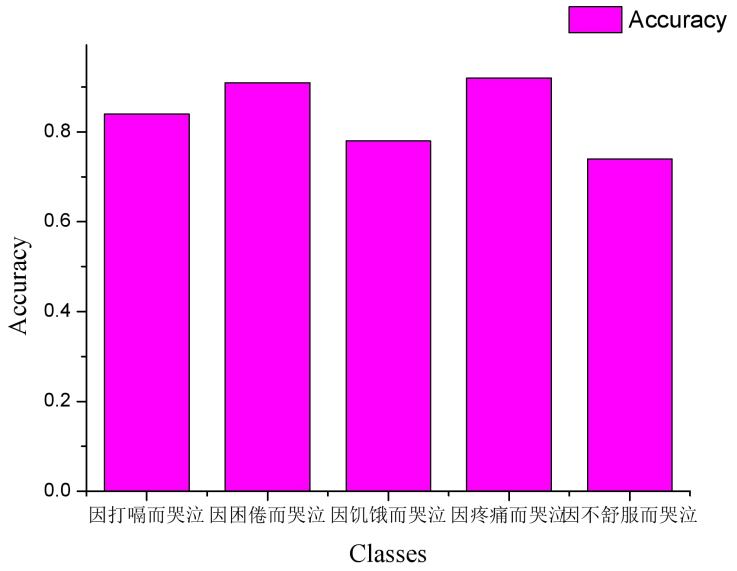


图 4.9 Inception-V3 的单类正确率

Fig.4.9 Single-class accuracy rate of Inception-V3

图 4.9 是 Inception-v3 算法的单类正确率，Inception-v3 的单类别正确率中，有 2 类正确率不足 80%，有 1 类的正确率不足 90%，正确率大于 90%的为 2 类，在对算法对比分析的过程中得出 Inception-v3 算法在单类的研究上还有一定的拓展空间，虽然整体上的数据正确率较高，但是针对单一类别的正确率研究还是存在一定的差距。

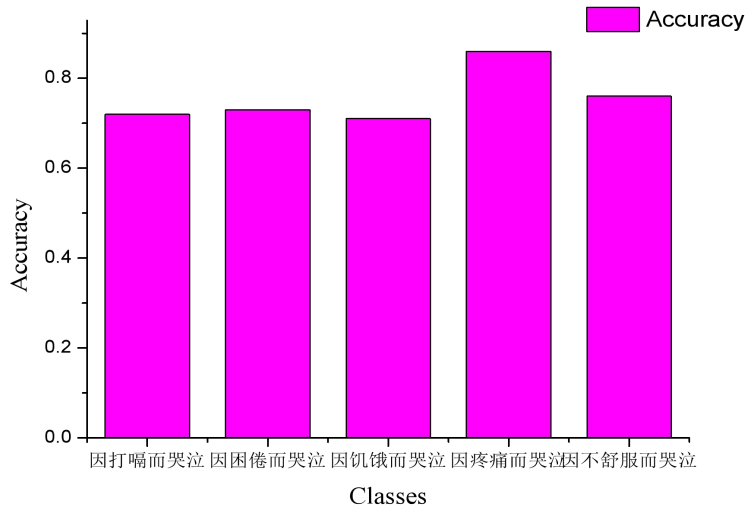


图 4.10 CNN-LSTM 模型的单类正确率

Fig.4.10 Single-class accuracy rate of CNN-LSTM model

中国知网 https://www.cnki.net

图 4.10 为 CNN-LSTM 模型的单类正确率，CNN-LSTM 模型单类的准确率最高为 88.7%。CNN-LSTM 模型单类的准确率最低为 73%其类别为因饥饿而哭，其中有 4 类的正确率不足 80%，得出 CNN-LSTM 模型具有较差的适应性，在复杂情况下，不易进行数据处理。

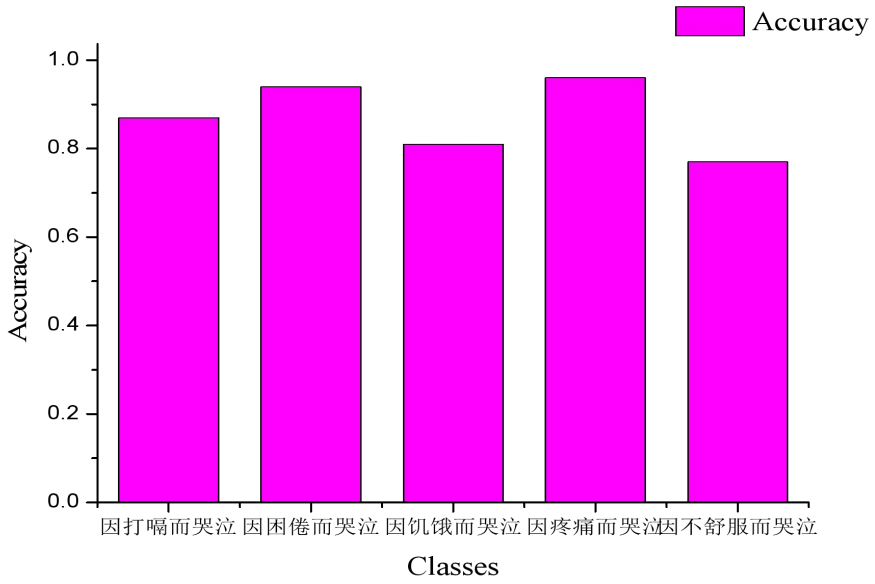


图 4.11 CNN-Transformer 模型的单类正确率

Fig.4.11 Single-class accuracy rate of CNN-Transformer model

图 4.11 为 CNN-Transformer 模型的单类正确率。由图可以看出 CNN-Transformer 模型中单类的准确率最低的类别是因为不舒服而哭，正确率为 78.1%，其中有 4 类的正确率在 80%以上，有 2 类的正确率超过 90%，由此可以得出 CNN-Transformer 模型具有很好的适应性，能够应对复杂情况下的数据处理。

在对上述图表信息的分析中可以找出正确率不足 90%、80%的各类的特征，对于模型在不同层次的分析上起到很好的效果，特别是针对数据正确率的分析效果显著，这体现出模型在时间上的处理效果显著，具有很好的时间特征提取效果。但是三种模型在因不舒服而哭泣，和因饥饿而哭泣这两类的表现一般，可能是这两类的数据在特征属性具有很多的相似性，导致造成其在数据处理上的模糊，对其结果略有影响。

如下表所示，Two-Stream 算法属于基础的双流法，其主要的贡献就是对 ESC-50 数据的采集效率达到 86.4%，C3D 算法可以独立完成对数据的收集计算，其正确率

中国知网 https://www.cnki.net

达到 92.8%，TSN 算法其准确率为 91.7，由此可以看出主流算法在数据集上的表现并不好，准确率有待提升。

表 4.6 是在当前常见的算法基础上实现对 ESC-50 数据集的研究。

表 4.6 主流算法在 ESC-50 上的表现[61]

Table 4.6 The performance of mainstream algorithms on ESC-50

算法	额外操作	正确率
Two-stream	无	86.4%
TSN	无	91.7%
C3D	无	92.8%

在对模型的对比研究中得出，CNN-Transformer 模型与 Inception-v3 算法可以独立完成各项数据的分析和操作，其中 CNN-Transformer 模型在准确率上具有很好的表现，并且对于数据的处理效果显著同时在测评指标中有着优秀的结果。CNN-Transformer 模型中包含的卷积结构，当面向的训练样本较大时，可以满足后续的升级优化需求。

通过对上述的研究分析得出，CNN-Transformer 模型和 CNN-LSTM 模型在数据的处理上效果显著，在正确率上略有差距，但是对数据的处理效率有较大差距，两者都具有很好的实践价值，前者在大规模数据处理上更加适用，后者则是在小规模的数据处理上表现更佳。

4.4.2 Freesound 数据集实验结果

在 200 次训练之后，三种模型的数值基本上趋向一致，CNN-LSTM 模型在 37 次训练之后的正确率达到较好状态，在训练 185 次时出现浮动，最高数值为 90.5%，Inception-v3 模型在 48 次训练后得到较好准确率，在第 128 次时达到数值的最高值，数值为 94.1%，CNN-Transformer 模型在经过 134 次训练之后的就有较好的正确效率，最高数值为 98.1%。CNN-LSTM 模型每次训练的时间为 7.2 秒，Inception-v3 每次训练的时间为 6.7 秒，CNN-Transformer 每次训练的时间为 6.2 秒，详细的结果如表 4.7 所示。

在 Freesound 数据集中利用 CNN-Transformer 模型可以实现对数据的快速收集整理,并表现出更好的特征。CNN-LSTM 模型则需要消耗的时间较长，CNN-Transformer

中国知网 https://www.cnki.net

模型与 nception-v3 算法的耗时相差不大，在 ESC-50 数据集中 CNN-Transformer 模型耗时比较长，这是因为 Freesound 数据集体量小，所占内存空间小。

表 4.7 不同算法的正确率与训练耗时

Table 4.7 The accuracy and training time of different algorithms

算法	正确率（%）	耗时（s）
CNN-LSTM	90.5	7.2
Inception-V3	94.1	6.7
CNN-Transformer	98.1	6.2

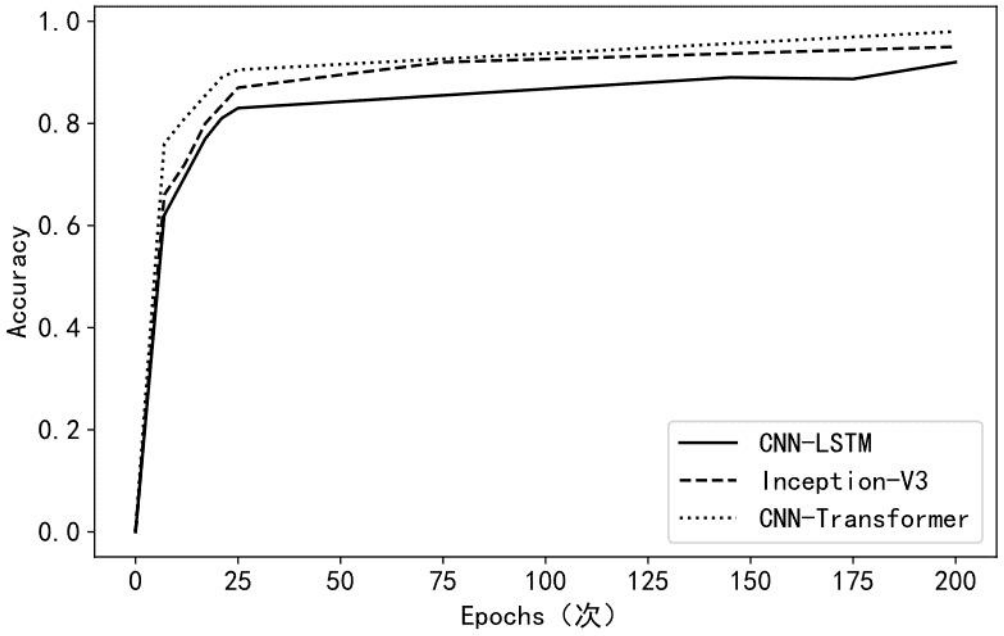


图 4.12 不同模型正确率

Fig.4.12 Correct rate of different models

图 4.12 与图 4.13 表示随着训练的不断进行，其展示出来的正确率折线图如图所示。在对数据的分析中得出 CNN-Transformer 模型与 Inception-v3 算法正确率较高且耗时较短，但是在 ESC-50 数据集上 Inception-v3 算法的研究效果有所下降，这可能是其面对数据集 Inception-v3 算法的数据学习效果不佳。CNN-Transformer 模型具有很好地数据处理效果，说明其对数据具有很好的分析效果，而 CNN-LSTM 模型在

中国知网 https://www.cnki.net

正确率上的研究有待提高，这是因为 CNN-LSTM 模型在参数的设置上需要有很好的科学性，需要对设置不断完善。Inception-v3 算法 、CNN-Transformer 模型在正确率上具有很好的优势，随着训练样本的不断完善，其正确率也在不断提升，CNN-LSTM 模型在经过 200 代的训练过程中其正确率高达 90.5%左右， Inception-v3 算法在数据处理上的正确率为 90.1%，在经过 200 次的训练中其正确率高达 94%左右；CNN-Transformer 模型具有很高的正确率，尤其是经过 200 次训练之后的正确率高达 98%，从 loss 图上来看，曲线的变化趋势都呈现出逐渐下降的趋势，这也是其数据拟合的重要因素，CNN-Transformer 模型在这样的情况下表现出的特征尤其显著，这是因为 CNN-Transformer 模型的 3D 卷积需要借助大量的数据实现，但是其优异的学习能力，使得在正确率上和数据处理上的差异不大。

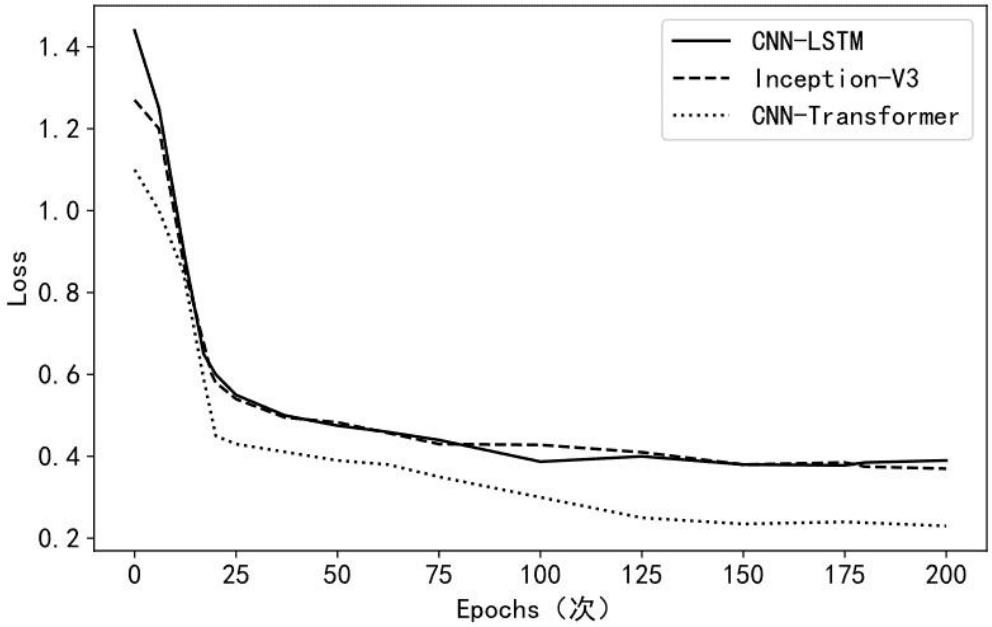


图 4.13 不同模型 loss 变化

Fig.4.13 Changes in loss of different models

根据数据集比较的结果来看，Inception-v3 算法不如 CNN-Transformer 模型，其主要体现在学习能力上的差异，CNN-Transformer 模型学习能力更佳，Inception-v3 受到拟合因素的影响使得数据的学习处理效率受到牵制，但是在多次训练之后的正确率也非常高；同时 CNN-Transformer 模型在稳定性上更加突出，而 Inception-v3 算法在 Freesound 数据集上的表现明显好于 ESC-50 的数据集说明其模型适用性有待提升。

中国知网 https://www.cnki.net

图 4.14 是 Inception-V3 算法针对单类正确率的分析，其中因饥饿而哭泣与因打嗝而哭泣的类分别为 0.82 和 0.81，主要是受到语谱图的影响，使得其稳定性降低，理论上采样的帧节时间间断较小在研究中的影响不大，但是在实际的自注意力帧节输入中却会出现卡顿的情况。Inception-V3 算法在单分类正确率中只有一类达到了90%以上，而其他四类的准确率都不高

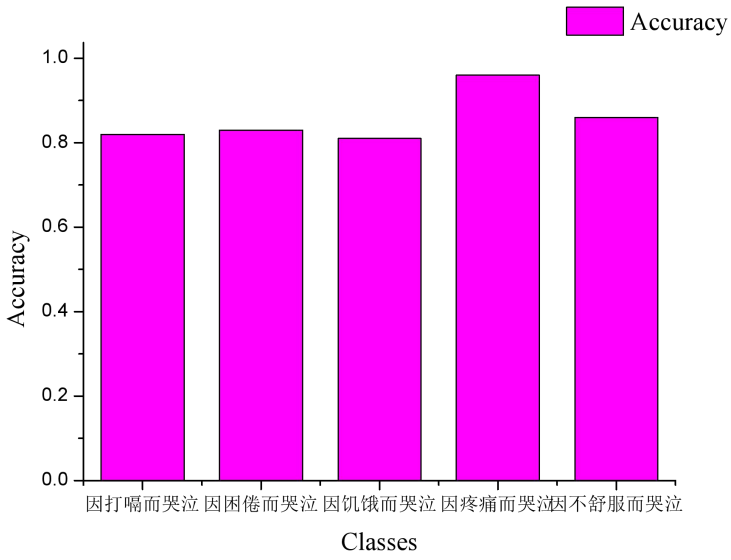


图 4.14 Inception-V3 算法的单类正确率

Fig.4.14 Single-class accuracy rate of Inception-V3 algorithm

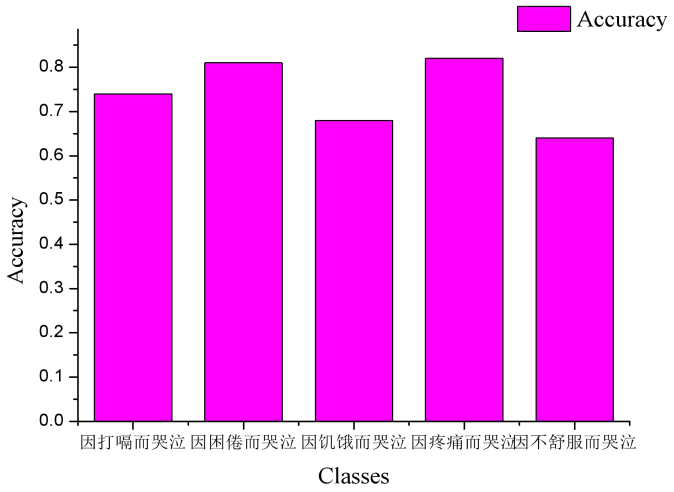


图 4.15CNN- LSTM 模型的单类正确率

Fig.4.15 Single-class accuracy rate of CNN-LSTM model

中国知网 https://www.cnki.net

图 4.15 是 CNN-LSTM 模型的单分类正确率。这里因不舒服而哭泣类的正确率为64%是表现最低的，研究中因打嗝而哭泣、因饥饿而哭泣以及因不舒服而哭泣这 3 类的正确率在 80%以下；同时，而因困倦而哭泣与因疼痛而哭泣这 2 类的正确率在 80%与 90%之间，说明在 Freesound 数据集下，CNN-LSTM 模型的数据适应性并不好。

图 4.16 是 CNN-Transformer 模型的单类正确率。研究中因困倦而哭泣、因饥饿而哭泣以及因不舒服而哭泣这 3 类的正确率在 90%以下 80%以上，而因打嗝而哭泣与因疼痛而哭泣这 2 类正确率极高，并且 5 类正确率都超过了 80%。其主要原因是 CNN-Transformer 模型在时间特征的采集效果更好，而在因饥饿而哭泣类上，会因为数据模糊问题受到影响，这也是值得关注的地方。

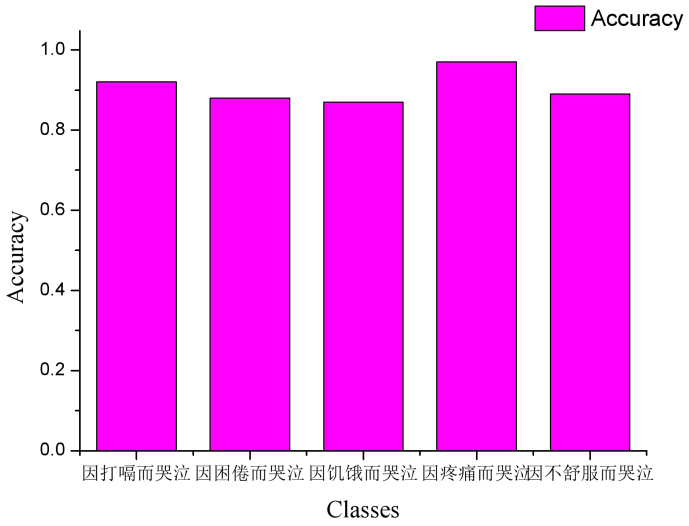


图 4.16 CNN-Transformer 模型的单类正确率

Fig.4.16 Single-class accuracy rate of CNN-Transformer model

针对上述的分析可以得出，在 Freesound 数据集上 CNN-Transformer 模型在分类正确率，单分类正确率以及训练耗时三个方面都具有很好的表现，并且在 ESC-50 的数据集上也有很高的正确率以及单分类正确率，由此可以看出 CNN-Transformer 模型相比其他两个模型具有很好的泛化性。

4.5 Encoder 堆叠模型

本文在对婴儿啼哭情感分析模型进行研究时发现，神经网络的学习能力会伴随着网络的深入而不断提升。谷歌对 Transformer 模型的使用主要体现在机器编译方面，研究中发现当存在 6 个 Encoder 与 Decoder 时的处理效果最好，但是还是会受到时序的影响，同时随着学习的不断深入，学习过程中的成本以及对于硬件和软件

中国知网 https://www.cnki.net

环境的要求也在不断提高，如何实现成本和学习能力之间的平衡，也是需要研究的重点。

为保证研究思路的科学有效，提升数据处理效率，确保学习能力不断提升，本文的模型结构设计就是简单一个的 Encoder 的结构。这里开展各项信息数据的对比分析，在对比模型的研究中分别使用 1 个 Encoder 堆叠模型、2 个 Encoder 堆叠模型、3 个 Encoder 堆叠模型作为模型创建的基础，Encoder 的数量也可以继续增加，但是过多的 Encoder 堆叠会带来网络难以训练的问题。本文实验研究中发现使用 3 个 Encoder 可以实现数据的快速处理，也是系统性能最优化的表现。使用 Freesoud 数据集可以避免拟合造成的影响，对系统的稳定性和数据的完整性具有积极的意义，并且可以提升网络收敛的速度。这里的模型都是在无 nestrov 的 SGD 优化器基础上实现优化，然后通过 200 次训练来对正确率进行研究分析。

图 4.17 是采用 CNN-Transformer 模型呈现的堆叠模型正确率变化曲线图。由图可以得出，其添加的 Encoder 堆叠数为 CNN-Transformer 模型学习能力的提升创造更多的空间，随着 Encoder 数量的增加，其正确率也在不断提升。1 个 Encoder 堆叠模型每次训练的时间大约为 6 秒，添加一个 1 个 Encoder 所增加时间为 6s 左右，对于训练耗时来说其增加不大。不同堆叠模型正确率提升速度相差不大，这也说明模型的收敛速度相差不大。CNN-Transformer 模型的三种堆叠模型正确率变化如下所示：

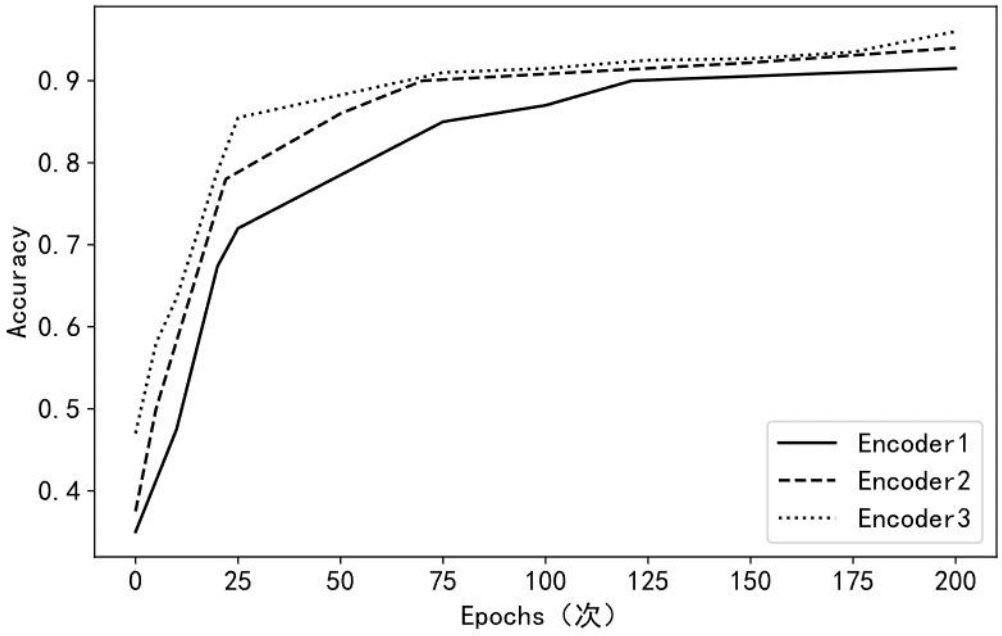


图 4.17 CNN-Transformer 模型的三种堆叠模型正确率

Fig.4.17 The accuracy of the three stacked models of the CNN-Transformer model

中国知网 https://www.cnki.net

4.6 本章小结

本章提出采用 CNN-Transformer 模型对婴儿哭声进行情感分类，给出了模型的构建过程和具体细节，并对模型进行优化，此优化步骤包括：用 3D 卷积代替 resent50 与 pool5 层，将 Transformer 中的线性层与全连接层用 sin 与 cos 函数进行位置编码的修改，用 AA 多头感知方式进行修改，来保证归一化的效果。最后通过实验来验证，对 CNN-Transformer 模型、Inception-V3 算法以及 CNN-LSTM 模型的特征性能进行了对比分析，其结果表明本文提出的 CNN-Transformer 模型在分类正确率、单分类正确率以及训练耗时三个评价指标中都有良好的表现。

中国知网 https://www.cnki.net

第 5 章 总结与展望

5.1 总结

随着科技的快速发展，人类生活品质有了质的飞跃，科技给我们的生活带来了极大的便利。新生儿的诞生给家庭带来了许多欢笑，同时也带来了很大的挑战。婴儿与父母沟通表达需求的唯一途径就是哭泣，然而作为新手爸妈，很难短时间内就学会如何快速地知道婴儿所表达什么需求，也无法快速地判断是否宝宝的身体有所不适，这些问题给家庭带来了许多焦虑。本文针对此种需求，利用深度学习在语音识别上的优势，提出了基于 CNN-Transformer 模型的婴儿啼哭情感分析方法，来快速又准确地对婴儿的哭声作出分类。本文的研究成果有以下几个方面：

（1） 本文收集了 YouTube 网站与公开数据集上的音频数据，并对音频进行整理筛选，根据丹斯婴儿语言理论设计了包含 5 种情感的婴儿哭声情感数据库，为婴儿啼哭情感分析模型的研究与应用提供了扩充后的数据支持。

（2） 本文对婴儿哭声发声的原理与特点进行分析，总结了婴儿哭声特有的特点，并采用预加重、分窗、加帧、端点检测方式对婴儿哭声语音数据进行了适合的预处理，为后续模型的训练提供了优秀的音频信息。本文提出的婴儿啼哭数据预处理技术提供了一套标准的数据处理过程，为其他研究者提供了新的思路。

（3） 本文提出采用 CNN-Transformer 模型对婴儿哭声进行情感分类，将语音信号转换成语谱图的形式进行特征提取，并对模型进行改进将连续语谱图以视频帧的形式进行情感分析研究。为验证本文所提出的模型的有效性，将本文模型与 Inception-v3 算法及 CNN-LSTM 模型进行对比，并分别在两个公开数据集上进行实验验证，实验结果证明了本文提出的模型在准确率、单分类准确率、时间效率方面都有较大的提升。

5.2 展望

本文首先对婴儿发声与成人的发声的特点进行了分析与研究，总结出了婴儿哭声特有的特点。其后，建立了基于 5 种哭声情感的数据库，此数据库对模型的训练起着重要的作用。本文还对相关工作中基于深度学习的语音情感分析模型的优势及不足进行了分析，提出了基于 CNN-Transformer 模型对婴儿的哭声进行情感分类。实验结果表明该模型在三个评价指标中有一定的提升。但本文也存在着不足之处，在接下来的工作中会逐步完善。

（1） 由于时间的原因，本文所提出的模型在两个公开数据集上分别与 Inception-v3 算法及 CNN-LSTM 模型进行了对比，在这三个评价指标上有优秀的表

中国知网 https://www.cnki.net

现，然而与其他更多的模型如 LSTM 的改进模型[62]性能的对比与分析以及在其他的评价指标上的表现还有待深入研究。

（2） 本文所提出的婴儿哭声情感分析模型在两个公开的数据集上的测试有着较好的表现，但是由于时间关系以及实验用可靠数据集有限，对模型泛化性的研究会在后续工作中完成。

中国知网 https://www.cnki.net

致谢

朝来庭下，光阴似箭。写到此处时，三年的研究生生活快要步入尾声。我本科的时候也就读于沈阳化工大学，在这所学校我生活学习了 7 年，从 19 岁到 26 岁。学校于我来说非同寻常，而我也十分幸运，在求学与生活当中遇到了很多帮助我的人，老师，同学，家人，素未谋面的论坛小伙伴，同时也幸运的遇到了我的另一半。

古之学者必有师，师者传道授业解惑也。感谢我的导师王亮老师，不仅仅学业上的帮助，知识的传授更感谢老师对于我生活上的指导与点拨。在论文初期选题的指导，完成度的督促，到成稿的审改都饱含着老师的认真负责，一遍又一遍地对论文进行指导修改饱含着老师的心血。感谢老师为我创造了优良的科研环境，感谢老师对我的肯定，耐心与引导。同时也感谢计算机科学与技术学院的所有老师，对于学习上的帮助与指导。我会继续在未来的道路上继续努力，不会停止学习的步伐。

何其幸运，在三年的生活中遇到了可爱的室友们，王妮，雪雁，美颀。不开心时对我的安慰与宽解，开心时一起的打闹，一起对于课题进行讨论，感谢你们对于我学习与生活上的帮助。不论是本科时期，还是研究生时期，都遇到了非常可爱的室友们，一起生活，一起成长。同时还有同班的同学们，大家来自五湖四海，感谢缘分，让我们一起学习生活三年。也感谢在论坛上素未谋面的小伙伴，谢谢你们给予我知识上的点拨。

从大学时候开始在外一人生活到现在，7 年，妈妈爸爸每天一个电话，担心我照顾不好自己，担心我是否按时加衣，担心我生活费是否够花，担心我学习累不累。我胆子很小，也不善表达，遇到问题爸爸妈妈总是无条件地支持我，爸爸妈妈总是尽其所能来让我生活得更好让我更开心。感谢爸爸妈妈，爸爸妈妈是我永远的精神支柱和港湾。

青青子衿悠悠我心。七年时间里，我很幸运了遇到超哥，一个脾气有些急躁的但却善良又正义，聪明又幽默的男孩。相处 5 年，朝朝暮暮。感谢在我考研时期，做实验时期的打气与鼓励。

最后，感谢百忙之中抽出时间来审阅论文的各位老师，感谢你们提出的宝贵意见和建议！

中国知网 https://www.cnki.net

攻读学位期间发表的期刊文章

[1] 基于词汇的微博情感分类分析新方法[J]电子技术与软件工程 CN10-1108/TP.2020.
（已发表，为第一作者）

中国知网 https://www.cnki.net

参考文献

[1] Smith J . Calm the Crying: Using the Dunstan Baby Language, The Secret Baby Language That Reveals the Hidden Meaning Behind an Infant's Cry[J]. Jurnal Sains Terapan, vol. 3, no. 5, pp:39-44, 2013.

[2] Cohen R， Lavner Y . Infant Cry Analysis and Detection[M].in 2012 IEEE 27th Convention of Electrical & Electronics Eng. Israel (IEEEI), IEEE, pp: 1–5, 2012.

[3] Lester B M， Boukydis C， Garcia-Coll C T , et al. Infantile Colic: Acoustic Cry Characteristics, Maternal Perception of Cry and Temperament[J]. Infant Behavior and Development, 15(1)pp:15-26, 1992.

[4] Mima Y， Arakawa K . Cause Estimation of Younger Babies' Cries from the Frequency Analyses of the Voice - Classification of Hunger, Sleepiness, and Discomfort -[J]. Ieice Technical Report, 106(260):43-46, 2006.

[5] Briones R L， Kuch B， BF Liu, et al. Keeping up with the digital age: How the American Red Cross Uses Social Media to Build Relationships[J]. Public Relations Review, 37(1) pp:37-43, 2011.

[6] Marshall Z . The Relation between Variations in Pitch and Maternal Perceptions of Infant Crying[J]. Child Development, 59(1) pp:193-196, 1988.

[7] JR György VÁRALLYAY. Future Prospects of the Application of the Infant Cry in the Medicine[J]. Electrical Engineering, volume 50(1-2) pp:47-62, 2006.

[8] Wasz-Höckert O, Partanen T J, Vuorenkoski V, et al. The Identification of some Specific Meanings in Infant Vocalization[J]. Experientia, 20(3) pp:154-154, 1964.

[9] Zabidi A， Yassin I M， Hassan H A , et al. Detection Of Asphyxia In Infants Using Deep Learning Convolutional Neural Network (CNN) Trained On Mel Frequency Cepstrum Coefficient (MFCC) Features Extracted From Cry Sounds[J]. Journal of Fundamental and Applied Sciences, 9(3S) pp:132-138, 2017.

[10] Ji C , Xiao X , Basodi S , et al. Deep Learning for Asphyxiated Infant Cry Classification Based on Acoustic Features and Weighted Prosodic Features[C]// 2019 International Conference on Internet of Things (iThings) and IEEE Green Computing and Communications (GreenCom) and IEEE Cyber, Physical and Social Computing (CPSCom) and IEEE Smart Data (SmartData). IEEE, 2019.

[11] Zabidi A， Mansor W， Lee Y K , et al. Binary Particle Swarm Optimization for Selection of Features in the Recognition of Infants Cries with Asphyxia[C]// Signal Processing and its Applications (CSPA), 2011 IEEE 7th International Colloquium on. IEEE, 2011.

中国知网 https://www.cnki.net

[12]Garcia J O , Garcia C . Acoustic features Analysis for Recognition of Normal and Hypoacoustic Infant Cry Based on Neural Networks[C]// 7th International Work Conference on Artificial and Natural Neural. 2003.

[13]Hariharan M , Sindhu R , Yaacob S . Normal and Hypoacoustic Infant Cry Signal Classification Using Time–Frequency Analysis and General Regression Neural Network[J]. Computer Methods & Programs in Biomedicine, 108(2)pp:559-569, 2012.

[14]Petroni M , Malowany A S , Johnston C C , et al. A Comparison of Neural Network Architectures for the Classification of Three Types of Infant Cry Vocalizations[C]// Engineering in Medicine and Biology Society, 1995. IEEE 17th Annual Conference. IEEE, 1995.

[15]Mohammed Y A . Infant Cry Recognition System: A Comparison of System Performance based on CDHMM and ANN[J]. International Journal of Advanced Pervasive & Ubiquitous Computing, 11(1)pp:15-32, 2019.

[16]Srijiranon K , Eiamkanitchat N . Application of Neuro-Fuzzy Approaches to Recognition and Classification of Infant Cry[C]// TENCON 2014 - 2014 IEEE Region 10 Conference. IEEE, 2015.

[17]A Rosales-Pérez, CA Reyes-García, Gonzalez J A , et al. Infant Cry Classification Using Genetic Selection of a Fuzzy Model[C]// Iberoamerican Congress on Pattern Recognition. Springer Berlin Heidelberg, 2012.

[18]Lavner Y , Cohen R , Ruinskiy D , et al. Baby Cry Detection in Domestic Environment Using Deep Learning[J]. Social Science Electronic Publishing,pp:15 -22,2017.

[19]Neustein, Ed. Advances in Speech Recognition: Mobile Environments, Call Centers and Clinics. New York: Springer[M], PP: 57-58,2010.

[20]Guyer C, Fontijn J, Bucher H U, et al. Effects of a 24h Light-Dark Rhythm in Neonatal Care on Sleep and Crying Patterns of Preterm Infants [J]. Swiss Medical Weekly: Official Journal of the Swiss Society of Infectious Diseases. 138(4)pp:62-64, 2008.

[21]Zabidi A , Yassin I M , Hassan H A , et al. Detection Of Asphyxia In Infants Using Deep Learning Convolutional Neural Network (CNN) Trained On Mel Frequency Cepstrum Coefficient (MFCC) Features Extracted From Cry Sounds[J]. Journal of Fundamental and Applied Sciences, 9(3S)pp:17-21, 2017.

[22]Franti E , Ispas I , Dascalu M . Testing the Universal Baby Language Hypothesis - Automatic Infant Speech Recognition with CNNs[C]//2018 41st International

中国知网 https://www.cnki.net

Conference on Telecommunications and Signal Processing (TSP), Athens,, pp:1-4, doi: 10.1109/TSP.2018.8441412, 2018.

[23] Mohamad Adnan Al-Alaoui Lina Al-Kanj Jimmy Azar Elias Yaacoub. "Speech Recognition Using Artificial Neural Networks And Hidden Markov Models[C]" The 3rd International Conference on Mobile and Computer Aided Learning IMCL Conference pp:16-18 April 2008.

[24] Chen S T , Srinivasan K , Lin C , et al. Neonatal Cry Analysis and Categorization System Via Directed Acyclic Graph Support Vector Machine[M]. Big Data Analytics for Sensor-Network Collected Intelligence. pp:205-222, 2017.

[25] Sahak R , Mansor W , Lee K Y , et al. Optimization of Principal Component Analysis and Support Vector Machine for the Recognition of Infant Cry with Asphyxia[J]. International Journal of Computers and Applications, 35(3)pp:99-107, 2013.

[26] Michelsson K , Pertti S A , O Wasz‐Höckert. Sound Spectrographic Cry Analysis of Infants with Bacterial Meningitis[J]. Developmental Medicine & Child Neurology,19,2010.

[27] Dokur Z, Lmez T. Heart Sound Classification Using Wavelet Transform and Incremental Self-Organizing Map[J]. Digital Signal Processing, 18(6)pp:951-959, 2008.

[28] S. Chandralingam, T. Anjaneyulu, and K. Satyanarayana, “Estimation of Fundamental and Formant Frequencies of infants cries; a study of infants with congenital heart disorder,” in Indian Journal of Comp. Sc. and Eng., vol. 3(4), pp:574–582, 2012.

[29] Yoo S K , Sofotasios P C , Cotton S L , et al. Entropy and Energy Detection-based Spectrum Sensing over F Composite Fading Channels[J]. IEEE Transactions on Communications.1-1, 2019.

[30] Dewi S P , Prasasti A L , Irawan B . The Study of Baby Crying Analysis Using MFCC and LFCC in Different Classification Methods[C]// IEEE International Conference on Signals and Systems. Faculty of Electrical Engineering, Telkom University, Bandung, Bandung, Indonesia;Faculty of Electrical Engineering, Telkom University, Bandung, Bandung, Indonesia;Faculty of Electrical Engineering, Telkom University, Bandung, Bandung, Indonesia;, 2019.

[31] 王群. 面向监控场景的婴儿哭声识别[D].中国科学院大学(中国科学院深圳先进技术研究院),2019.

[32] 崔战士. 复杂背景噪声中的婴儿啼哭声检测研究[D].哈尔滨工业大学,2019.

[33] 魏丽娜. 婴儿情绪信息的模式识别技术研究与实现[D].复旦大学,2012.

中国知网 https://www.cnki.net

[34]吴鸿凯. 基于婴儿哭声检测的婴儿情感需求信息识别方法研究[D].东南大学,2018.

[35]王诗佳. 基于深度学习的声音事件识别研究[D].东南大学,2018.

[36]王毅, 谢娟, 成颖. 结合 LSTM 和 CNN 混合架构的深度神经网络语言模型[J]. 情报学报, 037(002):194-205, 2018.

[37]赵永生, 徐海青, 张引强. 基于 CNN RSC 组合优化算法语音情感分析与研究[J]. 湘潭大学自然科学学报, 040(004):101-105, 2018.

[38]李洋, 董红斌. 基于 CNN 和 BiLSTM 网络特征融合的文本情感分析[J]. 计算机应用, 38(11):29-34, 2018.

[39]缪裕青, 汪俊宏, 刘同来,等. 图文融合的微博情感分析方法[J]. 计算机工程与设计, 040(004):1099-1105, 2019.

[40]Yadav S , Ekbal A , Saha S , et al. Feature Assisted Stacked Attentive Shortest Dependency Path Based Bi-LSTM Model for Protein-Protein Interaction[J]. Knowledge-Based Systems, 166(FEB.15)pp:18-29, 2019.

[41]Liang J , Chai Y , Yuan H , et al. Polarity Shifting and LSTM Based Recursive Networks for Sentiment Analysis[J]. Journal of Chinese Information Processing, 29(5).pp:152-160,2015.

[42]Ma Y , Peng H , Khan T , et al. Sentic LSTM: a Hybrid Network for Targeted Aspect-Based Sentiment Analysis[J]. Cognitive Computation, vol 10(1),pp:639-650,2018.

[43]Yz A , Pt B , Ds C , et al. Learning Interaction Dynamics with an Interactive LSTM for Conversational Sentiment Analysis[J]. Neural Networks, 133:40-56, 2021.

[44]Schmidhuber J , Gers F , D Eck. Learning Nonregular Languages: A Comparison of Simple Recurrent Networks and LSTM[J]. Neural Computation, 14(9)pp:2039-2041, 2014.

[45]郭浩然. 大熊猫行为识别研究与应用[D]. 电子科技大学, 2019.

[46]Gao L , Dai Z , Callan J . Modularized Transfomer-based Ranking Framework[C]// Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2020.

[47]胡章芳、徐轩、付亚芹、夏志广、马苏东. 基于 ResNet-BLSTM 的端到端语音识别[J]. 计算机工程与应用, 56(18):130-136, 2020.

[48]李想, 郑涌, 孟宪鑫,等. 成人对婴儿哭声的反应及其脑机制[J]. 心理科学进展，21(10):1770-1779, 2013.

[49]张赛花, 赵兆, 许志勇,等. 基于 Mel 子带参数化特征的自动鸟鸣识别[J]. 计算机应用, 37（4）:1111-1115，2017.

中国知网 https://www.cnki.net

[50]Nisbet M C， Mooney C . Framing Science[J]. Science, 316(5821):56-56, 2007.

[51]Duarte T， Prikl Ad Nicki R， F Ca lefato, et al. Speech Recognition for Voice-Based Machine Translation[J]. IEEE Software, 31(1):26-31, 2014.

[52]遼莞 田代, 聖一 芹川, 優希 北園. Development of Operation Support System of Blinker and Hazard Lamp by Image Processing and Voice Recognition[J]. 産業応用工学会論文誌, 8(2):140-146, 2020.

[53]Khunarsal P， Lursinsap C， Raicharoen T . Very Short Time Environmental Sound Classification Based on Spectrogram Pattern Matching[J]. Information Sciences, 243(Complete),PP:57-74, 2013.

[54]Alpar O . Frequency spectrograms for Biometric Keystroke Authentication Using Neural Network Based Classifier[J]. Knowledge-Based Systems, 116(JAN.15),PP:163-171, 2016.

[55]Litjens G， Kooi T， Bejnordi B E , et al. A Survey on Deep Learning in Medical Image Analysis[J]. Medical Image Analysis, 42(9):60-88, 2017.

[56]张号逵, 李映, 姜晔楠. 深度学习在高光谱图像分类领域的研究现状与展望[J]. 自动化学报, 44(006):961-977, 2018.

[57]Liu W , Li W , Gong W . Ensemble of Fine-Tuned Convolutional Neural Networks for Urine Sediment Microscopic Image Classification[J]. IET Computer Vision, 14(2) ,pp:28-32, 2019.

[58]Fernandez R， Mauricio D . Bullet Impact Detection in Silhouettes Using Mask R-CNN[J]. IEEE Access, (99)PP:1-1, 2020.

[59]Tangriberganov G， Adesuyi T， Kim B M . A Hybrid Approach for Speech Emotion Recognition Using 1D-CNN LSTM[C]// Korea Computer Congress (KCC 2020). 2020.

[60]Szegedy C， Vanhoucke V， Ioffe S , et al. Rethinking the Inception Architecture for Computer Vision[J]. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 308,pp:2818-2826, 2016.

[61]ifj. Várallyay György, Benyó Zoltán,et al. Acoustic Analysis of the Infant Cry: Classical and New Methods[J]. Conference proceedings:. Annual International Conference of the IEEE Engineering in Medicine and Biology Society. IEEE Engineering in Medicine and Biology Society. Conference, 1:313-316, 2004.

[62]余莉萍, 梁镇麟, 梁瑞宇. 基于改进 LSTM 的儿童语音情感识别模型[J]. 计算机工程, 46(6):40-49，2020.

中国知网 https://www.cnki.net